



PAUTA PRUEBA 2

Pregunta 1

- a) Se usaron dos métodos:
- Clustering jerárquico con "average linkage" (distancia promedio)
 - K-medias con $k = 2$
- b) En ambos casos se obtuvieron 2 clusters: {P1, P2, P3} y {P4, P5}
- c) Dendrograma:



- d) La fórmula usada para la normalización fue $y = \frac{x - \min}{\max - \min}$ con los valores máximos y mínimos dados en el enunciado. Luego la transformación inversa es:

$$x = y(\max - \min) + \min$$

Para la presión sería $x = 100y + 100$

Para la glucosa $x = 100y + 50$

Centroide 1:

- Presión: 0.2 $\rightarrow$ 120 mmHg
- Glucosa: 0.6 $\rightarrow$ 110 mg/dL

Centroide 2:

- Presión: 0.85 $\rightarrow$ 185 mmHg
- Glucosa: 0.2 $\rightarrow$ 70 mg/dL

- e) Todos los valores del coeficiente de silhouette son > 0 , por lo que no hay ninguna que esté mal asignada.

Pregunta 2

- a) La historia solo muestra un caso, que puede haber ocurrido por azar. Es más, si la promoción se hubiera enviado a todas las clientes mujeres la situación hubiera ocurrido igual, aunque solo un porcentaje pequeño de ellas esté embarazada. En otras palabras, el caso no nos dice nada de cuántas mujeres embarazadas no recibieron la promoción ni de cuántas mujeres no embarazadas la recibieron.

Para evaluar correctamente el método hay que revisar la matriz de confusión:

		Predicho	
		Embarazada	No embarazada
Verdadero	Embarazada		
	No embarazada		

Algunos de los indicadores que se pueden calcular con la matriz son:

- Exactitud (Accuracy)
- Sensibilidad (Recall)
- Especificidad
- Precisión

- b) Este es un problema de clasificación (Embarazada/No embarazada) por lo que se necesitaría datos etiquetados, es decir una base de datos de clientas en la que se sepa si están embarazadas o no. Además de a variables de “etiqueta” necesitaremos las variables predictoras, que en el caso del retail puede ser el consumo de cada clienta en los distintos artículos (cada artículo es una variable). Otras variables que pueden ayudar a la predicción si es que se cuenta con ella son las características demográficas de la clienta (edad, nivel de estudios, comuna en que vive, etc.)

El modelo de clasificación puede ser:

- Análisis discriminante lineal (LDA) si los datos son normales y la matriz de varianza de los predictores es igual entre embarazadas y no embarazadas
- Análisis determinante cuadrático (QDA) si los datos son normales pero las matrices de varianza son distintas
- Bayes Ingenuo, más flexible, permite combinar variables categóricas con numéricas