



Profesores: Carmen Carrasco | Héctor López

Ayudantes: José Ignacio Costa | Cristóbal Van der Meer

Pauta Ayudantía 2

P1- Una empresa afirma que como máximo el 15 % de sus parabrisas no cumplen con las especificaciones. Para evaluar esta afirmación, se toma una muestra aleatoria de tamaño 200, en la cual se observa que 40 parabrisas no cumplen con las especificaciones.

¿La información muestral respalda la afirmación de la empresa? Formule y desarrolle una prueba de hipótesis para responder la pregunta, utilizando un nivel de significancia del 5 %.

Solución:

Definamos H_0 y H_1 :

$$\begin{array}{l} \blacksquare H_0 : p \leq 0,15 \\ \blacksquare H_1 : p > 0,15 \end{array}$$

Adicionalmente, notemos que $np_0 = 200 \cdot 0,15 = 30 \geq 5$ y $n(1 - p_0) = 200 \cdot 0,85 = 170 \geq 5$. En consecuencia, es posible deducir que corresponde a un test de proporciones con muestras grandes. Luego, determinamos el pivote obtenido:

$$\blacksquare z_{\text{obt}} = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \frac{0,2 - 0,15}{\sqrt{\frac{0,15 \cdot 0,85}{200}}} = \frac{0,05}{0,0252} \approx 1,98$$

Finalmente, según Región Crítica, puesto que $z_{\text{obt}} > z_{0,05} = 1,64$, se rechaza H_0 , es decir, existe evidencia suficiente para afirmar que la proporción de parabrisas que no cumplen con las especificaciones es mayor al 15 %. Por tanto, la información muestral no respalda la afirmación de la empresa.

De forma equivalente, utilizando software:

Resolución con Comando

```
x <- 40
n <- 200
p0 <- 0.15
prop.test(x, n, p = p0, alternative = "greater", correct = FALSE)
```

Esto permite obtener el siguiente resultado en consola:

Consola

```
> prop.test(x, n, p = p0, alternative = "greater", correct = FALSE)
1-sample proportions test without continuity correction
data:  x out of n, null probability p0
X-squared = 3.9216, df = 1, p-value = 0.02384
alternative hypothesis: true p is greater than 0.15
95 percent confidence interval:
 0.157619 1.000000
sample estimates:
 p
0.2
```

Finalmente, si consideramos $z_{\text{obt}} = \sqrt{3,9216} = 1,9803 > z_{0,05} = 1,64$, se rechaza H_0 , es decir, existe evidencia suficiente para afirmar que la proporción de parabrisas que no cumplen con las especificaciones es mayor al 15 %. Por tanto, la información muestral no respalda la afirmación de la empresa.

Alternativamente, el cálculo manual es:

Resolución con Cálculo directo

```
phat <- 40/200
p0 <- 0.15
n <- 200
z <- (phat - p0)/sqrt(p0*(1-p0)/n)
z # Estadístico
qnorm(0.95) # Valor critico
1 - pnorm(z) # p-valor
```

Esto permite obtener:

Consola

```
> z # Estadístico
[1] 1.980295
> qnorm(0.95) # Valor critico
[1] 1.644854
> 1 - pnorm(z) # p-valor
[1] 0.02383519
```

Finalmente, como $z_{\text{obt}} = 1,98 > z_{0,05} = 1,64$, se rechaza H_0 , es decir, existe evidencia suficiente para afirmar que la proporción de parabrisas que no cumplen con las especificaciones es mayor al 15 %. Por tanto, la información muestral no respalda la afirmación de la empresa.

P2- El dueño de una empresa empackadora de productos alimenticios necesita adquirir una nueva máquina para verificar el peso de las bolsas que empaca. Se supone que la desviación estándar del peso de las bolsas debe ser igual a 0,02 kg y el peso de las bolsas distribuye normal. Con el fin de decidir si compra la máquina a cierto proveedor, se toma una muestra aleatoria de 20 bolsas, obteniéndose las siguientes mediciones (en kg):

0,95	1,02	1,02	0,97	1,03	0,97	1,01	1,00	1,02	0,98
0,98	1,01	1,00	0,99	1,01	0,98	1,02	1,04	1,03	0,80

Considere un nivel de significancia del 5 %.

- El dueño comprará la nueva máquina si se demuestra que la media está centrada en 1 kg. Determine si debe adquirir la máquina mediante una prueba de hipótesis utilizando el valor- p .
- Determine los valores de la media muestral que implican que no se cumple la suposición.
- Calcule la probabilidad de no rechazar la afirmación de que la media poblacional es 1 kg, sabiendo que la media poblacional verdadera es 1,005 kg.

Solución:

(a) Definamos H_0 y H_1 :

$$\begin{array}{l} \blacksquare H_0 : \mu = 1 \\ \blacksquare H_1 : \mu \neq 1 \end{array} \quad \left| \right.$$

Dado que se conoce la desviación estándar poblacional ($\sigma = 0,02$) y la población es normal, se utiliza un test Z :

Resolución con Cálculo directo

```
x <- c(0.95,1.02,1.02,0.97,1.03,0.97,1.01,1.00,1.02,0.98,
      0.98,1.01,1.00,0.99,1.01,0.98,1.02,1.04,1.03,0.8)
z <- (mean(x)-1)/(0.02/sqrt(20))
z
2*(1-pnorm(abs(z))) # p-valor
```

Esto permite obtener:

Consola

```
> z
[1] -1.900658
> 2*(1-pnorm(abs(z))) # p-valor
[1] 0.05734685
```

Finalmente, dado que $p\text{-value} = 0,057 > 0,05$, no se rechaza H_0 , es decir, no existe evidencia estadística suficiente para afirmar que la media difiere de 1 kg. Por lo tanto, la máquina cumple con la especificación requerida y puede ser adquirida.

(b) Notemos el intervalo de no rechazo de H_0 :

$$z_{0,025} \leq z \leq z_{0,975} \implies \mu_0 + z_{0,025} \frac{\sigma}{\sqrt{n}} \leq \bar{X} \leq \mu_0 + z_{0,975} \frac{\sigma}{\sqrt{n}}$$

Utilizando R:

Resolución con Cálculo directo

```
z_inf <- qnorm(0.025)
z_sup <- qnorm(0.975)
x_inf <- z_inf*(0.02/sqrt(20))+1
x_sup <- z_sup*(0.02/sqrt(20))+1
x_inf
x_sup
```

Esto permite obtener:

Consola

```
> x_inf
[1] 0.9912348
> x_sup
[1] 1.008765
```

Finalmente, se rechaza H_0 si $\bar{X} < 0,9912 \vee \bar{X} > 1,0088$, es decir, valores de la media muestral fuera de este intervalo indican que no se cumple la suposición de centrado en 1 kg.

(c) Se desea calcular la probabilidad de no rechazar H_0 cuando la media real es $\mu = 1,005$.

Esto corresponde a:

$$P(0,9912 \leq \bar{X} \leq 1,0088 \mid \mu = 1,005)$$

Utilizando R:

Resolución con Cálculo directo

```
mu <- 1.005
sigma <- 0.02
se <- sigma/sqrt(20)
pnorm(1.0088, mu, se) - pnorm(0.9912, mu, se)
```

Esto permite obtener:

Consola

```
> pnorm(1.0088, mu, se) - pnorm(0.9912, mu, se)
[1] 0.8012406
```

Finalmente, la probabilidad de no rechazar H_0 cuando la media verdadera es 1,005 es aproximadamente 0,80. Esto indica que el test tiene una probabilidad relativamente alta de no detectar pequeñas desviaciones respecto al valor objetivo, es decir, presenta una potencia moderada frente a este escenario.

P3- Una empresa afirma que la varianza del peso de sus paquetes es de $\sigma^2 = 4$ kg. Se toma una muestra aleatoria de tamaño 10, obteniéndose los siguientes pesos: 52, 55, 54, 58, 53, 56, 57, 59, 54, 56.

- (a) Se desea verificar si la varianza es distinta de 4.
- (b) ¿Cuáles son los valores de la varianza muestral que rechazarían la hipótesis?
- (c) Si la verdadera varianza poblacional es 5 ¿Cuál es la probabilidad de no rechazar la hipótesis?

Solución:

(a) Definamos H_0 y H_1 :

$$\begin{array}{l} \blacksquare H_0 : \sigma^2 = 4 \\ \blacksquare H_1 : \sigma^2 \neq 4 \end{array}$$

Utilizando R:

Resolución con Cálculo directo

```
x <- c(52,55,54,58,53,56,57,59,54,56)
n <- length(x)
s2 <- var(x)
sigma02 <- 4
chi <- (n-1)*s2/sigma02
chi_inf <- qchisq(0.025, n-1)
chi_sup <- qchisq(0.975, n-1)
chi
chi_inf
chi_sup
```

Esto permite obtener:

Consola

```
> chi
[1] 11.1
> chi_inf
[1] 2.700389
> chi_sup
[1] 19.02277
```

Finalmente, según Región Crítica, puesto que $2,700389 < 11,1 < 19,02277$, no se rechaza H_0 . Por lo tanto, no existe evidencia suficiente para afirmar que la varianza sea distinta de 4.

(b) Se busca determinar los valores de la varianza muestral que conducen al rechazo de H_0 :

Resolución con Cálculo directo

```
x <- c(52,55,54,58,53,56,57,59,54,56)
n <- length(x)
sigma02 <- 4
chi_inf <- qchisq(0.025, n-1)
chi_sup <- qchisq(0.975, n-1)
s2_inf <- sigma02*chi_inf/(n-1)
s2_sup <- sigma02*chi_sup/(n-1)
s2_inf
s2_sup
```

Esto permite obtener:

Consola

```
> s2_inf
[1] 1.200173
> s2_sup
[1] 8.454563
```

Finalmente, se rechaza H_0 si: $S^2 < 1,200173 \vee S^2 > 8,4546$.

(c) Se desea calcular la probabilidad de no rechazar H_0 cuando la varianza verdadera es $\sigma^2 = 5$:

$$P\left(\chi_{\inf}^2 \leq \frac{(n-1)S^2}{\sigma_{\text{real}}^2} \leq \chi_{\sup}^2\right)$$

Utilizando R:

Resolución con Cálculo directo

```
x <- c(52,55,54,58,53,56,57,59,54,56)
n <- length(x)
sigma02 <- 4
chi_inf <- qchisq(0.025, n-1)
chi_sup <- qchisq(0.975, n-1)
s2_inf <- sigma02*chi_inf/(n-1)
s2_sup <- sigma02*chi_sup/(n-1)
sigma_real <- 5
chi1 <- (n-1)*s2_inf/sigma_real
chi2 <- (n-1)*s2_sup/sigma_real
prob_no_rechazar <- pchisq(chi2, n-1) - pchisq(chi1, n-1)
prob_no_rechazar
```

Esto permite obtener:

Consola

```
> prob_no_rechazar
[1] 0.9035575
```

Finalmente, la probabilidad de no rechazar H_0 cuando la varianza real es 5 es aproximadamente 0,9035575. Esto indica que el test tiene una alta probabilidad de no detectar la diferencia, es decir, presenta una baja potencia frente a este escenario.

P4- Una empresa quiere comparar la variabilidad del tiempo de ensamblaje entre dos máquinas que producen la misma pieza. Se toman 10 observaciones de cada máquina (en minutos):

Máquina A: 15, 16, 14, 18, 17, 16, 15, 19, 17, 16

Máquina B: 12, 14, 13, 15, 12, 14, 13, 12, 14, 13

Se desea comprobar si la máquina A tiene mayor varianza que la máquina B.

Solución:

Definamos H_0 y H_1 :

$$\begin{array}{l} \blacksquare H_0 : \sigma_A^2 \leq \sigma_B^2 \\ \blacksquare H_1 : \sigma_A^2 > \sigma_B^2 \end{array} \quad \left| \right.$$

Luego, utilizamos el comando de R:

Resolución con Comando

```
xA <- c(15,16,14,18,17,16,15,19,17,16)
xB <- c(12,14,13,15,12,14,13,12,14,13)
var.test(xA, xB, alternative = "greater")
```

Esto permite obtener:

Consola

```
> var.test(xA, xB, alternative = "greater")
      F test to compare two variances
data:  xA and xB
F = 2.0938, num df = 9, denom df = 9, p-value = 0.1431
alternative hypothesis: true ratio of variances is greater than 1
95 percent confidence interval:
 0.6586412      Inf
sample estimates:
ratio of variances
      2.09375
```

Finalmente, dado que $p\text{-value} = 0,1431 > 0,05$, no se rechaza H_0 , es decir, no existe evidencia suficiente para afirmar que la máquina A presenta mayor variabilidad en sus tiempos de ensamblaje.

P5- Una empresa de retail analiza el comportamiento de compra de 5 clientes seleccionados mediante cuatro variables: Frecuencia de compra (veces al mes), Gasto promedio (\$), Número de categorías compradas y Uso de cupones (veces). Los datos recolectados, junto con el análisis de componentes principales realizado en R sobre la matriz de correlaciones, se muestran a continuación:


Consola

```
> clientes
  Frecuencia Gasto Categorías Cupones
1          7 41962           5        2
2          8 66644           3        2
3         15 64345           7        4
4         11 53818           5        4
5          9 66123           4        3

> pca <- prcomp(clientes, scale. = TRUE)
> summary(pca)
Importance of components:
               PC1      PC2      PC3      PC4
Standard deviation  1.4617  0.9909  0.8623  0.37143
Proportion of Variance 0.5341 0.2455 0.1859 0.03449
Cumulative Proportion 0.5341 0.7796 0.9655 1.00000

> pca$rotation
               PC1      PC2      PC3      PC4
Frecuencia  0.6341368 -0.2424999 -0.1201098 -0.72431895
Gasto       0.4335808  0.4966545 -0.6776901  0.32569643
Categorías  0.5467570 -0.5127872  0.2654178  0.60634929
Cupones     -0.3330691 -0.6569455 -0.6751764  0.04030424
```

Además, se tiene el siguiente scree plot:



- ¿Cuántos componentes principales recomendaría retener, utilizando el criterio de Kaiser, el criterio del codo y el criterio de varianza acumulada (80%)? Justifique.
- Escriba explícitamente las expresiones de PC1 y PC2.
- Interprete conceptualmente el significado del primer componente principal.
- Un nuevo cliente presenta: Frecuencia = 10, Gasto = \$58000, Categorías = 5, Cupones = 3. ¿Es posible obtener su *score* en PC1 utilizando estos valores en la expresión de PC1 obtenida en (b)? Explique cómo se debe proceder correctamente y calcule el score de este cliente en PC1.

Solución:

(a) Los autovalores se obtienen elevando al cuadrado la desviación estándar de cada componente:

$$\lambda_1 = 1,4617^2 = 2,1366, \quad \lambda_2 = 0,9909^2 = 0,9819, \quad \lambda_3 = 0,8623^2 = 0,7436, \quad \lambda_4 = 0,3714^2 = 0,1379$$

- **Criterio de Kaiser** ($\lambda \geq 1$): Solo PC1 cumple ($\lambda_1 = 2,1366 \geq 1$), por lo que este criterio sugiere retener **1 componente**.
- **Criterio del Codo**: Observando el scree plot, la caída más pronunciada ocurre entre PC1 y PC2, mientras que la caída siguiente es considerablemente menor. Así, el codo se identifica en $k = 2$, por lo que este criterio también sugiere retener **1 componente**.
- **Criterio de varianza acumulada** ($\geq 80\%$): con PC1+PC2+PC3 se supera el umbral, alcanzando 96,55%. Este criterio sugiere retener **3 componentes**.

(b) Cada componente principal es una combinación lineal de las variables **estandarizadas** (es decir, ya centradas y escaladas), usando como coeficientes las cargas (columnas de `pca$rotation`):

$$\begin{aligned} PC_1 &= 0,634 Z_{Frecuencia} + 0,434 Z_{Gasto} + 0,547 Z_{Categorías} - 0,333 Z_{Cupones} \\ PC_2 &= -0,242 Z_{Frecuencia} + 0,497 Z_{Gasto} - 0,513 Z_{Categorías} - 0,657 Z_{Cupones} \end{aligned}$$

(c) Las cargas de PC1 (Frecuencia = 0,634, Gasto = 0,434, Categorías = 0,547, Cupones = -0,333) muestran que las tres primeras variables tienen signo positivo y magnitud considerable, mientras que Cupones tiene signo negativo y menor magnitud.

Esto indica que PC1 puede interpretarse como un **índice general de intensidad de compra o nivel de compromiso del cliente**: los clientes con un puntaje alto en PC1 son aquellos que compran con mayor frecuencia, gastan más en promedio y exploran más categorías de producto, mostrando además una leve tendencia a depender menos de cupones de descuento (consistente con un perfil de cliente más fidelizado, que compra "porque quiere" no principalmente motivado por promociones).

En cambio, un cliente con PC1 bajo compraría poco, gastaría menos y usaría más cupones, características propias de un comprador ocasional y sensible al precio.

(d) No es posible reemplazar los valores originales del cliente directamente en la expresión de PC1, ya que dicha expresión está definida en función de las variables **estandarizadas** Z_j (con media 0 y desviación estándar 1), no de las variables originales X_j , que tienen escalas y unidades muy distintas entre sí (por ejemplo, Gasto está en pesos mientras que Cupones son unidades).

Usar los valores originales sin estandarizar distorsionaría por completo el score, ya que la variable con mayor magnitud (Gasto) dominaría artificialmente el resultado.

De esta manera, reemplazamos los valores Z ya entregados en el PC1 de (b):

$$\begin{aligned} PC1 &= 0,634 (-0,1784) + 0,434 (0,0460) + 0,547 (0,2664) - 0,333 (-0,1426) \\ &= -0,1131 + 0,0200 + 0,1457 + 0,0475 \\ &= 0,1001 \end{aligned}$$

Finalmente, como este score es muy cercano a 0 (el promedio de la muestra), el nuevo cliente presenta un nivel de intensidad de compra **cercano al promedio** del grupo de clientes analizado: ni especialmente comprometido ni especialmente ocasional en su comportamiento de compra.