

Ayudantía 2

Test de Hipótesis y PCA

Cristóbal Van der Meer Miranda

Facultad de Ingeniería y Ciencias Aplicadas
Universidad de los Andes, Chile



Universidad de
los Andes

Tests de una Población

Test de Hipótesis (μ): Caso 1

Sea una **población normal** con confianza $1 - \alpha$ para la **media** μ , con σ conocida:

$$z_{\text{obt}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

alternative="less"	alternative="greater"	alternative="two.sided"
■ $H_0: \mu \geq \mu_0$ ■ $H_1: \mu < \mu_0$	■ $H_0: \mu \leq \mu_0$ ■ $H_1: \mu > \mu_0$	■ $H_0: \mu = \mu_0$ ■ $H_1: \mu \neq \mu_0$

Además, en **R** existe un **comando** que realiza el **test automáticamente**:

```
library(BSDA)

z.test(x = (X1, X2, ..., Xn),
       mu =  $\mu_0$ ,
       sigma.x =  $\sigma$ ,
       alternative = "signo  $H_1$ ",
       conf.level =  $1 - \alpha$ )
```

Ejercicio

- Una empresa afirma que sus baterías para drones duran en promedio 180 minutos, con $\sigma = 12$ minutos.

Un laboratorio toma una muestra y mide: 184, 179, 190, 175, 188, 183, 192, 177 minutos ¿Es la duración real distinta a la afirmada? Resuelva el test con $\alpha = 0,05$.

Definamos H_0 y H_1 :

- $H_0: \mu = 180$
- $H_1: \mu \neq 180$

Luego, escribimos código en R:

```
library(BSDA)
datos <- c(184, 179, 190, 175, 188, 183, 192, 177)

z.test(x = datos,
      mu = 180,
      sigma.x = 12,
      alternative = "two.sided",
      conf.level = 0.95)
```

(Ejecutamos)



```
One-sample z-Test

data:  datos
z = 0.82496, p-value = 0.4094
alternative hypothesis: true mean is not equal to 180
95 percent confidence interval:
 175.1846 191.8154
sample estimates:
mean of x
 183.5
```

Finalmente, como $p_{\text{value}} > 0,05 = \alpha$, por Regla de Oro no se rechaza H_0 , es decir, no existe evidencia suficiente para afirmar que la duración real es distinta a la afirmada (180 minutos).

Test de Hipótesis (μ): Caso 2

Sea una **población normal** con confianza $1 - \alpha$ para la **media** μ , con σ desconocida:

$$t_{\text{obt}}^{(\text{gl})} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

alternative="less"	alternative="greater"	alternative="two.sided"
■ $H_0: \mu \geq \mu_0$ ■ $H_1: \mu < \mu_0$	■ $H_0: \mu \leq \mu_0$ ■ $H_1: \mu > \mu_0$	■ $H_0: \mu = \mu_0$ ■ $H_1: \mu \neq \mu_0$

Además, en **R** existe un **comando** que realiza el **test automáticamente**:

```
t.test(x = (X1, X2, ..., Xn),  
       mu =  $\mu_0$ ,  
       alternative = "signo  $H_1$ ",  
       conf.level =  $1 - \alpha$ )
```

Ejercicio

■ Un fabricante de bombillas LED afirma que sus productos duran en promedio 10.000 horas.

Luego, toma una muestra y mide (en horas): 9800, 10200, 9950, 10100, 9700, 10050, 9900, 10150 ¿Hay evidencia de que la duración real es menor a la afirmada? Resuelva el test, mediante Región Crítica, con $\alpha = 0,1$.

Definamos H_0 y H_1 :

- $H_0: \mu \geq 10.000$
- $H_1: \mu < 10.000$

Luego, escribimos código en R:

```
datos <- c(9800, 10200, 9950, 10100,  
          9700, 10050, 9900, 10150)  
  
t.test(x = datos,  
       mu = 10000,  
       alternative = "less",  
       conf.level = 0.90)
```

(Ejecutamos)



```
One Sample t-test  
  
data:  datos  
t = -0.30283, df = 7, p-value = 0.3854  
alternative hypothesis: true mean is less than 10000  
90 percent confidence interval:  
 -Inf 10068.86  
sample estimates:  
mean of x  
 9981.25
```

Finalmente, como $t_{\text{obt}}^{(7)} = -0,303 > -1,4149 = t_{0,1}^{(7)}$, por Región Crítica no se rechaza H_0 , es decir, no existe evidencia suficiente para afirmar que la duración real es menor a la afirmada (10.000 horas).

Test de Hipótesis (p)

Sea una población normal con confianza $1 - \alpha$ para la **proporción** p , con $np_0 \geq 5$ y $n(1 - p_0) \geq 5$.

$$z_{\text{obt}} = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}}$$

alternative="less"	alternative="greater"	alternative="two.sided"
■ $H_0: p \geq p_0$ ■ $H_1: p < p_0$	■ $H_0: p \leq p_0$ ■ $H_1: p > p_0$	■ $H_0: p = p_0$ ■ $H_1: p \neq p_0$

Además, en **R** existe un **comando** que realiza el **test automáticamente**:

```
prop.test(x = (X1, X2, ..., Xn),  
          n = (Y1, Y2, ..., Ym),  
          p = p0,  
          alternative = "signo H1",  
          conf.level = 1 - α,  
          correct = FALSE)
```

Ejercicio

■ Una cadena de cines afirma que el 70% de sus espectadores compra bebidas al ver una película.

El gerente quiere verificar si la proporción de compra de bebidas es distinta al 70%. Para ello, revisa una muestra de 150 espectadores y encuentra que 96 compraron bebidas. Resuelva el test con $\alpha = 0,05$.

Definamos H_0 y H_1 :

- $H_0: p = 0,7$
- $H_1: p \neq 0,7$

Luego, escribimos código en R:

```
prop.test(x = 96,  
          n = 150,  
          p = 0.70,  
          alternative = "two.sided",  
          conf.level = 0.95,  
          correct = FALSE)
```

(Ejecutamos)



```
data: 96 out of 150, null probability 0.7  
X-squared = 2.5714, df = 1, p-value = 0.1088  
alternative hypothesis: true p is not equal to 0.7  
95 percent confidence interval:  
 0.5605742 0.7124342  
sample estimates:  
 p  
0.64
```

Finalmente, como $p_{\text{value}} > 0,05 = \alpha$, por Regla de Oro no se rechaza H_0 , es decir, no existe evidencia suficiente para afirmar que la proporción de compra de bebidas es distinta al 70%.

Test de Hipótesis (σ^2)

Sea una población normal con confianza $1 - \alpha$ para la **varianza** σ^2 :

$$\chi^2_{\text{obt}} = \frac{S^2(n - 1)}{\sigma^2}$$

alternative="less"	alternative="greater"	alternative="two.sided"
■ $H_0: \sigma^2 \geq \sigma_0^2$ ■ $H_1: \sigma^2 < \sigma_0^2$	■ $H_0: \sigma^2 \leq \sigma_0^2$ ■ $H_1: \sigma^2 > \sigma_0^2$	■ $H_0: \sigma^2 = \sigma_0^2$ ■ $H_1: \sigma^2 \neq \sigma_0^2$

Lamentablemente en R NO existe un comando que realice el test automáticamente, por lo que se debe realizar de **forma manual**.

Tests de dos Poblaciones

Test de Hipótesis (σ_1^2/σ_2^2)

Sean dos poblaciones normales con confianza $1 - \alpha$ para el **cociente de varianzas** σ_1^2/σ_2^2 :

$$F_{\text{obt}}^{(\text{gl}_1, \text{gl}_2)} = \frac{S_1^2}{\sigma_1^2} \cdot \frac{\sigma_2^2}{S_2^2}$$

alternative="less"	alternative="greater"	alternative="two.sided"
■ $H_0: \sigma_1^2/\sigma_2^2 \geq k_0$ ■ $H_1: \sigma_1^2/\sigma_2^2 < k_0$	■ $H_0: \sigma_1^2/\sigma_2^2 \leq k_0$ ■ $H_1: \sigma_1^2/\sigma_2^2 > k_0$	■ $H_0: \sigma_1^2/\sigma_2^2 = k_0$ ■ $H_1: \sigma_1^2/\sigma_2^2 \neq k_0$

Además, en **R** existe un **comando** que realiza el **test automáticamente**:

```
var.test(x = (X1, X2, ..., Xn),  
         y = (Y1, Y2, ..., Ym),  
         ratio = k0,  
         alternative = "signo H1",  
         conf.level = 1 - α)
```

Ejercicio

■ Dos máquinas empacadoras (A y B) llenan bolsas de arroz de 500 g. Un ingeniero de calidad sospecha que la varianza del peso de la máquina A es menos del doble de la varianza de la máquina B. Para verificarlo, toma una muestra de 5 bolsas de cada máquina y registra su peso (en gramos):

• Máquina A (502, 498, 501, 499, 500) y Máquina B (495, 510, 488, 515, 505). Determine el test con $\alpha = 0,05$.

Definamos H_0 y H_1 :

- $H_0: \sigma_A^2 / \sigma_B^2 \geq 2$
- $H_1: \sigma_A^2 / \sigma_B^2 < 2$

Luego, escribimos código en R:

```
maquina_A <- c(502, 498, 501, 499, 500)
maquina_B <- c(495, 510, 488, 515, 505)

var.test(x = maquina_A,
         y = maquina_B,
         ratio = 2,
         alternative = "less",
         conf.level = 0.95)
```

(Ejecutamos)



F test to compare two variances

```
data: maquina_A and maquina_B
F = 0.010305, num df = 4, denom df = 4, p-value = 0.00031
alternative hypothesis: true ratio of variances is less than 2
95 percent confidence interval:
 0.0000000 0.1316618
sample estimates:
ratio of variances
 0.02061006
```

Finalmente, como $p_{\text{value}} < 0,05 = \alpha$, por Regla de Oro se rechaza H_0 , es decir, existe evidencia suficiente para afirmar que la varianza del peso de la máquina A es menos del doble de la varianza de la máquina B.

Test de Hipótesis ($\mu_1 - \mu_2$): Caso 1

Sean dos poblaciones normales independientes con confianza $1 - \alpha$ para la **diferencia de medias** $\mu_1 - \mu_2$, con σ_1 y σ_2 conocidas:

$$z_{\text{obt}} = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

alternative="less"

■ $H_0: \mu_1 - \mu_2 \geq \mu_0$
■ $H_1: \mu_1 - \mu_2 < \mu_0$

alternative="greater"

■ $H_0: \mu_1 - \mu_2 \leq \mu_0$
■ $H_1: \mu_1 - \mu_2 > \mu_0$

alternative="two.sided"

■ $H_0: \mu_1 - \mu_2 = \mu_0$
■ $H_1: \mu_1 - \mu_2 \neq \mu_0$

Además, en **R** existe un **comando** que realiza el **test automáticamente**:

```
library(BSDA)

z.test(x = (X1, X2, ..., Xn),
       y = (Y1, Y2, ..., Ym),
       mu =  $\mu_0$ ,
       sigma.x =  $\sigma_1$ ,
       sigma.y =  $\sigma_2$ ,
       alternative = "signo  $H_1$ ",
       conf.level =  $1 - \alpha$ )
```

Ejercicio

■ Dos sucursales de un banco (A y B) desean comparar su tiempo promedio de espera. Se sabe que $\sigma_A = 4$ minutos y $\sigma_B = 5$ minutos. Se registran los tiempos de espera (en minutos): A (12, 15, 11, 14, 13, 16) y B (14, 17, 13, 16, 15) ¿Existe diferencia entre los tiempos promedio de espera? Determine el test con $\alpha = 0,1$.

Definamos H_0 y H_1 : $\begin{cases} \blacksquare H_0: \mu_A - \mu_B = 0 \\ \blacksquare H_1: \mu_A - \mu_B \neq 0 \end{cases}$

Luego, escribimos código en R:

```
sucursal_A <- c(12, 15, 11, 14, 13, 16)
sucursal_B <- c(14, 17, 13, 16, 15)
library(BSDA)

z.test(x = sucursal_A,
       y = sucursal_B,
       mu = 0,
       sigma.x = 4,
       sigma.y = 5,
       alternative = "two.sided",
       conf.level = 0.9)
```

(Ejecutamos)



Two-sample z-Test

```
data:  sucursal_A and sucursal_B
z = -0.54174, p-value = 0.588
alternative hypothesis: true difference in means is not equal to 0
90 percent confidence interval:
 -6.054393  3.054393
sample estimates:
mean of x mean of y
   13.5    15.0
```

Finalmente, como $p_{\text{value}} > 0,05 = \alpha$, por Regla de Oro no se rechaza H_0 , es decir, no existe evidencia suficiente para afirmar que existe diferencia entre los tiempos promedio de espera.

Test de Hipótesis ($\mu_1 - \mu_2$): Caso 2

Sean dos poblaciones normales independientes con confianza $1 - \alpha$ para la **diferencia de medias** $\mu_1 - \mu_2$, con σ_1 y σ_2 desconocidas e iguales:

$$t_{\text{obt}}^{(w)} = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{S_P^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

alternative="less"

■ $H_0: \mu_1 - \mu_2 \geq \mu_0$
■ $H_1: \mu_1 - \mu_2 < \mu_0$

alternative="greater"

■ $H_0: \mu_1 - \mu_2 \leq \mu_0$
■ $H_1: \mu_1 - \mu_2 > \mu_0$

alternative="two.sided"

■ $H_0: \mu_1 - \mu_2 = \mu_0$
■ $H_1: \mu_1 - \mu_2 \neq \mu_0$

Además, en **R** existe un **comando** que realiza el **test automáticamente**:

```
t.test(x = (X1, X2, ..., Xn),  
       y = (Y1, Y2, ..., Ym),  
       mu =  $\mu_0$ ,  
       alternative = "signo  $H_1$ ",  
       var.equal = TRUE,  
       conf.level =  $1 - \alpha$ )
```

Ejercicio

■ Un profesor quiere comparar el rendimiento en una prueba de dos metodologías de enseñanza (A y B). No se conocen las varianzas, pero se asume que son iguales entre ambos grupos. Luego, se registran las notas (escala 0-100): A (78, 85, 82, 90, 76, 88, 84) y B (70, 75, 72, 80, 68, 74) ¿Es posible que el grupo A supere al grupo B por al menos 5 puntos en promedio? Determine el test con $\alpha = 0,05$.

Definamos H_0 y H_1 :
■ $H_0: \mu_A - \mu_B \geq 5$
■ $H_1: \mu_A - \mu_B < 5$

Luego, escribimos código en R:

```
grupo_A <- c(78, 85, 82, 90, 76, 88, 84)
grupo_B <- c(70, 75, 72, 80, 68, 74)
```

```
t.test(x = grupo_A,
      y = grupo_B,
      mu = 5,
      alternative = "less",
      var.equal = TRUE,
      conf.level = 0.95)
```

(Ejecutamos)



Two Sample t-test

```
data: grupo_A and grupo_B
t = 1.9606, df = 11, p-value = 0.9621
alternative hypothesis: true difference in means is less than 5
95 percent confidence interval:
 -Inf 14.80796
sample estimates:
mean of x mean of y
 83.28571  73.16667
```

Finalmente, como $p_{\text{value}} > 0,05 = \alpha$, por Regla de Oro no se rechaza H_0 , es decir, no existe evidencia suficiente para afirmar que el grupo A supera al grupo B por al menos 5 puntos en promedio.

Test de Hipótesis ($\mu_1 - \mu_2$): Caso 3

Sean dos poblaciones normales independientes con confianza $1 - \alpha$ para la **diferencia de medias** $\mu_1 - \mu_2$, con σ_1 y σ_2 desconocidas y distintas:

$$t_{\text{obt}}^{(v)} = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

alternative="less"	alternative="greater"	alternative="two.sided"
■ $H_0: \mu_1 - \mu_2 \geq \mu_0$ ■ $H_1: \mu_1 - \mu_2 < \mu_0$	■ $H_0: \mu_1 - \mu_2 \leq \mu_0$ ■ $H_1: \mu_1 - \mu_2 > \mu_0$	■ $H_0: \mu_1 - \mu_2 = \mu_0$ ■ $H_1: \mu_1 - \mu_2 \neq \mu_0$

Además, en **R** existe un **comando** que realiza el **test automáticamente**:

```
t.test(x = (X1, X2, ..., Xn),  
       y = (Y1, Y2, ..., Ym),  
       mu =  $\mu_0$ ,  
       alternative = "signo  $H_1$ ",  
       var.equal = FALSE,  
       conf.level =  $1 - \alpha$ )
```

Ejercicio

■ Dos proveedores de transporte (X e Y), con varianzas desconocidas y distintas, registran sus tiempos de entrega (horas): Proveedor X (28, 32, 25, 35, 30, 29, 33) y Proveedor Y (20, 22, 18, 25, 21).

¿Hay evidencia de que X demora en promedio más de 3 horas que Y ? Determine el test con $\alpha = 0,05$.

Definamos H_0 y H_1 :
■ $H_0: \mu_X - \mu_Y \leq 3$
■ $H_1: \mu_X - \mu_Y > 3$

Luego, escribimos código en R:

```
proveedor_X <- c(28, 32, 25, 35, 30, 29, 33)
proveedor_Y <- c(20, 22, 18, 25, 21)
```

```
t.test(x = proveedor_X,
      y = proveedor_Y,
      mu = 3,
      alternative = "greater",
      var.equal = FALSE,
      conf.level = 0.95)
```

(Ejecutamos)



Welch Two Sample t-test

```
data: proveedor_X and proveedor_Y
t = 3.546, df = 9.8758, p-value = 0.002704
alternative hypothesis: true difference in means is greater than 3
95 percent confidence interval:
 5.971141      Inf
sample estimates:
mean of x mean of y
30.28571  21.20000
```

Finalmente, como $p_{\text{value}} < 0,05 = \alpha$, por Regla de Oro se rechaza H_0 , es decir, existe evidencia suficiente para afirmar que el proveedor X demora en promedio más de 3 horas que el Y .

Test de Hipótesis ($\mu_1 - \mu_2$): Caso 4

Sean dos poblaciones normales dependientes con confianza $1 - \alpha$ para la **diferencia de medias** $\mu_1 - \mu_2$:

$$t_{obt}^{(gl)} = \frac{\bar{D} - \mu_D}{\frac{S_D}{\sqrt{n}}}$$

alternative="less"

$$\begin{array}{l} \blacksquare H_0: \mu \geq \mu_0 \\ \blacksquare H_1: \mu < \mu_0 \end{array}$$

alternative="greater"

$$\begin{array}{l} \blacksquare H_0: \mu \leq \mu_0 \\ \blacksquare H_1: \mu > \mu_0 \end{array}$$

alternative="two.sided"

$$\begin{array}{l} \blacksquare H_0: \mu = \mu_0 \\ \blacksquare H_1: \mu \neq \mu_0 \end{array}$$

Además, en **R** existe un **comando** que realiza el **test automáticamente**:

```
t.test(x = (X1, X2, ..., Xn),  
       y = (Y1, Y2, ..., Ym),  
       mu =  $\mu_0$ ,  
       alternative = "signo  $H_1$ ",  
       paired = TRUE,  
       conf.level =  $1 - \alpha$ )
```

Ejercicio

■ Un gimnasio quiere evaluar si un nuevo programa de entrenamiento reduce el peso de sus socios. Se pesa a 7 personas antes y después de 8 semanas del programa, obteniendo:

Antes	82	90	75	88	95	78	85
Después	79	86	74	84	90	76	83

¿Hay evidencia de que el peso promedio disminuyó? Determine el test con $\alpha = 0,05$.

Definamos H_0 y H_1 :
■ $H_0: \mu_D \leq 0$
■ $H_1: \mu_D > 0$ (Definiendo $D = \text{Antes} - \text{Después}$)

```
antes <- c(82, 90, 75, 88, 95, 78, 85)
despues <- c(79, 86, 74, 84, 90, 76, 83)
```

```
t.test(x = antes,
      y = despues,
      mu = 0,
      alternative = "greater",
      paired = TRUE,
      conf.level = 0.95)
```

(Ejecutamos)

Paired t-test

```
data: antes and despues
t = 5.6125, df = 6, p-value = 0.0006826
alternative hypothesis: true mean difference is greater than 0
95 percent confidence interval:
 1.961326      Inf
sample estimates:
mean difference
              3
```

Finalmente, como $p_{\text{value}} < 0,05 = \alpha$, por Regla de Oro se rechaza H_0 , es decir, existe evidencia suficiente para afirmar que el peso promedio de los socios disminuyó tras el programa de entrenamiento.

Inferencia sobre Vector de Medias

Test de Mardia

Sea $x_1, \dots, x_n$ una muestra aleatoria de una distribución p -variada, con $\bar{x}$ el vector de medias muestral y S la matriz de covarianzas muestral. Se decide contrastar:

$$\begin{array}{l} \blacksquare H_0: x_1, \dots, x_n \sim N_p(\mu, \Sigma) \\ \blacksquare H_1: x_1, \dots, x_n \not\sim N_p(\mu, \Sigma) \end{array}$$

Este test evalúa **dos propiedades** de datos a la vez: **asimetría** y **curtosis multivariadas**.

Asimetría	Curtosis
$b_{1,p} = \frac{1}{n^2} \sum_{i,j} [(x_i - \bar{x})' S^{-1} (x_j - \bar{x})]^3$	$b_{2,p} = \frac{1}{n^2} \sum_{i,j} [(x_i - \bar{x})' S^{-1} (x_j - \bar{x})]^2$

Además, en **R** existe un **comando** que realiza el **test automáticamente**:


```
library(MVN)
mardia(datos)
```

¿Realizar varias Pruebas t ?

Supongamos que se **miden** varias **variables** a la vez en cada individuo y se quiere contrastar si el **vector de medias** $\mu = (\mu_1, \mu_2, \dots, \mu_p)$ es igual a un **vector de referencia** $\mu_0 = (\mu_{01}, \mu_{02}, \dots, \mu_{0p})$.

Uno podría tener la **tentación** de hacer **p tests** (una por cada variable), sin embargo, esta **idea** es **errónea** debido a los siguientes detalles:

#	Desventajas de múltiples tests t
1	No controlan el error global.
2	Ignoran la correlación entre las variables.



Test de Hotelling

Sea $x_1, \dots, x_n$ una muestra aleatoria de una población normal multivariada, donde $x_i \sim \mathcal{N}_p(\mu, S)$, con $\mu \in \mathbb{R}^p$ y S desconocidos, el **Test de Hotelling** se plantea sobre las siguientes **hipótesis**:

■ $H_0: \mu = \mu_0$

■ $H_1: \mu \neq \mu_0$

Además, su **estadístico de prueba** está dado por:

$$T^2 = n(\bar{x} - \mu_0)' S^{-1} (\bar{x} - \mu_0)$$



$$F_{obt}^{(p, n-p)} = \frac{(n - p) T^2}{(n - 1) p}$$

Finalmente, sus **reglas de decisión** están dados por:

Región Crítica	p value
$T^2 > \frac{(n - 1)p}{(n - p)} F_{\alpha}^{(p, n-p)}$	$\mathbb{P} \left(F^{(p, n-p)} > \frac{(n - p) T_2}{(n - 1) p} \right)$

```
library(ICSNP)
datos <- data.frame(x1 = x1,
                    x2 = x2)

mu0 <- mu0
HotellingsT2(datos, mu = mu0)
```

Intervalos de Confianza Simultáneos

Sea $x_1, \dots, x_n$ una muestra aleatoria de una población normal multivariada, donde $x_i \sim \mathcal{N}_p(\mu, \Sigma)$, con $\mu \in \mathbb{R}^p$ y Σ desconocidos, se consideran los siguientes **intervalos simultáneos**:

Intervalos Simultáneos de Roy	Intervalos Simultáneos de Bonferroni
Cualquier combinación lineal $a'\mu$.	Solo para las p variables originales.
$IC_{1-\alpha}(a'\mu) = \left[a'\bar{x} \pm \sqrt{\frac{p(n-1)}{n-p} F_{\alpha}^{(p, n-p)}} \cdot \sqrt{\frac{a'Sa}{n}} \right]$	$IC_{1-\alpha}(\mu_k) = \left[\bar{x}_k \pm t_{\alpha/2m}^{(n-1)} \sqrt{\frac{S_{kk}}{n}} \right], \quad k \in \{1, \dots, m\}$

Ejercicio

■ Un gerente de call center afirma que, en promedio, sus agentes logran una satisfacción de 8 (escala 1-10) y un tiempo de espera de 3 minutos. Se registran estas dos variables en 6 llamadas para verificar la afirmación:

Satisfacción	7,8	8,1	7,5	8,3	7,9	8,0
Espera [min]	4,2	3,8	4,5	3,6	4,0	3,9

- (a) Verifique el supuesto de normalidad multivariada.
- (b) Realice el test correspondiente.
- (c) Identifique con Bonferroni que variable causa el rechazo.

(a) Definamos H_0 y H_1 :

- $H_0: x_1, \dots, x_n \sim N_p(\mu, \Sigma)$
- $H_1: x_1, \dots, x_n \not\sim N_p(\mu, \Sigma)$

```
library(MVN)
datos <- data.frame(satisfaccion = c(7.8, 8.1, 7.5, 8.3, 7.9, 8.0),
                    espera = c(4.2, 3.8, 4.5, 3.6, 4.0, 3.9))

mardia(datos)
```

```
> mardia(datos)
      Test  Statistic  p.value  Method
1 Mardia Skewness  1.2225045 0.8743797 asymptotic
2 Mardia Kurtosis -0.8964313 0.3700225 asymptotic
```

- ✓ Asimetría: No se rechaza H_0 , ya que $p_{value} > 0,05$.
- ✓ Curtosis: No se rechaza H_0 , ya que $p_{value} > 0,05$.

Ejercicio

■ Un gerente de call center afirma que, en promedio, sus agentes logran una satisfacción de 8 (escala 1-10) y un tiempo de espera de 3 minutos. Se registran estas dos variables en 6 llamadas para verificar la afirmación:

Satisfacción	7,8	8,1	7,5	8,3	7,9	8,0
Espera [min]	4,2	3,8	4,5	3,6	4,0	3,9

- (a) Verifique el supuesto de normalidad multivariada.
(b) Realice el test correspondiente.
(c) Identifique con Bonferroni que variable causa el rechazo.

(b) Definamos H_0 y H_1 :

$$\begin{aligned} \blacksquare H_0: \mu &= (8,3) \\ \blacksquare H_1: \mu &\neq (8,3) \end{aligned}$$

Hotelling's one sample T2-test

```
data:  datos
T.2 = 2161.5, df1 = 2, df2 = 4, p-value = 8.546e-07
alternative hypothesis: true location is not equal to c(8,3)
```

```
library(ICSNP)
datos <- data.frame(satisfaccion = c(7.8, 8.1, 7.5, 8.3, 7.9, 8.0),
                  espera = c(4.2, 3.8, 4.5, 3.6, 4.0, 3.9))

mu0 <- c(8.0, 3.0)
HotellingsT2(datos, mu = mu0)
```

Como $p_{\text{value}} < 0,05$, se **rechaza** H_0 .

Es decir, existe evidencia suficiente para afirmar que **al menos una** de las **dos cifras** que afirma el gerente **no se cumple en la realidad**.

Ejercicio

■ Un gerente de call center afirma que, en promedio, sus agentes logran una satisfacción de 8 (escala 1-10) y un tiempo de espera de 3 minutos. Se registran estas dos variables en 6 llamadas para verificar la afirmación:

Satisfacción	7,8	8,1	7,5	8,3	7,9	8,0
Espera [min]	4,2	3,8	4,5	3,6	4,0	3,9

- (a) Verifique el supuesto de normalidad multivariada.
- (b) Realice el test correspondiente.
- (c) Identifique con Bonferroni que variable causa el rechazo.

(c) Realicemos el código en R:

```
n <- nrow(datos); p <- ncol(datos); m <- p
xbar <- colMeans(datos); S <- cov(datos)
alpha <- 0.05
tcrit_bonf <- qt(1 - alpha / (2 * m), df = n - 1)
margen_bonf <- tcrit_bonf * sqrt(diag(S) / n)

bonferroni <- cbind(inferior = xbar - margen_bonf,
                    superior = xbar + margen_bonf,
                    mu0 = mu0)

print(bonferroni)
```



	inferior	superior	mu0
satisfaccion	7.580443	8.286223	8
espera	3.591609	4.408391	3


El tiempo de espera es responsable del rechazo.

Esto es debido a que el intervalo para espera, $[3.592, 4.408]$ no contiene el valor 3 que afirma el gerente acorde a **Bonferroni**.

Análisis de Componentes Principales

Introducción al Contexto

Como introducción, supongamos que disponemos de información sobre individuos medida a través de múltiples variables:



En este caso, es evidente que las variables tienen información redundante, ya que corresponden a mismas magnitudes expresadas en distintas unidades.

Problema Real

Pero supongamos que el escenario no es tan sencillo de identificar que variables están relacionadas con otra, como por ejemplo, un investigador está estudiando el rendimiento de estudiantes universitarios. Para cada alumno se registran las siguientes variables:

Nota Matemáticas	Nota Lenguaje	Nota Química	Nota Física	Nota Biología	Nota Historia	Nota Arte	Nota Música
------------------	---------------	--------------	-------------	---------------	---------------	-----------	-------------


En este caso, es razonable suponer que **algunas variables** están **correlacionadas entre sí**, ya que podrían reflejar habilidades subyacentes comunes. Sin embargo, estas relaciones **no son explícitas ni triviales de identificar**.

Necesitamos de una **herramienta** que permita **detectar** estructuras ocultas en los datos, **reducir** la dimensionalidad y **conservar** la mayor cantidad posible de información...



Análisis de Componentes Principales

El **Análisis de Componentes Principales (PCA)** es una técnica estadística de reducción de dimensionalidad que transforma un conjunto de variables posiblemente correlacionadas en un nuevo conjunto de variables no correlacionadas, llamadas **componentes principales**.



Además, esta metodología consiste en **reducir la dimensionalidad** de los datos preservando la **mayor cantidad posible de variabilidad**, permitiendo **simplificación** del análisis de datos complejos, **eliminar** redundancia entre variables y **facilitar** la visualización del modelamiento.

Componente Principal

Un **componente principal** es una nueva variable que se construye como una **combinación lineal** de las **variables originales**:

$$PC_k = v_{1k}X_1 + v_{2k}X_2 + \dots + v_{pk}X_p$$

Donde los coeficientes $v_{\blacksquare k}$ determinan cuanto aporta cada variable. Además, un **componente principal** es una dirección en el espacio de los datos sobre la cual los **datos varían lo máximo posible**.

Además, los **componentes principales** se comportan de la siguiente forma:

- PC_1 : Es la combinación que captura la mayor variabilidad total.
- PC_2 : Captura la mayor variabilidad restante y es ortogonal (independiente) a PC_1 .
- Y así sucesivamente...



Metodología del PCA

Paso 1: Centralización de Variables

Sea $X \in \mathbb{R}^{n \times p}$ una matriz de datos, con n observaciones y p variables, el primer paso en PCA consiste en centrar cada variable, es decir, restar su media. De esta manera, la **matriz centrada** se define como:

$$\tilde{X} = X - \vec{1} \cdot \bar{x}^T$$

A partir de lo anterior, cada variable queda con **media cero**, es decir, los datos quedan re-expresados como **desviaciones respecto a su media**.




Paso 2: Construcción de Matriz Covarianza

Sea $\tilde{X} \in \mathbb{R}^{n \times p}$ la matriz de datos centrados, la **matriz de covarianza** se define como:

$$S = \frac{1}{n-1} \tilde{X}^T \tilde{X} = \begin{bmatrix} \mathbb{V}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_1, X_2) & \mathbb{V}(X_2) & \cdots & \text{Cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_1, X_p) & \text{Cov}(X_2, X_p) & \cdots & \mathbb{V}(X_p) \end{bmatrix}$$

Además, la matriz presenta las siguientes **propiedades**:

- 1 Es **simétrica** ($S = S^T$).
- 2 Es **semidefinida positiva** (autovalores no-negativos).
- 3 Sus **autovectores** son **ortogonales** entre sí.



Paso 3: Obtención de Autovalores y Autovectores

Una vez construida la matriz de covarianza $S \in \mathbb{R}^{p \times p}$, el objetivo es encontrar las direcciones de máxima variabilidad. Para esto, se debe resolver el siguiente problema:

$$S\vec{v} = \lambda\vec{v} \quad \rightarrow \quad \det(S - \lambda I_p) = 0$$

Donde:

- $\vec{v}$ (**autovector**): Dirección en el espacio de las variables donde se proyectan los datos.
- λ (**autovalor**): Varianza de los datos en dicha dirección.

De esta manera, **cada par** $(\lambda_k, \vec{v}_k)$, con $\|\vec{v}_k\| = 1$, define un **componente principal**.


Además, los autovalores se ordenan de **mayor a menor** ($\lambda_1 \geq \dots \geq \lambda_p \geq 0$), siendo $\vec{v}_1$ la dirección de **máxima varianza (PC1)**, $\vec{v}_2$ segunda dirección de mayor varianza (ortogonal a $\vec{v}_1$), y así sucesivamente...



Paso 4: Selección del Número de Componentes



Sea $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ la **secuencia de autovalores** de la matriz S , se selecciona un entero $k \leq p$ tal que **los primeros k componentes principales** conserven la **mayor parte de la variabilidad** total de los datos. Para ello, se cuenta con:

Criterio de Varianza Explicada	Criterio del Codo (Scree Test de Cattell)	Criterio de Kaiser
La proporción de la varianza explicada acumulada es: $PVE(k) = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^p \lambda_i}$ Se selecciona el menor k tal que: $PVE(k) \geq \alpha$ Donde $\alpha \in (0,1)$, suele ser $0,8 - 0,95$.	Se selecciona un entero k tal que: $\lambda_k - \lambda_{k+1} \gg \lambda_{k+1} - \lambda_{k+2}$ 	Se selecciona el número de componentes k tal que: $\lambda_j > 1, \quad j \in \{1, \dots, k\}$ Sin embargo, este criterio es solo válido cuando se utiliza la matriz de correlación.

Paso 5: Proyección de los Datos

Sea $X \in \mathbb{R}^{n \times p}$ la matriz de datos centrados y $V_m = [\vec{v}_1, \vec{v}_2, \dots, \vec{v}_m] \in \mathbb{R}^{p \times m}$ la matriz formada por los m autovectores asociados a los mayores autovalores de la matriz de covarianza. Entonces, la **proyección de los datos** al subespacio generado por los m PCA's está dada por:

$$Z = \tilde{X} \cdot V_m$$

A partir de lo anterior, se tienen las **siguientes notaciones**:

- Cada **fila** de Z es una **observación** en el nuevo sistema de coordenadas.
- Cada **columna** de Z es un **componente principal**.

Además, para cada **observación** $i \in \{1, \dots, n\}$ y **componente** $\ell \in \{1, \dots, m\}$, su **score** ($z_{i\ell}$) es:

$$z_{i\ell} = \sum_{j=1}^p \tilde{x}_{ij} v_{j\ell}$$