

Ayudantía 4 Métodos Estadísticos:

Profesores: Carmen Gloria Carrasco | Héctor López.

Ayudantes: José Ignacio Costa | Cristóbal Van Der Meer

27 de agosto de 2026

1. Responda Verdadero o Falso según corresponda:

- a) El análisis de componentes principales transforma un conjunto de variables posiblemente correlacionadas en un nuevo conjunto de variables no correlacionadas llamadas “componentes principales”.

R: Verdadero. El objetivo central del PCA es encontrar nuevas variables (componentes principales) que sean combinaciones lineales de las variables originales, pero que estén no correlacionadas entre sí. Esto se logra diagonalizando la matriz de covarianza (o correlación) de los datos, de modo que cada componente capture una parte independiente de la variabilidad.

- b) Los componentes principales se obtienen como combinaciones lineales de las variables originales.

R: Verdadero. Cada componente puede escribirse como:

$$Z_k = a_{1k}X_1 + a_{2k}X_2 + \dots + a_{pk}X_p$$

Donde los coeficientes a_{ik} provienen de los vectores propios de la matriz de covarianza o correlación. Estos coeficientes determinan la dirección del espacio de variables donde se proyectan los datos.

- c) El primer componente principal es la combinación lineal que minimiza la varianza de los datos proyectados.

R: Falso. El primer componente principal es la dirección que maximiza la varianza de los datos proyectados. Es decir, busca la dirección en el espacio de variables donde los datos presentan la mayor dispersión posible. Esta propiedad hace que el primer componente capture la mayor cantidad de información contenida en los datos.

- d) En PCA, cada componente principal es ortogonal a los demás componentes.

R: Verdadero. Los componentes principales corresponden a los vectores propios ortogonales de la matriz de covarianza o correlación. Como consecuencia, los componentes resultantes son linealmente independiente y no correlacionados, lo que permite separar la variabilidad de los datos en direcciones independientes.

- e) El número máximo de componentes principales es igual al número de variables originales.

R: Verdadero. Si el conjunto de datos tiene p variables, entonces se pueden obtener hasta p componentes principales. Sin embargo, en la práctica suele utilizarse solo un subconjunto (2 o 3) que explique una proporción alta de la varianza total.

- f) Si las variables originales están medidas en escalas muy distintas, es recomendable aplicar PCA usando la matriz de correlaciones en lugar de la matriz de covarianzas.

R: Verdadero. Cuando las variables tienen unidades o escalas muy diferentes, aquellas con mayor varianza pueden dominar el análisis. Usar la matriz de correlación equivale a estandarizar las variables ($\mu = 0, \sigma^2 = 1$), evitando que una variable domine el resultado solo por su escala.

- g) La suma de las varianzas explicadas por todos los componentes principales es igual a la suma de las varianzas de las variables originales.

R: Verdadero. En PCA se cumple que la suma de los valores propios de la matriz de covarianza es igual a la varianza total del sistema. Como cada valor propio corresponde a la varianza explicada por un componente principal, la suma de las varianzas de todos los componentes reproduce exactamente la varianza total original.

h) El PCA es un método supervisado porque utiliza información de una variable objetivo para construir los componentes.

R: Falso. El PCA es un método no supervisado, ya que solo utiliza las variables explicativas para analizar su estructura de variabilidad. No utiliza ninguna variable objetivo o etiqueta de clase, a diferencia de métodos supervisados como regresión o clasificación.

i) Los componentes principales se obtienen a partir de los vectores propios de la matriz de covarianza o correlación de los datos.

R: Verdadero. Matemáticamente, el PCA se obtiene resolviendo el problema de valores y vectores propios de la matriz de covarianza o correlación.

- Los vectores propios determinan las direcciones de los componentes principales.
- Los valores propios indican cuánta varianza explica cada componente.

j) Reducir la dimensionalidad mediante PCA implica necesariamente perder toda la información contenida en los datos originales.

R: Falso. La reducción de dimensionalidad mediante PCA solo descarta una parte de la variabilidad asociada a los componentes menos importantes. Si se seleccionan suficientes componentes para explicar un alto porcentaje de la varianza (por ejemplo, 90-95%), se puede conservar la mayor parte de la información relevante de los datos.

k) Se dispone de las clasificaciones de 50 estudiantes en seis asignaturas. Si las notas de Matemáticas y Física no presentan correlación entre sí, entonces no tiene sentido aplicar un Análisis de Componentes Principales al conjunto de datos.

R: Falso. El análisis de PCA busca identificar estructuras de correlación entre todas las variables, no solo entre un par de ellas. El hecho de que Matemáticas y Física no estén correlacionadas entre sí no implica que las demás asignaturas tampoco lo estén.

- Por ejemplo, podría ocurrir que:
- Matemática está correlacionada con Álgebra o Estadística.
- Física esté correlacionada con Química.
- varias asignaturas estén relacionadas con una dimensión común como habilidad cuantitativa o habilidad verbal.

El ACP analiza la matriz de correlación entre las 6 asignaturas. Incluso, si un par de variables no está correlacionado, el método puede encontrar componentes principales que expliquen patrones globales de variación entre todas las variables.

En cambio, el ACP sería poco útil si todas las variables fueran aproximadamente no correlacionadas entre sí, ya que, en ese caso, cada variable aportaría información independiente y no habría una estructura de correlación que resumir mediante componentes.

l) Si el test de esfericidad de Bartlett no resulta significativo, entonces no se debe aplicar el Análisis de Componentes Principales.

R: Verdadero (en general). El test de Bartlett evalúa la hipótesis nula de que la matriz de correlaciones es igual a la matriz identidad, esto significa que las variables no están correlacionadas entre sí.

- Si el test es significativo ($p < 0.05$): se rechaza la hipótesis nula y se concluye que existen correlaciones entre las variables. En este caso sí tiene sentido aplicar ACP, porque el método busca justamente explotar esa estructura de correlación.
- Si el test no es significativo: no hay evidencia de correlación entre las variables. En ese escenario el ACP suele ser poco útil, porque cada variable aporta información independiente y no existe una estructura que pueda resumirse en un número menor de componentes.

m) Es preferible realizar un Análisis de Componentes Principales utilizando la matriz de correlaciones, ya que, en este caso, todos los valores propios serán mayores que 1.

R: Falso. Cuando el ACP se realiza utilizando la matriz de correlaciones, cada variable está estandarizada y tiene varianza igual a 1. Como consecuencia, la suma de los valores propios es igual al número de variables p .

Sin embargo, esto no implica que todos los valores propios sean mayores que 1. De hecho, normalmente ocurre lo contrario:

- Algunos valores son mayores que 1, indicando componentes que explican aún más varianza que una variable original promedio.
- Otros son menores que 1, indicando componentes que explican menos varianza.

Esto se relaciona con el Criterio de Kaiser, que sugiere retener los componentes con valores propios mayores que 1, pero no afirma que todos los valores propios cumplan con esa condición.

Conclusión: Usar la matriz de correlaciones no garantiza que todos los valores propios serán mayores que 1, por lo que la afirmación es falsa.

2. A continuación, encuentran el código en R para hacer un ACP en un dataframe de rendimiento académico de 50 alumnos en 6 asignaturas. En la pauta, encontrarán el desarrollo y explicación de cada parte de un ACP.
3. Usando los mismos datos del problema anterior, hacer un análisis factorial básico. En la pauta se encuentran todas las indicaciones necesarias.
4. Se hizo una encuesta sobre restaurantes en la que se le pidió a una muestra de personas que evaluaran un restaurant en una escala de 1 a 5 donde 1 es "Totalmente en desacuerdo" y 5 "Totalmente de acuerdo". Nosotros nos concentraremos en las preguntas 12 a 21:

12: Los empleados son amigables

13: Es un lugar entretenido para comer

14: Las porciones son grandes

15: La comida es fresca

16: Los precios son razonables

17: El interior es atractivo

18: Excelente sabor de la comida

19: Los empleados tienen conocimiento

20: La temperatura de la comida es apropiada

21: El servicio es rápido

Con los datos adjuntos, haga un análisis factorial de estas respuestas e interprete cada uno de los factores.

5. Un investigador quiere evaluar si un programa de entrenamiento mejora el tiempo promedio (en segundos) que tardan 8 atletas en completar un circuito en más de 2 segundos (usar un $\alpha = 0.05$). Se mide el tiempo antes y después del entrenamiento:

Antes: 52, 47, 50, 46, 49, 53, 48, 51

Después: 49, 46, 48, 44, 47, 50, 46, 48