



Profesores: Carmen Carrasco | Héctor López

Ayudantes: José Ignacio Costa | Cristóbal Van der Meer

Pauta Ayudantía 4

P1- En una empresa que fabrica ampolletas LED, se afirma que la vida útil promedio de sus productos es de 15000 horas, con una desviación estándar de 800 horas. Si se toma una muestra aleatoria de 64 ampolletas y se considera una significancia del 5 %, responda:

- (a) Si la vida útil promedio observada en la muestra es de 14700 horas ¿Es razonable aceptar la afirmación de la empresa sobre la media poblacional? Responda la pregunta aplicando una prueba de hipótesis usando el valor-p y justifique su decisión.
- (b) ¿Qué valores de la media muestral determinan que no se cumpla con la afirmación?
- (c) ¿Cuál es la probabilidad de rechazar la afirmación que dice que la vida útil promedio de las ampolletas es igual a 15000 horas, si en realidad la media es 14900 horas?

Hint: Quizás le sirva alguno(s) de estos comandos:

Comando R	pnorm(0.48)	pnorm(0.96)	pnorm(1.96)	pnorm(2.96)	pnorm(3)
Output R	0,6844	0,8315	0,9750	0,9985	0,9987

Solución:

(a) Definamos H_0 y H_1 :

$$\begin{array}{l} \blacksquare H_0 : \mu = 15000 \\ \blacksquare H_1 : \mu \neq 15000 \end{array} \quad \left| \right.$$

Luego, determinamos el pivote obtenido:

$$\blacksquare z_{\text{obt}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{14700 - 15000}{\frac{800}{\sqrt{64}}} = -3,00$$

Posteriormente, determinamos el p-value:

$$\begin{aligned} \blacksquare p_{\text{value}} &= 2 \cdot \mathbb{P}(z > |z_{\text{obt}}|) = 2 \cdot \mathbb{P}(z > 3,00) = 2 \cdot [1 - \mathbb{P}(z \leq 3,00)] \\ &\implies 2 \cdot (1 - 0,9987) \implies p_{\text{value}} = 0,0026 \end{aligned}$$

Finalmente, puesto que $p_{\text{value}} < 0,05 = \alpha$, se concluye que se rechaza H_0 . Es decir, existe evidencia suficiente para decir que la vida útil promedio difiere de 15000 horas, por lo tanto, no es razonable aceptar la afirmación de la empresa.

(b) Determinamos los valores de la media muestral que permiten que no se cumpla con la afirmación:

$$z_{0,025} \geq z_{\text{obt}} \implies -1,96 \geq \frac{\bar{X} - 15000}{\frac{800}{\sqrt{64}}} \implies 15000 - 1,96 \frac{800}{\sqrt{64}} \geq \bar{X} \implies 14804 \geq \bar{X}$$

$$z_{0,975} \leq z_{\text{obt}} \implies 1,96 \leq \frac{\bar{X} - 15000}{\frac{800}{\sqrt{64}}} \implies 15000 + 1,96 \frac{800}{\sqrt{64}} \leq \bar{X} \implies 15196 \leq \bar{X}$$

Finalmente, los valores de la media muestral solicitados corresponden a $(\bar{X} \leq 14804 \cup \bar{X} \geq 15196)$.

(c) Determinamos la probabilidad solicitada:

$$\begin{aligned} \mathbb{P}(\text{Potencia}) &= \mathbb{P}(\text{Rechazo } H_0 \mid H_1 \text{ Verdadera}) \\ &= \mathbb{P}(\bar{X} \leq 14804 \cup \bar{X} \geq 15196) \\ &= \mathbb{P}(\bar{X} \leq 14804) + [1 - \mathbb{P}(\bar{X} < 15196)] \\ &= \mathbb{P}\left(\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq \frac{14804 - 14900}{\frac{800}{\sqrt{64}}}\right) + 1 - \mathbb{P}\left(\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} < \frac{15196 - 14900}{\frac{800}{\sqrt{64}}}\right) \\ &= \mathbb{P}(z \leq -0,96) + 1 - \mathbb{P}(z < 2,96) \\ &= 0,1685 + 1 - 0,9985 \\ &= 0,1700 \end{aligned}$$

P2- El área de control de calidad de una fábrica de pinturas sospecha que la variabilidad en el contenido de una lata de pintura de 4 litros ha aumentado por sobre 0.05 litros², aunque los registros históricos sugieren que esto no debiese ser así. Para resolver esta controversia, se extrae una muestra de 25 latas, considerando un nivel de significancia del 1 %.

- Si a partir de la muestra se obtiene una varianza de 0.081 litros² ¿Es posible afirmar lo que sospecha el área de control de calidad? Responda esta pregunta a través de una prueba de hipótesis usando región crítica.
- Suponiendo que la sospecha del área de control de calidad es efectivamente falsa (es decir, $\sigma^2 = 0,05$ litros²) ¿Cuál es la probabilidad de cometer un error tipo I?
- Suponiendo ahora que la sospecha es efectivamente verdadera y que la varianza es de $\sigma^2 = 0,10$ litros² ¿Cuál es la probabilidad de cometer un error tipo II en este contexto?

Hint: Quizás le sirva alguno(s) de estos comandos:

Comando R	qchisq(0.01,24)	qchisq(0.99,24)	pchisq(13.02,24)	pchisq(21.49,24)
Output R	10,856	42,980	0,0344	0,3721

Solución:

(a) Definamos H_0 y H_1 :

$$\begin{array}{l} \blacksquare H_0 : \sigma^2 \leq 0,05 \\ \blacksquare H_1 : \sigma^2 > 0,05 \end{array} \quad \left| \right.$$

Luego, determinamos el pivote obtenido:

$$\blacksquare \chi_{\text{obt}}^{2(24)} = \frac{S^2(n-1)}{\sigma^2} = \frac{0,081 \cdot 24}{0,05} = 38,88$$

Según Región Crítica, puesto que $\chi_{0,99}^{2(24)} = 42,980 > \chi_{\text{obt}}^{2(24)} = 38,88$, no se rechaza H_0 , es decir, no hay evidencia suficiente para afirmar lo que sospecha el área de control de calidad.

(b) El error tipo I corresponde a rechazar H_0 cuando en realidad es verdadera:

$$\mathbb{P}(\text{Error tipo I}) = \mathbb{P}(\text{Rechazar } H_0 \mid H_0 \text{ Verdadera}) = \alpha = 0,01$$

(c) El error tipo II corresponde a no rechazar H_0 cuando en realidad es falsa, es decir, cuando la verdadera varianza es $\sigma^2 = 0,10$. Determinemos el valor crítico de S^2 que define la región H_0 :

$$\chi_{\text{obt}}^{2(24)} \leq \chi_{0,99}^{2(24)} \implies \frac{S^2 \cdot 24}{0,05} \leq 42,980 \implies S^2 \leq \frac{42,980 \cdot 0,05}{24} \implies S^2 \leq 0,08954$$

Luego, calculamos la probabilidad de no rechazar H_0 evaluada bajo la varianza real $\sigma^2 = 0,10$:

$$\begin{aligned} \mathbb{P}(\text{Error tipo II}) &= \mathbb{P}(\text{No rechazar } H_0 \mid H_1 \text{ Verdadera}) \\ &= \mathbb{P}(S^2 \leq 0,08954 \mid \sigma^2 = 0,10) \\ &= \mathbb{P}\left(\chi^{2(24)} \leq \frac{0,08954 \cdot 24}{0,10}\right) \\ &= \mathbb{P}(\chi^{2(24)} \leq 21,49) = 0,3721 \end{aligned}$$

P3- En una fábrica de electrodomésticos se implementa un nuevo sistema de trabajo en la línea de ensamblaje, con el objetivo de reducir el tiempo promedio de ensamblaje de los técnicos en tareas complejas. Sea A el tiempo (en minutos) que tarda un técnico en ensamblar una unidad antes del nuevo sistema, y B el tiempo que tarda después de implementarlo. La siguiente tabla muestra los tiempos de ensamblaje de 7 técnicos, antes y después del cambio:

A	30	28	32	35	25	33	29
B	25	25	28	29	23	28	26

Considerando un nivel de confianza del 95 %, determine:

- (a) ¿Es efectivo el nuevo sistema de trabajo? Use una prueba de hipótesis con Región Crítica.
 (b) Suponiendo que, en realidad, el nuevo sistema reduce el tiempo de ensamblaje en solo 3 minutos en promedio (es decir, $\mu_D = 3$) ¿Cuál es la probabilidad de cometer un error tipo II?

Hint: Quizás le sirva alguno(s) de estos comandos:

Comando R	qt(0.95,6)	qt(0.975,6)	pt(3.67,6)	pt(1.94,6)	pt(7.48,6)
Output R	1,9432	2,4469	0,9948	0,9498	0,9999

Solución:

(a) Definamos H_0 y H_1 :

$$\begin{array}{l} \blacksquare H_0 : \mu_A - \mu_B \leq 0 \\ \blacksquare H_1 : \mu_A - \mu_B > 0 \end{array} \quad \left| \right.$$

Luego, determinamos el pivote obtenido:

$$\blacksquare t_{\text{obt}}^{(6)} = \frac{\bar{D} - \mu_D}{\frac{S_D}{\sqrt{n}}} = \frac{4 - 0}{\frac{1,4142}{\sqrt{7}}} = 7,483$$

Según Región Crítica, puesto que $t_{\text{obt}}^{(6)} = 7,483 > t_{0,05}^{(6)} = 1,943$, se rechaza H_0 , es decir, existe evidencia suficiente para afirmar que el nuevo sistema de trabajo es efectivo en reducir el tiempo promedio.

(b) Primero, determinamos el valor crítico de $\bar{D}$ que define el límite de la zona de rechazo bajo H_0 :

$$t_{\text{obt}}^{(6)} < t_{0,05}^{(6)} \implies \frac{\bar{D} - 0}{\frac{1,4142}{\sqrt{7}}} < 1,943 \implies \bar{D} < 1,943 \cdot \frac{1,4142}{\sqrt{7}} \implies \bar{D} < 1,039$$

Luego, calculamos la probabilidad de no rechazar H_0 , evaluada bajo $\mu_D = 3$:

$$\begin{aligned} \mathbb{P}(\text{Error tipo II}) &= \mathbb{P}(\text{No rechazar } H_0 \mid H_1 \text{ Verdadera}) \\ &= \mathbb{P}(\bar{D} \leq 1,039 \mid \mu_D = 3) \\ &= \mathbb{P}\left(\frac{\bar{D} - \mu_D}{\frac{S_D}{\sqrt{n}}} \leq \frac{1,039 - 3}{\frac{1,4142}{\sqrt{7}}}\right) \\ &= \mathbb{P}(t^{(6)} \leq -3,67) \\ &\approx 0,0052 \end{aligned}$$

P4- [Ejercicio R] Una empresa de comercio electrónico desea evaluar la percepción que tienen sus clientes sobre el servicio de entrega de productos a domicilio. Para ello, se realizó una encuesta a 300 clientes, quienes calificaron distintos aspectos del servicio utilizando una escala de evaluación.

La base de datos contiene 10 variables que representan distintos criterios utilizados por los clientes para evaluar el servicio ofrecido por los proveedores o empresas encargadas de la entrega. Estas variables corresponden a:

- **precio:** nivel de competitividad del precio del servicio.
 - **descuentos:** disponibilidad de descuentos o promociones asociadas al servicio.
 - **cond_pago:** flexibilidad en las condiciones de pago ofrecidas.
 - **calidad_prod:** calidad percibida de los productos entregados.
 - **confiabilidad:** grado de confianza en el cumplimiento del servicio.
 - **certificaciones:** percepción sobre certificaciones o estándares de calidad del proveedor.
 - **tiempo_entrega:** rapidez en la entrega de los pedidos.
 - **soporte_tecnico:** calidad del soporte o asistencia ante problemas o consultas.
 - **comunicacion:** eficiencia en la comunicación entre el proveedor y el cliente.
 - **flexibilidad:** capacidad de adaptación del servicio ante cambios o requerimientos especiales.
- (a) Examine la matriz de correlaciones entre las variables y evalúe si es apropiado aplicar análisis factorial utilizando la medida de adecuación muestral KMO y el test de esfericidad de Bartlett.
- (b) Determinación del número de factores usando el criterio de Kaiser y del codo.
- (c) Realice el análisis utilizando los métodos de extracción: Componentes Principales (ACP), Ejes Principales, Máxima Verosimilitud.
- (d) Aplique una rotación ortogonal (Varimax) y dos rotaciones oblicuas (Promax y Oblimin). Compare los resultados obtenidos.
- (e) Interpretación de los factores. Identifique las variables con cargas factoriales más altas en cada factor, y proponga una interpretación conceptual para cada factor.
- (f) Evaluación del modelo: analice las comunalidades de las variables. Compare las soluciones obtenidas con distintos métodos y rotaciones. Justifique cuál solución considera más adecuada.

Solución:

(a) Cargamos los datos y calculamos la matriz de correlaciones:

Resolución con Comando


```
library(readxl); library(psych); library(GPArotation); library(corrplot)

datos <- read_excel("datosayudantiafactorial.xlsx")
datos <- as.data.frame(datos)
mat_cor <- cor(datos)
round(mat_cor, 2)

corrplot(mat_cor, method = "color", type = "upper", addCoef.col = "black",
          tl.col = "black", tl.cex = 0.8, number.cex = 0.7)

KMO(mat_cor)
cortest.bartlett(mat_cor, n = nrow(datos))
```

Al observar la matriz de correlaciones se identifican, a simple vista, tres bloques de variables que se correlacionan fuertemente entre sí:



- precio, descuentos, cond_pago, certificaciones y tiempo_entrega: correlaciones altas entre ellas (en torno a 0,75–0,91).
- calidad_prod y confiabilidad: correlación alta entre ambas (0,85) y moderada con el bloque anterior.
- soporte_tecnico, comunicacion y flexibilidad: correlacionadas entre sí (0,47 a 0,80), pero prácticamente incorrelacionadas (≈ 0) con el resto de las variables.

En cuanto a la adecuación muestral:

Consola

```
> KMO(mat_cor)
Kaiser-Meyer-Olkin factor adequacy
Call: KMO(r = mat_cor)
Overall MSA = 0.64
MSA for each item =
      precio      descuentos      cond_pago      calidad_prod
      confiabilidad
      0.88      0.93      0.94      0.68
      0.78
certificaciones tiempo_entrega soporte_tecnico comunicacion
flexibilidad
      0.97      0.55      0.17      0.23
      0.42

> cortest.bartlett(mat_cor, n = nrow(datos))
$chisq
[1] 4431.63
$p.value
[1] 0
$df
[1] 45
```

El KMO global es $0,64 > 0,5$, lo que clasifica como una adecuación muestral **aceptable** para realizar análisis factorial. Sin embargo, al revisar el MSA individual se detectan valores muy bajos para **soporte_tecnico** (0,17) y **comunicacion** (0,23), lo que indica que estas variables comparten poca varianza común con el resto y podrían ser candidatas a eliminarse en un análisis posterior.

Por otro lado, el test de esfericidad de Bartlett entregó $\chi_{\text{obt}}^{2(45)} = 4431,63$ y $p\text{-value} \approx 0$, por lo que se rechaza $H_0 : \Sigma = I$, es decir, existe evidencia suficiente de correlación entre las variables.

(b) Se calculan los valores propios de la matriz de correlaciones y se construye el scree plot:

Resolución con Comando


```
ev <- eigen(mat_cor)
ev$values

scree(datos, factors = TRUE, pc = TRUE)
```

Consola

```
> ev$values
[1] 5.4711010110 2.1552427306 1.0242614841 0.5533521698 0.3248959724
    0.1767430035
[7] 0.1450055038 0.0778018376 0.0706263970 0.0009698901
```

- **Criterio de Kaiser** ($\lambda \geq 1$): de los 10 valores propios, 3 superan el umbral de 1 ($\lambda_1 = 5,47$, $\lambda_2 = 2,16$, $\lambda_3 = 1,02$), por lo que este criterio sugiere retener **3 factores**.



- **Criterio del Codo:** El codo se ubica en torno a $k = 4$, por lo que el criterio del codo sugiere retener entre **3 factores**.

(c) Realicemos el método de extracción de Componentes Principales (ACP):

Resolución con Comando

```
acp <- principal(datos, nfactors = 3, rotate = "none")
print(acp$loadings, cutoff = 0.3, sort = TRUE)
```

Consola

```
> print(acp$loadings, cutoff = 0.3, sort = TRUE)
Loadings:
      precio      PC1      PC2      PC3
descuentos      0.918
cond_pago       0.865
confiabilidad   0.870
confiabilidad   0.824      0.486
certificaciones 0.943
tiempo_entrega  0.907
soporte_tecnico      0.797
comunicacion      0.892
flexibilidad     0.564    0.807
calidad_prod     0.633      0.747

      PC1      PC2      PC3
SS loadings  5.471  2.155  1.024
Proportion Var 0.547  0.216  0.102
Cumulative Var 0.547  0.763  0.865
```

Luego, realicemos el método de extracción de Ejes Principales:

Resolución con Comando

```
ejes <- fa(datos, nfactors = 3, fm = "pa", rotate = "none")
print(ejes$loadings, cutoff = 0.3, sort = TRUE)
```

Consola

```
> print(ejes$loadings, cutoff = 0.3, sort = TRUE)
Aviso: An ultra-Heywood case was detected. Examine the results carefully

Loadings:
      PA1    PA2    PA3
precio    0.906
descuentos 0.841
cond_pago 0.844
confiabilidad 0.814      0.432
certificaciones 0.935
tiempo_entrega 0.882
soporte_tecnico      0.591
comunicacion      0.767
flexibilidad 0.616 0.972
calidad_prod 0.635      0.735

      PA1    PA2    PA3
SS loadings 5.351 1.988 0.927
Proportion Var 0.535 0.199 0.093
Cumulative Var 0.535 0.734 0.827
```

Posteriormente, realicemos el método de extracción de Máxima Verosimilitud:

Resolución con Comando

```
mv <- fa(datos, nfactors = 3, fm = "ml", rotate = "none")
print(mv$loadings, cutoff = 0.3, sort = TRUE)
```

Consola

```
> print(mv$loadings, cutoff = 0.3, sort = TRUE)
Loadings:
      ML2    ML1    ML3
precio    0.749 0.310
descuentos 0.706
cond_pago 0.705
confiabilidad 0.634
certificaciones 0.850 0.338
tiempo_entrega 0.922 0.373
soporte_tecnico -0.354 0.734 0.575
comunicacion -0.322 0.832 -0.448
flexibilidad      0.981
calidad_prod 0.453

      ML2    ML1    ML3
SS loadings 3.996 2.797 0.566
Proportion Var 0.400 0.280 0.057
Cumulative Var 0.400 0.679 0.736
```

Los tres métodos identifican una estructura similar de 3 factores, aunque con diferencias relevantes:

- **ACP** logra la estructura más limpia y la mayor varianza explicada (86,5 %) precisamente porque no separa varianza común de varianza única: al maximizar varianza total, tiende a producir componentes con cargas altas y pocas cruzadas, pero esto es una ventaja artificial más que evidencia de una estructura latente real.

- **Ejes Principales** recupera una agrupación equivalente a la de ACP, pero al modelar varianza común mediante communalidades iniciales, expone una limitación que ACP no puede detectar: la communalidad de **flexibilidad** resulta mayor a 1 (caso ultra-Heywood), señal de que el modelo de 3 factores está sobreajustando esta variable o de que su varianza única fue mal especificada.
- **Máxima Verosimilitud** es el método más exigente estadísticamente, y por lo mismo el que peor ajusta sin rotar: al buscar el óptimo de verosimilitud sin restricción de estructura simple, reparte la varianza de **soporte_tecnico** y **comunicacion** en dos factores con signos opuestos, generando un tercer factor (ML3) débil y sin interpretación clara. La menor varianza acumulada (73,6 %) no refleja necesariamente un modelo peor, sino uno más conservador, que separa correctamente varianza común de error y por tanto exige rotación para volverse interpretable.

(d) Realicemos la rotación ortogonal (Varimax):

Resolución con Comando

```
varimax_sol <- fa(datos, nfactors = 3, fm = "ml", rotate = "varimax")
print(fa.sort(varimax_sol)$loadings, cutoff = 0.3)
```

Consola

```
> print(fa.sort(varimax_sol)$loadings, cutoff = 0.3)
Loadings:
      tiempo_entrega      ML2      ML1      ML3
certificaciones      0.919
precio               0.807
cond_pago            0.761
descuentos           0.751
confiabilidad        0.680
calidad_prod         0.503
comunicacion                0.982
flexibilidad          0.460      0.791      0.400
soporte_tecnico                0.324      0.943

      ML2      ML1      ML3
SS loadings      4.567  1.715  1.077
Proportion Var   0.457  0.172  0.108
Cumulative Var   0.457  0.628  0.736
```

Luego, realicemos la rotación oblicua (Promax):

Resolución con Comando

```
promax_sol <- fa(datos, nfactors = nf, fm = "ml", rotate = "promax")
print(fa.sort(promax_sol)$loadings, cutoff = 0.3)
```

Consola

```
> print(fa.sort(promax_sol)$loadings, cutoff = 0.3)
Loadings:
      tiempo_entrega      ML2      ML1      ML3
certificaciones      0.927
precio      0.810
cond_pago      0.767
descuentos      0.757
confiabilidad      0.688
calidad_prod      0.504
comunicacion      1.087
flexibilidad      0.363      0.706
soporte_tecnico      1.027

      ML2      ML1      ML3
SS loadings      4.595      1.687      1.128
Proportion Var      0.459      0.169      0.113
Cumulative Var      0.459      0.628      0.741
```

Posteriormente, realicemos la rotación oblicua (Oblimin):

Resolución con Comando

```
oblimin_sol <- fa(datos, nfactors = nfacs, fm = "ml", rotate = "oblimin")
print(fa.sort(oblimin_sol)$loadings, cutoff = 0.3)
```

Consola

```
> print(fa.sort(oblimin_sol)$loadings, cutoff = 0.3)
Loadings:
      tiempo_entrega      ML1      ML3      ML2
certificaciones      0.924
precio      0.811
cond_pago      0.766
descuentos      0.756
confiabilidad      0.685
calidad_prod      0.505
comunicacion      1.027
flexibilidad      0.432      0.671
soporte_tecnico      1.009

      ML1      ML3      ML2
SS loadings      4.602      1.510      1.102
Proportion Var      0.460      0.151      0.110
Cumulative Var      0.460      0.611      0.721
```

La agrupación de variables en factores es **consistente entre las tres rotaciones**: un primer factor con tiempo_entrega, certificaciones, precio, cond_pago, descuentos, confiabilidad y calidad_prod; un segundo factor con comunicacion y flexibilidad; y un tercer factor dominado por soporte_tecnico. Las cargas son levemente más altas y más "limpias" (menos cargas cruzadas) en Promax y Oblimin que en Varimax, lo cual es esperable en rotaciones oblicuas.

Además, notemos lo siguiente:

Resolución con Comando

```
oblmin_sol$Phi
promax_sol$Phi
```

Consola

```
> oblmin_sol$Phi
      ML1      ML3      ML2
ML1 1.00000000 0.1297898 0.08175966
ML3 0.12978979 1.0000000 0.51597385
ML2 0.08175966 0.5159738 1.00000000
> promax_sol$Phi
      ML2      ML1      ML3
ML2 1.0000000 0.2089925 0.1191772
ML1 0.2089925 1.0000000 0.5879291
ML3 0.1191772 0.5879291 1.0000000
```

Respecto a la correlación entre factores (Φ), se observa que la correlación entre el factor de **comunicacion / flexibilidad** y el factor de **soporte_tecnico** es **moderada-alta** ($\approx 0,52$ en Oblimin y $\approx 0,59$ en Promax), mientras que estos dos factores presentan correlación **baja** con el primer factor (comercial/calidad), en torno a 0,08–0,21. Esto indica que, si bien dos de los tres factores no son estrictamente independientes, forzar ortogonalidad entre todos ellos (Varimax) no es del todo realista, por lo que una **rotación oblicua (Oblimin o Promax) resulta más apropiada** que Varimax para este conjunto de datos.

(e) Utilizando las cargas ordenadas de la solución rotada (Oblimin, por ser la rotación oblicua más adecuada según lo discutido en (d)), se identifican tres factores interpretables:

- **Factor 1 (ML1):** tiempo_entrega (0,999), certificaciones (0,924), precio (0,811), cond_pago (0,766), descuentos (0,756), confiabilidad (0,685) y calidad_prod (0,505).

Este factor agrupa variables comerciales (precio, descuentos, condiciones de pago) junto con variables de calidad y confianza del proveedor (certificaciones, confiabilidad, calidad del producto) y la rapidez de entrega. Puede interpretarse como **Propuesta de valor y confiabilidad del proveedor**: refleja cuán atractiva es la oferta comercial del proveedor y cuánta confianza genera en términos de calidad y cumplimiento. Que estas variables se agrupen en un solo factor (y no en dos, como podría anticiparse a priori) sugiere que, para los clientes encuestados, un precio competitivo y buenas condiciones de pago están fuertemente asociados a la percepción de un proveedor confiable y de calidad.

- **Factor 2 (ML3):** comunicacion (1,027) y flexibilidad (0,671).

Agrupar la eficiencia de la comunicación con el cliente y la capacidad de adaptación del servicio. Se interpreta como **Comunicación y flexibilidad del servicio**: mide qué tan bien el proveedor se adapta y comunica ante cambios o requerimientos especiales del cliente.

- **Factor 3 (ML2):** soporte_tecnico (1,009), con carga moderada de flexibilidad (0,432).

Se interpreta como **Soporte técnico**: calidad de la asistencia entregada ante problemas o consultas puntuales. Que aparezca como un factor prácticamente aislado, correlacionado solo moderadamente con el factor de comunicación/flexibilidad, sugiere que el soporte técnico es percibido por los clientes como una dimensión de servicio relativamente distinta del resto.

(f) Comunalidades bajo cada método:

Resolución con Comando

```
data.frame(ACP      = acp$communality,
            Ejes     = ejes$communality,
            ML       = mv$communality,
            Varimax  = varimax_sol$communality,
            Oblimin  = oblimin_sol$communality)

mv$fit; ejes$fit; varimax_sol$fit; oblimin_sol$fit
```

Consola

	ACP	Ejes	ML	Varimax	Oblimin
precio	0.8948517	0.8796968	0.6577592	0.6577592	0.6577592
descuentos	0.8546151	0.8007570	0.5688351	0.5688351	0.5688351
cond_pago	0.8457481	0.7905152	0.5816519	0.5816519	0.5816519
calidad_prod	0.9606181	0.9495875	0.2576202	0.2576202	0.2576202
confiabilidad	0.9315692	0.8738247	0.4629078	0.4629078	0.4629078
certificaciones	0.9087894	0.9024706	0.8467027	0.8467027	0.8467027
tiempo_entrega	0.8345050	0.7923547	0.9953412	0.9953412	0.9953412
soporte_tecnico	0.6451763	0.3571324	0.9952036	0.9952036	0.9952036
comunicacion	0.8031930	0.5959158	0.9959465	0.9959465	0.9959465
flexibilidad	0.9715394	1.3240789	0.9971288	0.9971288	0.9971288

```
> mv$fit
[1] 0.9337534
> ejes$fit
[1] 0.9753703
> varimax_sol$fit
[1] 0.9337534
> oblimin_sol$fit
[1] 0.9337534
```

- **ACP:** Entrega comunalidades altas para todas las variables ($> 0,64$), sin valores fuera de rango. Es esperable, ya que ACP explica el 100 % de la varianza de cada variable (común + única).
- **Ejes Principales:** presenta el problema ya mencionado: la comunalidad de **flexibilidad** es 1,324, es decir, **mayor a 1**, lo cual es matemáticamente imposible para una comunalidad real y confirma el caso ultra-Heywood detectado por R. Esto invalida esta solución para **flexibilidad** en particular, aunque el resto de las comunalidades son razonables.
- **Máxima Verosimilitud:** (y por tanto también sus rotaciones Varimax/Oblimin, que no cambian las comunalidades) entrega comunalidades muy altas para **tiempo_entrega**, **soporte_tecnico**, **comunicacion** y **flexibilidad** (todas $> 0,99$), pero muy baja para **calidad_prod** (0,26), lo que indica que este método explica muy poco de la varianza de dicha variable con solo 3 factores.
- El índice de ajuste (**fit**) es levemente superior para Ejes Principales (0,975) que para ML (0,934), pero este resultado debe tomarse con cautela dado el caso ultra-Heywood detectado en Ejes Principales.

Justificación de la solución más adecuada: Se recomienda utilizar la **solución de Máxima Verosimilitud con rotación Oblimin** como la más adecuada para este análisis: permite modelar de forma más realista la correlación existente entre los factores de «Comunicación y flexibilidad» y «Soporte técnico», sin forzar una independencia (ortogonalidad) que los datos no respaldan completamente, evitando además el problema de estimación presente en Ejes Principales.