

Ayudantía 4

Análisis Factorial

Cristóbal Van der Meer Miranda

Facultad de Ingeniería y Ciencias Aplicadas
Universidad de los Andes, Chile




Universidad de
los Andes

Análisis Factorial



Diferencia entre PCA y AF

Sea $X = (X_1, X_2, \dots, X_p)^T$ un vector de variables observadas, entonces tenemos:



Cantidad de Factores en Análisis Factorial

En un análisis factorial, se pueden distinguir **cantidades de factores latentes**:

Unidimensional	Multidimensional
Variables se explican por solo 1 factor latente.	Variables se explican por más de 1 factor latente.
	

De esta manera, el **objetivo** del **análisis factorial** es identificar cuántos factores latentes explican la **varianza común entre las variables**.

Análisis Factorial

Sea $X = (X_1, X_2, \dots, X_p)^T$ un vector de variables observadas, entonces el análisis factorial define que cada variable puede ser expresada como:

$$X_i = \sum_{j=1}^k \lambda_{ij} F_j + \varepsilon_i$$

Donde:

Variable	Significado	Definición
F_j	Factor latente j Factor común j	Variable no observable que explica la varianza común entre las observadas.
λ_{ij}	Carga factorial ij	Valor que cuantifica la contribución de F_j en la explicación de X_i .
ε_i	Factor específico i	Componente de X_i que recoge la variabilidad no explicada por los factores.

Modelo Factorial en Forma Matricial

Sean $\vec{X} \in \mathbb{R}^p$ un vector de variables observadas, $\lambda_{p \times k}$ una matriz de cargas factoriales, $\vec{F} \in \mathbb{R}^k$ un vector de factores latentes y $\vec{\varepsilon} \in \mathbb{R}^p$ un vector de errores, entonces el modelo de análisis factorial puede escribirse como:

$$\vec{X} = \lambda \vec{F} + \vec{\varepsilon}$$

De **forma análoga**, se tiene:

$$\therefore \begin{bmatrix} X_1 \\ X_2 \\ X_3 \\ \vdots \\ X_p \end{bmatrix} = \begin{bmatrix} \lambda_{11} & \lambda_{12} & \cdots & \lambda_{1k} \\ \lambda_{21} & \lambda_{22} & \cdots & \lambda_{2k} \\ \lambda_{31} & \lambda_{32} & \cdots & \lambda_{3k} \\ \lambda_{41} & \lambda_{42} & \ddots & \vdots \\ \lambda_{p1} & \lambda_{p2} & \cdots & \lambda_{pk} \end{bmatrix} \begin{bmatrix} F_1 \\ F_2 \\ \vdots \\ F_k \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \vdots \\ \varepsilon_p \end{bmatrix} \Rightarrow \begin{cases} X_1 = \lambda_{11}F_1 + \lambda_{12}F_2 + \cdots + \lambda_{1k}F_k + \varepsilon_1 \\ X_2 = \lambda_{21}F_1 + \lambda_{22}F_2 + \cdots + \lambda_{2k}F_k + \varepsilon_2 \\ X_3 = \lambda_{31}F_1 + \lambda_{32}F_2 + \cdots + \lambda_{3k}F_k + \varepsilon_3 \\ \vdots \\ X_5 = \lambda_{51}F_1 + \lambda_{52}F_2 + \cdots + \lambda_{5k}F_k + \varepsilon_5 \end{cases}$$

Varianza Total

Sea X_i una variable observada, es posible calcular su **varianza total** de la siguiente manera:

$$\begin{aligned}\therefore \mathbb{V}(X_i) &= \mathbb{V}\left[\sum_{j=1}^k \lambda_{ij} F_j + \varepsilon_i\right] \\ &= \left[\sum_{j=1}^k \lambda_{ij}^2 \cancel{\mathbb{V}(F_j)}^1\right] + \left[2 \sum_{j < l} \lambda_{ij}^2 \lambda_{il}^2 \cancel{\text{Cov}(F_j, F_l)}^0\right] + \left[2 \sum_{j=1}^k \lambda_{ij}^2 \cancel{\text{Cov}(F_j, \varepsilon_i)}^0\right] + \mathbb{V}(\varepsilon_i)\end{aligned}$$

Finalmente, se obtiene la **expresión equivalente**:

$$\mathbb{V}(X_i) = \sum_{j=1}^k \lambda_{ij}^2 + \mathbb{V}(\varepsilon_i)$$

Varianza Específica

Varianza Común

Varianza común (Comunalidad)

La **comunalidad** de la variable X_i , denotada por h_i^2 , corresponde a la **proporción de la varianza** de X_i **explicada** por los **factores latentes** del modelo factorial. De esta manera, tenemos:

$$h_i^2 = \sum_{j=1}^k \lambda_{ij}^2$$

Además, la **comunalidad** posee las siguientes **interpretaciones**:

#	Caso	Interpretación
1	$h_i^2 \rightarrow 1$	La variable está bien representada por los factores, fuerte correlación con otras variables.
2	$h_i^2 \rightarrow 0$	La variable NO está bien representada por los factores, débil correlación con otras variables.

Varianza específica (Unicidad)

La **unicidad** de la variable X_i , denotada por ψ_i , corresponde a la **proporción de la varianza** de X_i **NO explicada** por los **factores latentes** del modelo factorial. De esta manera, tenemos:

$$\psi_i = 1 - h_i^2$$

Además, la **unicidad** posee las siguientes **interpretaciones**:

#	Caso	Interpretación
1	$\psi_i \rightarrow 1$	La variable NO está bien representada por los factores, débil correlación con otras variables.
2	$\psi_i \rightarrow 0$	La variable está bien representada por los factores, fuerte correlación con otras variables.

Evaluación de la Matriz de Correlación

Antes de aplicar Análisis Factorial, hay que verificar que los datos sean adecuados: las variables deben estar suficientemente **correlacionadas** entre sí. Así, dos pruebas permiten evaluarlo:

Test de Esferidad de Bartlett	Medida Kaiser-Meyer-Olkin
■ $H_0: R = I_p$ ■ $H_1: R \neq I_p$	$KMO = \frac{\sum_{j \neq i} \sum_{i \neq j} r_{ij}^2}{\sum_{j \neq i} \sum_{i \neq j} r_{ij}^2 + \sum_{j \neq i} \sum_{i \neq j} r_{ij}^2 (p)}$
Evalúa si la matriz de correlación es significativamente distinta de la identidad.	Evalúa qué tan bien las correlaciones simples se explican por factores comunes, frente al ruido de las correlaciones parciales.
• $p_{value} < 0,5$: Aceptable (AF es apropiado). • $p_{value} \geq 0,5$: Inaceptable (AF no es apropiado).	• $KMO \geq 0,5$: Aceptable (AF es apropiado). • $KMO < 0,5$: Inaceptable (AF no es apropiado).



Métodos de Extracción de Factores

A continuación, se presentan 3 métodos de **extracción de factores**:

Componentes Principales	Ejes Principales	Máxima Verosimilitud
• Usa las primeras k componentes principales. • Siempre converge. • No sigue el modelo factorial. • Usa toda la varianza (no solo la común).	• Reemplaza los 1s de la diagonal por comunales. • Método iterativo (hasta convergencia).	• Supone normalidad multivariada. • Estima A y Ψ maximizando verosimilitud. • Modelo: $\sum AA' + \Psi$. • Contiene el test χ^2 de ajuste.



Selección del Número de Factores

Antes de interpretar el modelo, hay que decidir **cuántos factores conservar**. No existe un único criterio correcto, en la práctica se combinan varios:

Determinación Apriori	• Basado en teoría o conocimiento previo. • Más confiable si hay buena base teórica
Regla de Kaiser	• Conservar factores con $\lambda > 1$. • Simple, pero puede subestimar factores.
Varianza Explicada	• Elegir factores que expliquen 75% – 80% de la varianza total. • El umbral es algo arbitrario.
Scree Plot	• Graficar eigenvalues vs factores, y elegir antes del “codo”. • Es subjetivo.



Tipos de Rotación

Los **métodos de extracción** no siempre generan **soluciones interpretables**, por tanto, surge la necesidad de “**rotarlos**” para **simplificar su estructura**, donde cada variable tenga **cargas altas** en **pocos factores** y **bajas en el resto**.

Ortogonal (Asume Factores independientes)	Varimax	Maximiza la varianza de las cargas dentro de cada factor. Produce factores más “puros” (variables cargan fuerte en uno)
	Quartimax	Simplifica variables (filas).
	Equamax	Balance entre ambos,
Oblicua (Asume Factores correlacionados)	Oblimin	Permite correlación entre factores.
	Promax	Varimax + permite correlación (rápido).

Además, la rotación no cambia comunalidades, especificidades ni varianza total explicada, **solo mejora la interpretabilidad**.



Verdaderos/Falsos

Ejercicio 1-1

■ Responda Verdadero o Falso según corresponda:

<<El análisis factorial busca identificar variables latentes observables directamente en los datos.>>

∴ Falso.

⇒ Los factores son variables latentes no observadas, inferidas a partir de las correlaciones.

Ejercicio 1-2

■ Responda Verdadero o Falso según corresponda:

<<En análisis factorial, una alta correlación entre dos variables sugiere que podrían estar influenciadas por un mismo factor latente.>>

∴ Verdadero.

⇒ Los factores explican la varianza común entre variables correlacionadas.

Ejercicio 1-3

■ Responda Verdadero o Falso según corresponda:

<<Si las variables presentan correlaciones moderadas pero las correlaciones parciales son altas, entonces el análisis factorial es apropiado.>>

∴ Falso.

⇒ Correlaciones parciales altas indican poca varianza común explicada por factores.

Ejercicio 1-4

■ Responda Verdadero o Falso según corresponda:

<<El modelo factorial supone que los factores comunes y los factores específicos pueden estar correlacionados entre sí.>>

∴ Falso.

⇒ El modelo supone que factores comunes y específicos son incorrelados.

Ejercicio 1-5

■ Responda Verdadero o Falso según corresponda:

<<Una comunalidad cercana a cero indica que la variable está mal representada por los factores extraídos.>>

∴ Verdadero.

⇒ Significa que los factores explican muy poca varianza de esa variable.

Ejercicio 1-6

■ Responda Verdadero o Falso según corresponda:

<<Si una variable tiene comunalidad igual a 1, entonces toda su varianza es explicada por los factores comunes.>>

∴ Verdadero.

⇒ No existiría varianza específica ni error.

Ejercicio 1-7

■ Responda Verdadero o Falso según corresponda:

<<El método de componentes principales es estrictamente un modelo de análisis factorial porque estima factores comunes.>>

∴ Falso.

⇒ PCA no distingue entre varianza común y específica.

Ejercicio 1-8

■ Responda Verdadero o Falso según corresponda:

<<El criterio de Kaiser garantiza siempre una estimación correcta del número de factores.>>

∴ Falso.

⇒ Puede subestimar o sobreestimar el número de factores.

Ejercicio 1-9

■ Responda Verdadero o Falso según corresponda:

<< Una rotación factorial puede cambiar las comunalidades de las variables.>>

∴ Falso.

⇒ La rotación no altera comunalidades ni varianza total explicada.

Ejercicio 1-10

■ Responda Verdadero o Falso según corresponda:

<<En rotaciones oblicuas, los factores pueden estar correlacionados entre sí.>>

∴ Verdadero.

⇒ A diferencia de rotaciones ortogonales.

Ejercicio 1-11

■ Responda Verdadero o Falso según corresponda:

<<Si la matriz de correlaciones es cercana a la identidad, es probable que el análisis factorial sea poco útil.>>

∴ Verdadero.

⇒ Indica ausencia de correlación entre variables.

Ejercicio 1-12

■ Responda Verdadero o Falso según corresponda:

<<Un valor KMO alto indica que las correlaciones parciales son relativamente pequeñas respecto a las correlaciones simples.>>

∴ Verdadero.

⇒ Lo que sugiere presencia de factores comunes.

Ejercicio 1-13

■ Responda Verdadero o Falso según corresponda:

<<Una carga factorial alta indica necesariamente que la variable está asociada únicamente a ese factor.>>

∴ Falso.

⇒ Puede tener cargas altas en varios factores.

Ejercicio 1-14

■ Responda Verdadero o Falso según corresponda:

<<La rotación factorial busca modificar el número de factores obtenidos inicialmente.>>

∴ Falso.

⇒ La rotación solo redistribuye las cargas factoriales.

Ejercicio 1-15

■ Responda Verdadero o Falso según corresponda:

<< El principio de parsimonia sugiere utilizar el mayor número posible de factores para explicar completamente los datos.>>

∴ Falso.

⇒ Busca explicar los datos con el menor número de factores posible.

Ejercicio 1-16

■ Responda Verdadero o Falso según corresponda:

<<El scree plot permite identificar el número de factores observando el punto donde los eigenvalues dejan de decrecer rápidamente.>>

∴ Verdadero.

⇒ Ese punto se conoce como “codo” del gráfico.

Ejercicio 1-17

■ Responda Verdadero o Falso según corresponda:

<<Si una variable tiene cargas factoriales cercanas a cero en todos los factores, es probable que no esté bien representada por el modelo factorial.>>

∴ Verdadero.

⇒ Los factores no explican adecuadamente su variabilidad.

Ejercicio 1-18

■ Responda Verdadero o Falso según corresponda:

<<La rotación Varimax permite que los factores estén correlacionados entre sí.>>

∴ Falso.

⇒ Varimax es una rotación ortogonal.

Ejercicio 1-19

■ Responda Verdadero o Falso según corresponda:

<<El análisis factorial puede aplicarse, aunque no exista ninguna correlación significativa entre las variables.>>

∴ Falso.

⇒ Sin correlaciones no hay varianza común que modelar.

Ejercicio 1-20

■ Responda Verdadero o Falso según corresponda:

<<Los factores en análisis factorial son combinaciones lineales de variables observadas.>>

∴ Falso.

⇒ Las variables observadas son combinaciones lineales de factores, no al revés.

Ejercicio 1-21

■ Responda Verdadero o Falso según corresponda:

<<Si se aplica una rotación ortogonal, la matriz de correlaciones entre factores es la matriz identidad.>>

∴ Verdadero.

⇒ Esto significa correlación cero entre factores.

Ejercicio 1-22

■ Responda Verdadero o Falso según corresponda:

<<En rotaciones ortogonales, cada variable debe cargar exclusivamente en un solo factor.>>

∴ Falso.

⇒ Una variable puede tener cargas en varios factores.

Ejercicio 1-23

■ Responda Verdadero o Falso según corresponda:

<<Una solución factorial puede rotarse infinitas veces sin alterar el ajuste global del modelo.>>

∴ Verdadero.

⇒ El modelo factorial no es único salvo rotaciones.

Ejercicio 1-24

■ Responda Verdadero o Falso según corresponda:

<<En una rotación oblicua, las comunalidades cambian porque los factores pasan a estar correlacionados.>>

∴ Falso.

⇒ Las comunalidades dependen de las cargas factoriales totales y no cambian por la rotación.

Ejercicio 1-25

■ Responda Verdadero o Falso según corresponda:

<<Si los factores teóricos del fenómeno estudiado están correlacionados, es preferible utilizar rotación oblicua.>>

∴ Verdadero.

⇒ La rotación oblicua permite modelar correlaciones entre factores.

Ejercicio 1-26

■ Responda Verdadero o Falso según corresponda:

<<Una rotación ortogonal siempre produce una interpretación más realista del fenómeno estudiado.>>

∴ Falso.

⇒ Muchos fenómenos reales tienen factores correlacionados, por lo que una rotación oblicua puede ser más adecuada.

Ejercicio 1-27

■ Responda Verdadero o Falso según corresponda:

<<Varimax es un método de rotación oblicua diseñado para maximizar la correlación entre factores.>>

∴ Falso.

⇒ Varimax es rotación ortogonal y mantiene factores independientes.

Ejercicio 1-28

■ Responda Verdadero o Falso según corresponda:

<<La rotación factorial modifica las correlaciones originales entre las variables observadas.>>

∴ Falso.

⇒ Las rotaciones no alteran la matriz de correlaciones original.

Ejercicio 1-29

■ Responda Verdadero o Falso según corresponda:

<<En el modelo factorial se cumple que la comunalidad más la especificidad es igual a 1.>>

∴ Verdadero.

⇒ Cuando las variables están estandarizadas se cumple la relación $h^2 + \psi = 1$.

Ejercicio 1-30

■ Responda Verdadero o Falso según corresponda:

<<La especificidad de una variable corresponde a la varianza explicada por los factores comunes.>>

∴ Falso.

⇒ La especificidad es la varianza propia de la variable que no es explicada por los factores.

Ejercicio 1-31

■ Responda Verdadero o Falso según corresponda:

<<Si todas las variables presentan correlaciones muy bajas entre sí, el análisis factorial sigue siendo una técnica adecuada para aplicar.>>

∴ Falso.

⇒ El análisis factorial requiere correlaciones relativamente altas entre variables para identificar factores comunes.

Ejercicio 1-32

■ Responda Verdadero o Falso según corresponda:

<<El análisis factorial es una técnica que permite reducir un gran número de variables a un número menor de factores latentes.>>

∴ Verdadero.

⇒ El análisis factorial busca explicar las correlaciones entre variables observadas mediante un número menor de factores latentes.

Ejercicio 1-33

■ Responda Verdadero o Falso según corresponda:

<<En el análisis factorial existe una variable dependiente y varias variables independientes que explican su comportamiento.>>

∴ Falso.

⇒ En el análisis factorial todas las variables tienen el mismo papel; no existe una relación de dependencia como en regresión.

Ejercicio 1-34

■ Responda Verdadero o Falso según corresponda:

<<A medida KMO evalúa la adecuación de la muestra comparando correlaciones simples con correlaciones parciales.>>

∴ Verdadero.

⇒ El KMO mide si las correlaciones observadas pueden explicarse por factores comunes.

Ejercicio 1-35

■ Responda Verdadero o Falso según corresponda:

<<Valores de KMO menores a 0.5 indican que el análisis factorial es adecuado para los datos.>>

∴ Falso.

⇒ Valores menores a 0.5 indican que el análisis factorial no es apropiado.

Ejercicio 1-36

■ Responda Verdadero o Falso según corresponda:

<<El método de Componentes Principales analiza únicamente la varianza común entre las variables.>>

∴ Falso.

⇒ El PCA analiza toda la varianza (común + específica).

Ejercicio 1-37

■ Responda Verdadero o Falso según corresponda:

<<El método de Componentes Principales analiza toda la varianza de las variables, tanto común como específica.>>

∴ Verdadero.

⇒ Por eso PCA no es estrictamente un modelo factorial.

Ejercicio 1-38

■ Responda Verdadero o Falso según corresponda:

<<La regla de Kaiser sugiere conservar factores con valores propios menores que 1.>>

∴ Falso.

⇒ La regla indica conservar factores con eigenvalue mayor que 1.

Ejercicio 1-39

■ Responda Verdadero o Falso según corresponda:

<<El scree plot permite decidir el número de factores observando el punto donde la curva de eigenvalues se estabiliza.>>

∴ Verdadero.

⇒ Se conservan los factores antes del “codo” del gráfico.

Ejercicio 1-40

■ Responda Verdadero o Falso según corresponda:

<<La rotación factorial cambia las comunales y la varianza total explicada por los factores.>>

∴ Falso.

⇒ La rotación solo redistribuye la varianza entre factores, sin cambiar comunales ni varianza total.

Ejercicio 1-41

■ Responda Verdadero o Falso según corresponda:

<<La rotación de factores busca mejorar la interpretabilidad de la matriz de cargas factoriales.>>

∴ Verdadero.

⇒ La rotación produce una estructura más simple, facilitando la interpretación de los factores.