

Ayudantía 5 Métodos Estadísticos

Profesores: Carmen Gloria Carrasco | Héctor López.

Ayudantes: José Ignacio Costa | Cristóbal Van Der Meer

24 de septiembre de 2026

1. Estas son las coordenadas de las localizaciones de 5 tiendas. Si queremos agruparlas en dos grupos, ¿cuáles serían esas agrupaciones?

Punto	X	Y
A	1	1
B	2	6
C	4	3
D	7	4
E	5	1

- a) Construir la matriz de distancias usando la norma del taxista (Manhattan).
- b) Realizar 3 iteraciones de clustering jerárquico aglomerativo usando:
- Vecino más cercano.
 - Vecino más lejano.
 - Promedio.
- c) Dibujar el dendrograma aproximado.

Solución:

a) Matriz de Distancias Manhattan:

Punto	(x, y)
A	(1, 1)
B	(2, 6)
C	(4, 3)
D	(7, 4)
E	(5, 1)

La distancia del taxista entre dos puntos $p = (x_1, y_1)$ y $q = (x_2, y_2)$ es:

$$d(p, q) = |x_1 - x_2| + |y_1 - y_2|$$

Matriz de distancias (norma del taxista)

Calculamos todas las distancias dos a dos:

- $d(A, B) = |1 - 2| + |1 - 6| = 1 + 5 = 6$
- $d(A, C) = |1 - 4| + |1 - 3| = 3 + 2 = 5$
- $d(A, D) = |1 - 7| + |1 - 4| = 6 + 3 = 9$
- $d(A, E) = |1 - 5| + |1 - 1| = 4 + 0 = 4$
- $d(B, C) = |2 - 4| + |6 - 3| = 2 + 3 = 5$
- $d(B, D) = |2 - 7| + |6 - 4| = 5 + 2 = 7$
- $d(B, E) = |2 - 5| + |6 - 1| = 3 + 5 = 8$
- $d(C, D) = |4 - 7| + |3 - 4| = 3 + 1 = 4$
- $d(C, E) = |4 - 5| + |3 - 1| = 1 + 2 = 3$
- $d(D, E) = |7 - 5| + |4 - 1| = 2 + 3 = 5$

Matriz de distancias

	A	B	C	D	E
A	0	6	5	9	4
B	6	0	5	7	8
C	5	5	0	4	3
D	9	7	4	0	5
E	4	8	3	5	0

b) Clustering jerárquico aglomerativo:

- **Vecino más cercano (Single Linkage)**

Iteración 1

Distancia mínima: $d(C, E) = 3$. **Se agrupan C–E**

Clústeres: {C, E}, A, B, D

Iteración 2:

Distancias relevantes:

- $d(\{C, E\}, D) = \min(4, 5) = 4$
- $d(\{C, E\}, A) = \min(5, 4) = 4$
- $d(\{C, E\}, B) = \min(5, 8) = 5$
- $d(A, B) = 6$
- $d(B, D) = 7$

Mínima = 4, **tomamos {C, E} – D**

Clústeres: {C, E, D}, A, B


Iteración 3:

- $d(\{C, E, D\}, A) = \min(5, 4, 9) = 4$
- $d(\{C, E, D\}, B) = \min(5, 8, 7) = 5$
- $d(A, B) = 6$

Se agrupan $\{C, E, D\} - A$

Clústeres tras 3 iteraciones: $\{A, C, D, E\}, \{B\}$

Dos grupos finales: $\{A, C, D, E\}$ y $\{B\}$



- **Vecino más lejano (Complete linkage)**

Iteración 1:

Mínima distancia: $d(C, E) = 3$. **Se agrupan C-E**

Clústeres: $\{C, E\}, A, B, D$

Iteración 2:

Distancias (máximo entre puntos):

- $d(\{C, E\}, A) = \max(5, 4) = 5$
- $d(\{C, E\}, D) = \max(4, 5) = 5$

- $d(\{C, E\}, B) = \max(5, 8) = 8$
- $d(A, B) = 6$
- $d(B, D) = 7$

Se agrupan A – {C, E}

Clústeres: {A, C, E}, B, D


Iteración 3:

- $d(\{A, C, E\}, D) = \max(9, 4, 5) = 9$
- $d(B, D) = 7$

Se agrupan B – D

Clústeres tras 3 iteraciones: {A, C, E}, {B, D}

Dos grupos finales: $\{A, C, E\}$ y $\{B, D\}$



C) Promedio (Average linkage)

Iteración 1:

Mínima distancia: $d(C, E) = 3$.

Se agrupan C – E

Clústeres: $\{C, E\}$, A, B, D

Iteración 2:

Distancias promedio:

- $d(\{C, E\}, A) = \frac{5+4}{2} = 4.5$
- $d(\{C, E\}, D) = \frac{4+5}{2} = 4.5$
- $d(A, B) = 6$

Se agrupa $\{C, E\}$ – A

Clústeres: $\{A, C, E\}$, B, D


Iteración 3:

- $d(\{A, C, E\}, D) = \frac{9+4+5}{3} = 6$
- $d(B, D) = 7$

Se agrupa $\{A, C, E\}$ – D

Clústeres tras 3 iteraciones: $\{A, C, E, D\}$, $\{B\}$

Dos grupos finales: $\boxed{\{A, C, E, D\} \text{ y } \{B\}}$



2. Se tiene la siguiente información acerca de 5 proveedores:

Proveedor	Precio	Calidad	Tiempo
P1	130	8	5
P2	120	9	6
P3	90	6	4
P4	200	7	10
P5	180	8	9

Realizar 3 iteraciones usando el centroide como el punto de referencia de cada clúster.

Solución:

Debido que las variables tienen escalas distintas, normalizamos con Min-Max:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Valores Mínimos y Máximos:

Variable	Min	Max
Precio	90	200
Calidad	6	9
Tiempo	4	10

Datos Normalizados:

Proveedor	Precio	Calidad	Tiempo
P1	$(130-90)/110 = 0.36$	$(8-6)/3 = 0.67$	$(5-4)/6 = 0.17$
P2	0.27	1.00	0.33
P3	0.00	0.00	0.00
P4	1.00	0.33	1.00
P5	0.82	0.67	0.83

```
> datos_norm
  precio  calidad  tiempo proveedor
1 0.3636364 0.6666667 0.1666667      P1
2 0.2727273 1.0000000 0.3333333      P2
3 0.0000000 0.0000000 0.0000000      P3
4 1.0000000 0.3333333 1.0000000      P4
5 0.8181818 0.6666667 0.8333333      P5
```

Iteración 1:

Distancias mínimas usando la fórmula de distancia entre dos puntos:

- $d(P1, P2) = \sqrt{(0.36 - 0.27)^2 + (0.67 - 1)^2 + (0.17 - 0.33)^2} = 0.38$
- $d(P1, P3) = \sqrt{(0.36 - 0.27)^2 + (0.67 - 1)^2 + (0.17 - 0.33)^2} = 0.78$
- $d(P1, P4) = \sqrt{(0.36 - 0.27)^2 + (0.67 - 1)^2 + (0.17 - 0.33)^2} = 1.10$

(Obs: Por extensión se omite el resto de los cálculos)

Se forma el clúster: $C_1 = (P1, P2)$

- Promedio de las variables.
 - Precio: $\frac{0.36+0.27}{2} = 0.32$
 - Calidad: $\frac{0.67+1}{2} = 0.84$
 - Tiempo: $\frac{0.17+0.33}{2} = 0.25$

Centroide de $C_1 = (0.32, 0.84, 0.25)$

Clústeres actuales:

- C_1 : (P1, P2)
- P3
- P4
- P5

Iteración 2:

- Distancias nuevas.
 - $C1 - P3$: $\sqrt{(0.32 - 0)^2 + (0.84 - 0)^2 + (0.25 - 0)^2} = 0.93$
 - $C1 - P4$: $\sqrt{(0.32 - 1)^2 + (0.84 - 0.33)^2 + (0.25 - 1)^2} = 1.14$
 - $C1 - P5$: $\sqrt{(0.32 - 0.82)^2 + (0.84 - 0.67)^2 + (0.25 - 0.83)^2} = 0.78$
 - $P3 - P4$: $\sqrt{(0 - 1)^2 + (0 - 0.33)^2 + (0 - 1)^2} = 1.45$
 - $P3 - P5$: $\sqrt{(0 - 0.82)^2 + (0.00 - 0.67)^2 + (0 - 0.83)^2} = 1.35$
 - **$P4 - P5$: $\sqrt{(1 - 0.82)^2 + (0.33 - 0.67)^2 + (1 - 0.83)^2} = 0.42$**

La menor distancia corresponde a $d(P4, P5) = 0.42$

Nuevo clúster: $C2 = (P4, P5)$

- Promedio de las variables.
 - Precio: $\frac{1+0.82}{2} = 0.91$
 - Calidad: $\frac{0.33+0.67}{2} = 0.50$
 - Tiempo: $\frac{1+0.83}{2} = 0.92$

Centroide de $C2 = (0.91, 0.50, 0.92)$

Clústeres:

- $C_1 = (P1, P2)$
- $C_2 = (P4, P5)$
- $P3$

Iteración 3:

- Distancias:
 - $C1 - P3: \sqrt{(0.32 - 0)^2 + (0.84 - 0)^2 + (0.25 - 0)^2} = 0.93$
 - $C2 - P3: \sqrt{(0.91 - 0)^2 + (0.5 - 0)^2 + (0.92 - 0)^2} = 1.39$
 - $C1 - C2: \sqrt{(0.32 - 0.91)^2 + (0.84 - 0.5)^2 + (0.25 - 0.92)^2} = 0.96$

Menor distancia: $(C_1, P3)$


Nuevo clúster: $C_3 = (P1, P2, P3)$

Resultado tras 3 iteraciones:

- Clúster A: $\{P1, P2, P3\}$
- Clúster B: $\{P4, P5\}$

Orden correcto de fusiones

- 1) $P1 - P2$
- 2) $P4 - P5$
- 3) $(P1, P2) - P3$



3. Supongamos 5 productos descritos por 4 características binarias:

- X_1 : Es ecológico.
- X_2 : Es importado.
- X_3 : Tiene garantía extendida.
- X_4 : Es de alta tecnología.

Producto	X1	X2	X3	X4
P1	1	0	1	1
P2	1	0	1	0
P3	0	1	0	0
P4	0	1	0	1
P5	1	0	0	1

Calcule la distancia para variables binarias y construya la matriz de distancias. Posteriormente, utilice el método DIANA para formar clústeres. Finalmente, interprete.

Solución:

Para calcular la distancia entre variables, usamos la distancia de Hamming:

$$d(x, y) = \text{número de variables distintas}$$

Ejemplos:

- $d(P1, P2) = 1$
- $d(P1, P3) = 4$
- $d(P3, P4) = 1$

Matriz de distancias

	P1	P2	P3	P4	P5
P1	0	1	4	3	1
P2	1	0	3	4	2
P3	4	3	0	1	3
P4	3	4	1	0	2
P5	1	2	3	2	0

Método DIANA (Divisive Analysis)

Iteración 1 – Primera división

Clúster inicial: $\{P1, P2, P3, P4, P5\}$

Calcular distancia promedio de cada objeto al resto:

- $\bar{d}(P1) = \frac{1+4+3+1}{4} = 2.25$
- $\bar{d}(P2) = \frac{1+3+4+2}{4} = 2.5$
- $\bar{d}(P3) = \frac{4+3+1+3}{4} = 2.75$
- $\bar{d}(P4) = \frac{3+4+1+2}{4} = 2.5$

- $\bar{d}(P5) = \frac{1+2+3+2}{4} = 2.0$

Como P3 es el máximo, este inicia un nuevo clúster.

División inicial:

- $C_1 = \{P3\}$
- $C_2 = \{P1, P2, P4, P5\}$

Reasignación: Comparar cada objeto con P3:

- Evaluando P1:
 - Distancia Promedio a C_2 : $(1 + 3 + 1)/3 = 1.67$
 - Distancia Promedio a C_1 : 4
- Evaluando P2:
 - Distancia Promedio a C_2 : $(1 + 4 + 2)/3 = 2.33$
 - Distancia Promedio a C_1 : 3
- Evaluando P4:
 - Distancia Promedio a C_2 : $(3 + 4 + 2)/3 = 3$
 - **Distancia Promedio a C_1 : 1**
- Evaluando P5:
 - Distancia Promedio a C_2 : $(1 + 2 + 2)/3 = 1.67$
 - Distancia Promedio a C_1 : 3

Se observa que la menor distancia es entre P3 y P4, por lo que P4 abandona C_2 y se incorpora a C_1 .

Resultado:

- $C_1 = \{P3, P4\}$
- $C_2 = \{P1, P2, P5\}$

Iteración 2 – Dividir el clúster más heterogéneo:

Calculamos disimilitud interna:

- $C_1 = (\{P3, P4\})$ (homogéneo).
- $C_2 = (\{P1, P2, P5\})$ (heterogéneo)

Se divide C_2 , y se identifica el objeto más distinto:

- $\bar{d}(P1) = \frac{(d(P1, P2) + d(P1, P5))}{2} = \frac{1+1}{2} = 1$
- $\bar{d}(P2) = \frac{(d(P2, P1) + d(P2, P5))}{2} = \frac{1+2}{2} = 1.5$
- $\bar{d}(P5) = \frac{(d(P5, P1) + d(P5, P2))}{2} = \frac{1+2}{2} = 1.5$

Escogemos alguno entre P2 y P5, usemos P5:

- $C_3 = \{P5\}$
- $C_4 = \{P1, P2\}$

Clústeres actuales:

- $\{P3, P4\}$
- $\{P1, P2\}$
- $\{P5\}$

Iteración 3 – Siguiente división

Dividimos el clúster más grande:

- $\{P1, P2\}$

Distancia:

a) $d(P1, P2) = 1$

Resultado final:

- $\{P3, P4\}$
- $\{P1\}$
- $\{P2\}$
- $\{P5\}$

Interpretación de los clústeres:

Clúster	Interpretación
$\{P3, P4\}$	Importados, no ecológicos
$\{P1, P2\}$	Ecológicos con garantía
$\{P5\}$	Perfil mixto
Individual	Perfiles únicos

4. Un banco chileno desea segmentar a sus clientes según su comportamiento financiero. Para ello se dispone de la siguiente base de datos limpia:

Cliente	Ingreso (MM\$)	Gasto Mensual (MM\$)	N° Productos
C1	1.2	0.8	2
C2	1.5	1.0	3
C3	1.3	0.9	2
C4	4.5	3.5	6
C5	5.0	3.8	7
C6	4.8	3.2	6

Donde las variables consideradas corresponden al Ingreso (ingreso mensual del cliente medido en millones de pesos), Gasto Mensual (monto promedio de gasto mensual del cliente en millones de pesos) y N° de productos (cantidad de productos financieros que el cliente posee en el banco).

Se desea aplicar técnicas de análisis de conglomerados para identificar grupos homogéneos de clientes.

- Explique formalmente qué es el análisis de clustering y cuál es su objetivo en este contexto.
- Justifique porqué es necesario estandarizar los datos antes de aplicar clustering. Estandarice las variables usando el método min-máx.
- Calcule la matriz de distancias euclidianas entre los clientes utilizando R.
- Aplice el método de clustering jerárquico aglomerativo con Single Linkage en R. Determine los clústeres después de las dos primeras iteraciones e interprete.
- Aplice el algoritmo *K-means* en R considerando $k = 2$. Interprete.
- Utilice el método del codo en R para determinar el número óptimo de clústeres. Interprete.
- Evalúe la calidad del clústering del algoritmo *K-means* utilizando el coeficiente de silueta en R. Interprete los resultados obtenidos y comente si la elección de $k=2$ es adecuada.

Solución:

- a) El análisis de clustering es una técnica de aprendizaje no supervisado que permite agrupar observaciones en subconjuntos disjuntos, de modo que la similitud dentro de cada grupo sea alta y entre grupos sea baja.

Formalmente, busca una partición $C_1, \dots, C_k$, que minimice la variabilidad intra-clúster y maximice la variabilidad inter-clúster. En este contexto, permite segmentar clientes con comportamientos financieros similares.

- b) Carga de datos

Carga de datos

```
datos <- data.frame(  
  ingreso = c(1.2,1.5,1.3,4.5,5.0,4.8),  
  gasto = c(0.8,1.0,0.9,3.5,3.8,3.2),  
  productos = c(2,3,2,6,7,6)  
)  
rownames(datos) <- c("C1","C2","C3","C4","C5","C6")  
datos
```

La estandarización es necesaria debido a que las variables se encuentran en distintas escalas. Sin ella, las variables de mayor magnitud dominan el cálculo de distancias.

De esta manera, utilizamos el escalamiento Min-Max:

Min-Max Scaling

```
datos_norm <- as.data.frame(scale(datos,  
                                center = apply(datos, 2, min),  
                                scale = apply(datos, 2, max) - apply(datos, 2, min)))  
datos_norm
```

c) Determinemos la matriz de distancias euclidianas:

Matriz de distancias

```
dist_matrix <- dist(datos, method = "euclidean")
as.matrix(dist_matrix)
```

A continuación, tenemos la matriz:

	C1	C2	C3	C4	C5	C6
C1	0.000000	1.063015	0.1414214	5.8463664	6.959885	5.8923679
C2	1.0630146	0.000000	1.0246951	4.9244289	6.007495	4.9729267
C3	0.1414214	1.024695	0.000000	5.7445626	6.862944	5.7913729
C4	5.8463664	4.924429	5.7445626	0.000000	1.157584	0.4242641
C5	6.9598851	6.007495	6.8629440	1.1575837	0.000000	1.1832160
C6	5.8923679	4.972927	5.7913729	0.4242641	1.183216	0.000000


- Se observan distancias relativamente pequeñas entre los clientes C1, C2 y C3, lo que indica que poseen comportamientos financieros similares (bajo ingreso, bajo gasto y pocos productos).
- De manera análoga, los clientes C4, C5 y C6 presentan distancias pequeñas entre sí, evidenciando un segundo grupo homogéneo con mayores niveles de ingreso, gasto y número de productos.
- Las distancias de separación entre ambos grupos son considerablemente mayores, lo que sugiere una clara separación entre dos segmentos de clientes.

d) Determinemos el clústering jerárquico (Single Linkage):

Single Linkage

```
hc_single <- hclust(dist_matrix, method = "single")  
plot(hc_single)  
cutree(hc_single, k = 2)
```

A partir de lo anterior tenemos:



- En las primeras iteraciones se agrupan los clientes C1 y C3, debido a su alta similitud.
- Posteriormente, se incorpora el cliente C2, formando el clúster {C1, C2, C3}.
- De manera paralela, los clientes C4, C5 y C6 comienzan a agruparse entre sí, formando un segundo grupo.

De esta manera, el método identifica dos clústers principales:

- Clúster 1: Clientes de bajo ingreso, bajo gasto y pocos productos.
- Clúster 2: Clientes de alto ingreso, alto gasto y mayor número de productos.
-

e) Determinemos el método K-means con $k = 2$:

```
K-means

set.seed(123)

km <- kmeans(datos_norm, centers = 2, nstart = 25)
km$cluster
km$centers
```

A partir de lo anterior, tenemos:

```
> km$cluster
C1 C2 C3 C4 C5 C6
 1  1  1  2  2  2
> km$centers
      ingreso      gasto  productos
1 0.03508772 0.03333333 0.06666667
2 0.93859649 0.90000000 0.86666667
```

A partir del resultado de K-means con $k = 2$, se obtiene la siguiente segmentación:

- Clúster 1: C1, C2, C3.
- Clúster 2: C4, C5, C6.

Los centroides muestran que:

- El primer clúster presenta valores bajos en todas las variables normalizadas.
- El segundo clúster presenta valores altos en ingreso, gasto y número de productos.

De esta manera, tenemos:

- Clúster 1: Clientes de bajo valor (segmento masivo o básico).
- Clúster 2: Clientes de alto valor (segmento premium).

Esto permite al banco diseñar estrategias diferenciadas según el perfil del cliente.

f) Método del codo:


```
Elbow Method

wss <- numeric(5)

for (k in 1:5) {
  km <- kmeans(datos_norm, centers = k, nstart = 25)
  wss[k] <- km$tot.withinss
}

plot(1:5, wss, type = "b",
     xlab = "Numero de clusters",
     ylab = "WSS")
```

A partir de lo anterior, tenemos:



El gráfico del método del codo muestra una disminución pronunciada del WSS (*Within Sum of Squares*), al pasar de $k = 1$ a $k = 2$, seguida de una reducción mucho menor para valores mayores de k .

Esto indica la presencia de un punto de inflexión (“codo”) en $k = 2$. De esta manera, el número óptimo de clústeres es $k = 2$, ya que captura la mayor parte de la estructura de los datos sin sobre ajustar el modelo.

g) El coeficiente de silueta toma valores en $[-1, 1]$ y mide qué tan bien asignada está cada observación a su clúster.


- Valores cercanos a 1 indican buena asignación.
- Valores cercanos a 0 indican observaciones en el borde entre clústers.
- Valores negativos sugieren mala asignación.

Luego, tenemos:

```
Silhouette

library(cluster)
km2 <- kmeans(datos_norm, centers = 2, nstart = 25)
sil <- silhouette(km2$cluster, dist(datos_norm))
plot(sil)
```

A partir de lo anterior, tenemos:



De esta manera, el coeficiente de silueta promedio obtenido es aproximadamente 0.87, lo que indica una calidad de clustering excelente.

- Los valores individuales de silueta se encuentran cercanos a 1, lo que indica que las observaciones están muy bien asignadas a sus respectivos clústeres.
- No se observan valores cercanos a 0 ni negativos, lo que implica que no existen observaciones ambiguas ni mal clasificadas.
- Ambos clústeres presentan tamaños equilibrados y valores promedio de silueta elevados, lo que refuerza la calidad de la segmentación.