



Profesores: Carmen Carrasco | Héctor López

Ayudantes: José Ignacio Costa | Cristóbal Van der Meer

Pauta Ayudantía 6

P1- Una empresa de telecomunicaciones desea anticipar qué clientes abandonarán el servicio. Para ello, registró la información de 14 clientes considerando tres variables categóricas: tipo de plan (Básico/Premium), si presentó algún reclamo durante el último trimestre (Sí/No) y su antigüedad en la empresa (Nuevo: menos de 1 año / Antiguo: 1 año o más), junto con si finalmente abandonó el servicio:

Cliente	Plan	Reclamo	Antigüedad	Abandona
1	Básico	Sí	Nuevo	Sí
2	Básico	Sí	Nuevo	Sí
3	Básico	No	Nuevo	Sí
4	Premium	Sí	Nuevo	Sí
5	Básico	Sí	Antiguo	Sí
6	Básico	No	Antiguo	No
7	Premium	No	Antiguo	No
8	Premium	No	Nuevo	No
9	Premium	Sí	Antiguo	No
10	Básico	No	Antiguo	No
11	Premium	No	Antiguo	No
12	Premium	No	Nuevo	No
13	Básico	No	Antiguo	No
14	Premium	Sí	Antiguo	No

- (a) Calcule las probabilidades a priori de cada clase.
- (b) Construya las tablas de verosimilitudes $\mathbb{P}(x_j | C_k)$ para cada variable.
- (c) Un nuevo cliente tiene plan Básico, presentó un reclamo y es Antiguo. Utilizando el clasificador Bayesiano Ingenuo, ¿se predice que abandonará el servicio? Calcule además la probabilidad a posteriori de cada clase.
- (d) Suponga que en la muestra **ningún** cliente que abandonó tuviera plan Premium. ¿Qué problema generaría esto al clasificar a un nuevo cliente Premium? ¿Cómo se soluciona?

Solución:

- (a) Las probabilidades a priori corresponden a la proporción de observaciones en cada clase:

$$\mathbb{P}(\text{Abandona} = \text{Sí}) = \frac{5}{14} = 0,357 \quad \mathbb{P}(\text{Abandona} = \text{No}) = \frac{9}{14} = 0,643$$

(b) Las verosimilitudes se obtienen como frecuencias relativas dentro de cada clase, es decir:

	Plan		Reclamo		Antigüedad	
Abandona	Básico	Premium	Sí	No	Nuevo	Antiguo
Sí	4/5	1/5	4/5	1/5	4/5	1/5
No	3/9	6/9	2/9	7/9	2/9	7/9

(c) Bajo el supuesto ingenuo de independencia condicional, el *score* de cada clase es:

$$\mathbb{P}(C_k | \mathbf{x}) \propto \mathbb{P}(C_k) \cdot \mathbb{P}(\text{Plan} | C_k) \cdot \mathbb{P}(\text{Reclamo} | C_k) \cdot \mathbb{P}(\text{Antigüedad} | C_k)$$

Para el cliente $\mathbf{x} = (\text{Básico}, \text{Sí}, \text{Antiguo})$:

$$\text{Score}(\text{Sí}) = \mathbb{P}(\text{Sí}) \cdot \mathbb{P}(\text{Básico} | \text{Sí}) \cdot \mathbb{P}(\text{Reclamo} | \text{Sí}) \cdot \mathbb{P}(\text{Antiguo} | \text{Sí}) = \frac{5}{14} \cdot \frac{4}{5} \cdot \frac{4}{5} \cdot \frac{1}{5} = 0,046$$

$$\text{Score}(\text{No}) = \mathbb{P}(\text{No}) \cdot \mathbb{P}(\text{Básico} | \text{No}) \cdot \mathbb{P}(\text{Reclamo} | \text{No}) \cdot \mathbb{P}(\text{Antiguo} | \text{No}) = \frac{9}{14} \cdot \frac{3}{9} \cdot \frac{2}{9} \cdot \frac{7}{9} = 0,037$$

Puesto que $\text{Score}(\text{Sí}) = 0,046 > \text{Score}(\text{No}) = 0,037$, el cliente se clasifica como **Abandona = Sí**. Normalizando, se obtienen las probabilidades a posteriori:

$$\mathbb{P}(\text{Sí} | \mathbf{x}) = \frac{0,046}{0,046 + 0,037} = 0,554 \quad \mathbb{P}(\text{No} | \mathbf{x}) = \frac{0,037}{0,046 + 0,037} = 0,445$$

Notemos que, aunque a priori la clase “No” es más frecuente (64 %), el perfil del cliente (plan Básico y con reclamo) es mucho más típico de quienes abandonan, lo que invierte la decisión. Sin embargo, la probabilidad a posteriori es cercana a 0,5, por lo que la clasificación no es muy contundente: su antigüedad (rasgo típico de quienes **no** abandonan) compensa parcialmente las otras dos variables.

De forma equivalente, utilizando software:

Resolución con Comando

```
library(e1071)
clientes <- data.frame(
  plan = c("Basico", "Basico", "Basico", "Premium", "Basico",
           "Basico", "Premium", "Premium", "Premium", "Basico",
           "Premium", "Premium", "Basico", "Premium"),
  reclamo = c("Si", "Si", "No", "Si", "Si", "No", "No",
              "No", "Si", "No", "No", "No", "No", "Si"),
  antig = c("Nuevo", "Nuevo", "Nuevo", "Nuevo", "Antiguo", "Antiguo", "Antiguo",
            "Nuevo", "Antiguo", "Antiguo", "Antiguo", "Nuevo", "Antiguo", "Antiguo"),
  abandona = c("Si", "Si", "Si", "Si", "Si", "No", "No",
               "No", "No", "No", "No", "No", "No", "No"),
  stringsAsFactors = TRUE)

modelo_nb <- naiveBayes(abandona ~ plan + reclamo + antig, data = clientes)
modelo_nb

nuevo <- data.frame(plan = factor("Basico", levels=levels(clientes$plan)),
                    reclamo = factor("Si", levels=levels(clientes$reclamo)),
                    antig = factor("Antiguo", levels=levels(clientes$antig)))
predict(modelo_nb, nuevo, type = "raw")
predict(modelo_nb, nuevo)
```

Esto permite obtener el siguiente resultado en consola:

Consola

```
> modelo_nb
Naive Bayes Classifier for Discrete Predictors

A-priori probabilities:
Y
      No      Si
0.6428571 0.3571429

Conditional probabilities:
      plan
Y      Basico    Premium
No 0.3333333 0.6666667
Si 0.8000000 0.2000000

      reclamo
Y      No      Si
No 0.7777778 0.2222222
Si 0.2000000 0.8000000

      antig
Y      Antiguo    Nuevo
No 0.7777778 0.2222222
Si 0.2000000 0.8000000

> predict(modelo_nb, nuevo, type = "raw")
      No      Si
[1,] 0.4475703 0.5524297
> predict(modelo_nb, nuevo)
[1] Si
Levels: No Si
```

Lo cual coincide con el cálculo manual: $\mathbb{P}(\text{Sí} \mid \mathbf{x}) = 0,5524$, por lo que el cliente se clasifica como un cliente que abandonará el servicio.

(d) Si ningún cliente que abandonó tuviera plan Premium, entonces $\mathbb{P}(\text{Premium} \mid \text{Sí}) = 0/5 = 0$. Como el *score* es un **producto**, cualquier cliente Premium tendría $\text{Score}(\text{Sí}) = 0$, sin importar cuán típicas del abandono fueran sus demás características (por ejemplo, reclamo y antigüedad baja). Es decir, una sola frecuencia nula “anula” toda la evidencia restante.

Este problema (de *frecuencia cero*) se soluciona aplicando el **suavizado de Laplace**, que suma una constante (usualmente 1) a cada conteo:

$$\mathbb{P}(x_j = v \mid C_k) = \frac{n_{jkv} + 1}{n_k + m_j}$$

donde m_j es el número de categorías de la variable j . Así, ninguna probabilidad condicional queda exactamente en cero. En R se implementa con el argumento `laplace = 1` en `naiveBayes()`.

P2- Un fondo de inversión clasifica a las pymes que postulan a financiamiento como **Éxito** o **Fracaso** a partir de dos indicadores: la razón de liquidez (X_1) y la razón de endeudamiento (X_2). A partir de datos históricos, se estimaron los siguientes parámetros por grupo:

Variable	Grupo	Media (μ)	Desv. Est. (σ)
Liquidez (X_1)	Fracaso	1,20	0,40
Liquidez (X_1)	Éxito	2,00	0,50
Endeudamiento (X_2)	Fracaso	0,70	0,10
Endeudamiento (X_2)	Éxito	0,45	0,12

Se presenta una nueva pyme con liquidez $X_1 = 1,5$ y endeudamiento $X_2 = 0,60$.

- Clasifique la pyme con el clasificador Bayesiano Ingenuo Gaussiano, suponiendo probabilidades a priori iguales para ambos grupos.
- Históricamente, el 80 % de las pymes financiadas resultan exitosas. Reclassifique la pyme utilizando estas probabilidades a priori y calcule la probabilidad a posteriori de Éxito.
- Comente el efecto que tienen las probabilidades a priori sobre la decisión.

Hint: Quizás le sirva alguno(s) de estos comandos:

Comando R	Output R
<code>dnorm(1.5, 1.2, 0.4)</code>	0,7528
<code>dnorm(0.6, 0.7, 0.1)</code>	2,4197
<code>dnorm(1.5, 2, 0.5)</code>	0,4839
<code>dnorm(0.6, 0.45, 0.12)</code>	1,5221

Solución:

(a) En el Bayesiano Ingenuo Gaussiano se asume que, dentro de cada grupo, cada variable distribuye normal, $X_j | C_k \sim N(\mu_{jk}, \sigma_{jk}^2)$, y que las variables son condicionalmente independientes. Además, la verosimilitud de cada variable se evalúa con la función de densidad normal:

$$f(x_j | C_k) = \frac{1}{\sigma_{jk} \sqrt{2\pi}} e^{-\frac{(x_j - \mu_{jk})^2}{2\sigma_{jk}^2}}$$

Utilizando los valores del hint:

$$\text{Score}(\text{Fracaso}) = f(1,5 | F) \cdot f(0,6 | F) \cdot \mathbb{P}(F) = 0,7528 \cdot 2,4197 \cdot 0,5 = 0,9108$$

$$\text{Score}(\text{Éxito}) = f(1,5 | E) \cdot f(0,6 | E) \cdot \mathbb{P}(E) = 0,4839 \cdot 1,5221 \cdot 0,5 = 0,3683$$

Puesto que $0,9108 > 0,3683$, la pyme se clasifica como **Fracaso**, con probabilidad a posteriori:

$$\mathbb{P}(\text{Fracaso} | \mathbf{x}) = \frac{0,9108}{0,9108 + 0,3683} = 0,7121$$

Observación: Notemos que algunas verosimilitudes son mayores a 1 (por ejemplo, 2,4197). Esto no es un error: al tratarse de variables continuas, $f(x_j | C_k)$ es una **densidad**, no una probabilidad, por lo que puede superar 1 cuando la desviación estándar es pequeña.

(b) Con probabilidades a priori $\mathbb{P}(E) = 0,8$ y $\mathbb{P}(F) = 0,2$, las verosimilitudes no cambian, solo los priors:

$$\text{Score}(\text{Fracaso}) = 0,7528 \cdot 2,4197 \cdot 0,2 = 0,3643$$

$$\text{Score}(\text{Éxito}) = 0,4839 \cdot 1,5221 \cdot 0,8 = 0,5892$$

Puesto que $0,5892 > 0,3643$, ahora la pyme se clasifica como **Éxito**, con probabilidad a posteriori:

$$\mathbb{P}(\text{Éxito} \mid \mathbf{x}) = \frac{0,5892}{0,5892 + 0,3643} = 0,6179$$

(c) Los datos de la pyme (liquidez y endeudamiento) son, por sí solos, más típicos de una empresa que fracasa: su verosimilitud conjunta es 2,5 veces mayor bajo Fracaso (1,8216) que bajo Éxito (0,7365). Sin embargo, cuando se incorpora que el 80 % de las pymes resultan exitosas, la probabilidad a priori ($0,8/0,2 = 4$ veces más a favor de Éxito) supera esa evidencia e invierte la decisión.

Esto ilustra que la regla de Bayes combina **dos fuentes de información**: lo que dicen los datos del individuo (verosimilitud) y qué tan frecuente es cada grupo en la población (prior). Si los priors no reflejan correctamente la realidad (por ejemplo, usar $0,5/0,5$ cuando los grupos están desbalanceados), el clasificador puede sesgarse hacia el grupo minoritario.

P3- [Ejercicio R] Una institución financiera desea construir una regla para clasificar a sus clientes como **Al día** o **Moroso**, utilizando tres variables: ingreso mensual (**ingreso**, en millones de pesos), carga financiera (**carga**, porcentaje del ingreso destinado a deudas) y antigüedad laboral (**antig**, en años). Se dispone de una muestra de 24 clientes (12 de cada grupo):

Datos

```
datos <- data.frame(
  ingreso = c(
    1.78, 1.22, 1.65, 1.57, 1.37, 0.72, 1.34, 1.24, 1.64, 1.43, 1.46, 1.34,
    1.28, 0.83, 1.27, 0.85, 0.75, 1.33, 0.74, 1.19, 0.85, 1.53, 1.31, 0.98),
  carga = c(
    26.4, 26.4, 10.2, 37.4, 32.3, 29.5, 22.4, 32.8, 25.7, 26.8, 18.3, 38.3,
    49.2, 45.8, 31.5, 40.1, 33.6, 46.0, 36.2, 39.9, 30.9, 33.4, 43.2, 33.0),
  antig = c(7.1, 12.7, 12.2, 7.2, 8.9, 12.2, 4.1, 7.5, 6.2, 8.0, 7.5, 10.5,
    3.2, 3.8, 3.1, 2.9, 0.3, 3.0, 0.3, 5.8, 1.5, 6.4, 4.5, 3.5),
  grupo = factor(rep(c("AlDia", "Moroso"), each = 12)))
```

- Evalúe mediante el test de Box's M si es razonable suponer matrices de covarianza iguales entre los grupos ¿Qué método discriminante sugiere este test?
- Ajuste un modelo LDA e interprete. Además, calcule la matriz de confusión y calcule exactitud, sensibilidad, especificidad, precisión y valor predictivo negativo, considerando **Moroso** como la clase positiva. Interprete al cliente mal clasificado.
- Ajuste un modelo QDA y un modelo Naive Bayes, y compare su exactitud de entrenamiento con la del LDA.
- Evalúe los tres modelos mediante validación cruzada Leave-One-Out (LOO). ¿Qué modelo recomendaría? Justifique.
- Un nuevo cliente presenta **ingreso** = 1,20, **carga** = 35 y **antig** = 5. Clasifíquelo con los tres modelos, reportando la probabilidad a posteriori de ser Moroso.

Solución:

- Definamos H_0 y H_1 :

$$\begin{array}{l|l} \blacksquare & H_0 : \Sigma_{\text{AlDia}} = \Sigma_{\text{Moroso}} \\ \color{red}\blacksquare & H_1 : \Sigma_{\text{AlDia}} \neq \Sigma_{\text{Moroso}} \end{array}$$

Resolución con Comando

```
library(MASS); library(e1071); library(biotools)
boxM(datos[, c("ingreso", "carga", "antig")], datos$grupo)
```

Consola

```
> boxM(datos[, c("ingreso", "carga", "antig")], datos$grupo)
Box's M-test for Homogeneity of Covariance Matrices
data: datos[, c("ingreso", "carga", "antig")]
Chi-Sq (approx.) = 12.624, df = 6, p-value = 0.04942
```

Puesto que $p\text{-value} = 0,0494 < 0,05$, se rechaza H_0 , es decir, existe evidencia de que las matrices de covarianza difieren entre grupos. Según este test, correspondería utilizar **QDA**.

(b) Ajustamos el modelo LDA:

Resolución con Comando

```
modelo_lda <- lda(grupo ~ ingreso + carga + antig, data = datos)
modelo_lda

pred_lda <- predict(modelo_lda, datos)
tabla_lda <- table(Real = datos$grupo, Predicho = pred_lda$class)
tabla_lda
sum(diag(tabla_lda)) / sum(tabla_lda)

datos[pred_lda$class != datos$grupo, ] # Cliente mal clasificado
```

Consola

```
> modelo_lda
Prior probabilities of groups:
  AlDia Moroso
    0.5    0.5

Group means:
      ingreso      carga      antig
AlDia  1.396667  27.20833  8.675000
Moroso  1.075833  38.56667  3.191667

Coefficients of linear discriminants:
      LD1
ingreso -1.15565053
carga    0.07362859
antig    -0.33463810

> tabla_lda
      Predicho
Real      AlDia Moroso
  AlDia     12     0
  Moroso     1     11
> sum(diag(tabla_lda)) / sum(tabla_lda)
[1] 0.9583333

> datos[pred_lda$class != datos$grupo, ]
      ingreso carga antig grupo
22      1.53  33.4   6.4 Moroso
```

La función discriminante lineal obtenida es $LD_1 = -1,156 \cdot (\text{Ingreso}) + 0,074 \cdot (\text{Carga}) - 0,335 \cdot (\text{Antig})$.

Valores altos de LD_1 (bajo ingreso, alta carga financiera y poca antigüedad laboral) se asocian al grupo **Moroso**, lo que es coherente con las medias de cada grupo.

Considerando **Moroso** como clase positiva ($VP = 11$, $FN = 1$, $FP = 0$, $VN = 12$):

Métrica	Cálculo	Resultado
Exactitud (Accuracy)	$(VP + VN)/\text{Total} = (11 + 12)/24$	95,83 %
Sensibilidad (Recall)	$VP/(VP + FN) = 11/12$	91,67 %
Especificidad	$VN/(VN + FP) = 12/12$	100 %
Precisión	$VP/(VP + FP) = 11/11$	100 %
Valor Predictivo Negativo	$VN/(VN + FN) = 12/13$	92,31 %

El único error corresponde al cliente 22, que es Moroso pero fue clasificado como Al día. Esto tiene sentido: su perfil es atípico para un moroso, ya que tiene un ingreso alto (1,53, por sobre la media de ambos grupos), una carga financiera intermedia (33,4 %) y una antigüedad laboral (6,4 años) más cercana a la de los clientes al día. En este contexto, este error (un falso negativo) es el más costoso para la institución, pues implica otorgar crédito a un cliente que no pagará.

(c) Ajustamos QDA y Naive Bayes:

Resolución con Comando

```
modelo_qda <- qda(grupo ~ ingreso + carga + antig, data = datos)
tabla_qda <- table(Real = datos$grupo,
                  Predicho = predict(modelo_qda, datos)$class)
tabla_qda
sum(diag(tabla_qda)) / sum(tabla_qda)

modelo_nb <- naiveBayes(grupo ~ ingreso + carga + antig, data = datos)
modelo_nb$tables
tabla_nb <- table(Real = datos$grupo, Predicho = predict(modelo_nb, datos))
tabla_nb
sum(diag(tabla_nb)) / sum(tabla_nb)
```

Consola

```
> tabla_qda
      Predicho
Real      AlDia Moroso
AlDia      12      0
Moroso       1     11
> sum(diag(tabla_qda)) / sum(tabla_qda)
[1] 0.9583333

> modelo_nb$tables
$ingreso
      ingreso
Y      [,1]      [,2]
AlDia 1.396667 0.2740714
Moroso 1.075833 0.2711410
$carga
      carga
Y      [,1]      [,2]
AlDia 27.20833 7.890438
Moroso 38.56667 6.345411
$antig
      antig
Y      [,1]      [,2]
AlDia 8.675000 2.686033
Moroso 3.191667 1.882676

> tabla_nb
      Predicho
Real      AlDia Moroso
AlDia      12      0
Moroso       1     11
> sum(diag(tabla_nb)) / sum(tabla_nb)
[1] 0.9583333
```

Los tres modelos obtienen la misma exactitud de entrenamiento (95,83 %), fallando únicamente en el cliente 22. Por lo tanto, la exactitud de entrenamiento **no permite discriminar** entre los modelos. Además, recordemos que esta métrica sobreestima el rendimiento real, ya que se evalúa sobre los mismos datos con los que se estimó el modelo.

(d) Realizamos validación cruzada Leave-One-Out. En LDA y QDA se utiliza el argumento `CV = TRUE`; para Naive Bayes, dado que `naiveBayes()` no lo incluye, se programa el ciclo manualmente:

Resolución con Comando

```
# L00 para LDA
loo_lda <- lda(grupo ~ ingreso + carga + antig, data = datos, CV = TRUE)
tabla_loo_lda <- table(Real = datos$grupo, Predicho = loo_lda$class)
tabla_loo_lda
sum(diag(tabla_loo_lda)) / sum(tabla_loo_lda)

# L00 para QDA
loo_qda <- qda(grupo ~ ingreso + carga + antig, data = datos, CV = TRUE)
tabla_loo_qda <- table(Real = datos$grupo, Predicho = loo_qda$class)
tabla_loo_qda
sum(diag(tabla_loo_qda)) / sum(tabla_loo_qda)

# L00 para Naive Bayes
pred_loo_nb <- sapply(1:nrow(datos), function(i) {
  m <- naiveBayes(grupo ~ ingreso + carga + antig, data = datos[-i, ])
  as.character(predict(m, datos[i, ]))
})
tabla_loo_nb <- table(Real = datos$grupo, Predicho = pred_loo_nb)
tabla_loo_nb
sum(diag(tabla_loo_nb)) / sum(tabla_loo_nb)
```

Consola

```
> tabla_loo_lda
      Predicho
Real      AlDia Moroso
AlDia      11      1
Moroso      1      11
> sum(diag(tabla_loo_lda)) / sum(tabla_loo_lda)
[1] 0.9166667

> tabla_loo_qda
      Predicho
Real      AlDia Moroso
AlDia      10      2
Moroso      1      11
> sum(diag(tabla_loo_qda)) / sum(tabla_loo_qda)
[1] 0.875

> tabla_loo_nb
      Predicho
Real      AlDia Moroso
AlDia      12      0
Moroso      1      11
> sum(diag(tabla_loo_nb)) / sum(tabla_loo_nb)
[1] 0.9583333
```

Modelo	Accuracy entrenamiento	Accuracy LOO-CV
LDA	95,83 %	91,67 %
QDA	95,83 %	87,50 %
Naive Bayes	95,83 %	95,83 %

Al validar, las diferencias aparecen: **QDA** es el que más empeora (95,83 % $\rightarrow$ 87,5 %): aunque Box's M rechazó la igualdad de covarianzas, con 12 observaciones por grupo QDA estima demasiados parámetros y se **sobreajusta**. **LDA** pierde algo de exactitud (91,67 %), mientras que **Naive Bayes** mantiene su rendimiento (95,83 %), siendo el más estable, algo esperable por ser el modelo con **menos parámetros** (solo medias y varianzas por grupo, sin covarianzas).

Por lo tanto, se recomienda **Naive Bayes**, o bien LDA como alternativa. Cabe destacar que, con $n = 24$, una diferencia de un solo cliente equivale a 4,17 puntos porcentuales, por lo que las diferencias entre LDA y Naive Bayes deben interpretarse con cautela.

(e) Clasificamos al nuevo cliente con los tres modelos:

Resolución con Comando

```
nuevo <- data.frame(ingreso = 1.20, carga = 35, antig = 5)
predict(modelo_lda, nuevo)$posterior
predict(modelo_qda, nuevo)$posterior
predict(modelo_nb, nuevo, type = "raw")
```

Consola

```
> predict(modelo_lda, nuevo)$posterior
      ALDia      Moroso
1 0.1749858 0.8250142
> predict(modelo_qda, nuevo)$posterior
      ALDia      Moroso
1 0.1112803 0.8887197
> predict(modelo_nb, nuevo, type = "raw")
      ALDia      Moroso
[1,] 0.1764029 0.8235971
```

Los tres modelos clasifican al nuevo cliente como **Moroso**, con probabilidades a posteriori de 0,825 (LDA), 0,889 (QDA) y 0,824 (Naive Bayes). Esto es coherente con su perfil: ingreso (1,20) y antigüedad (5 años) por debajo de la media de los clientes al día, y una carga financiera (35 %) más cercana a la de los morosos. El acuerdo entre los tres modelos da mayor confianza a la clasificación.

P4- Una empresa de envases plásticos evalúa a tres proveedores de resina (A , B y C). Para ello, fabrica 5 envases con la resina de cada proveedor, en orden completamente aleatorio, y mide la resistencia al impacto (en J) de cada envase:

Proveedor	Resistencia (J)				
A	20	22	19	23	21
B	25	27	24	26	28
C	22	20	24	23	21

Considerando un nivel de significancia del 5 %:

- Identifique el factor, sus niveles, la variable de respuesta y el tipo de diseño experimental utilizado.
- Construya la tabla ANOVA.
- ¿Existen diferencias significativas en la resistencia media según el proveedor? Responda utilizando Región Crítica y el valor- p .
- ¿Qué proporción de la variabilidad total de la resistencia es explicada por el proveedor?
- ¿Permite el ANOVA concluir cuál proveedor es el mejor? Justifique.

Hint: Quizás le sirva alguno(s) de estos comandos:

Comando R	qf(0.95,2,12)	qf(0.95,3,12)	pf(14,2,12)	pf(3.89,2,12)
Output R	3,8853	3,4903	0,9993	0,9501

Solución:

(a) El **factor** es el proveedor de resina, con $k = 3$ **niveles** (A , B y C), que en este caso corresponden a los tratamientos. La **variable de respuesta** es la resistencia al impacto (J). Como las $N = 15$ pruebas se realizaron en orden completamente aleatorio y no se consideran otros factores, corresponde a un **Diseño Completamente al Azar (DCA)** balanceado, con $n_i = 5$ repeticiones por tratamiento.

(b) Calculamos el total y la media de cada tratamiento:

$$Y_{A\bullet} = \sum_{j=1}^5 Y_{Aj} = 20 + 22 + 19 + 23 + 21 = 105 \implies \bar{Y}_{A\bullet} = \frac{Y_{A\bullet}}{n_A} = \frac{105}{5} = 21$$

$$Y_{B\bullet} = \sum_{j=1}^5 Y_{Bj} = 25 + 27 + 24 + 26 + 28 = 130 \implies \bar{Y}_{B\bullet} = \frac{Y_{B\bullet}}{n_B} = \frac{130}{5} = 26$$

$$Y_{C\bullet} = \sum_{j=1}^5 Y_{Cj} = 22 + 20 + 24 + 23 + 21 = 110 \implies \bar{Y}_{C\bullet} = \frac{Y_{C\bullet}}{n_C} = \frac{110}{5} = 22$$

Luego, el total general y la media general:

$$Y_{\bullet\bullet} = \sum_{i=1}^3 Y_{i\bullet} = Y_{A\bullet} + Y_{B\bullet} + Y_{C\bullet} = 105 + 130 + 110 = 345$$

$$\bar{Y}_{\bullet\bullet} = \frac{Y_{\bullet\bullet}}{N} = \frac{345}{15} = 23$$

Primero, calculamos la suma de los cuadrados de todas las observaciones, por tratamiento:

$$\begin{aligned}\sum_{j=1}^5 Y_{Aj}^2 &= 20^2 + 22^2 + 19^2 + 23^2 + 21^2 = 400 + 484 + 361 + 529 + 441 = 2215 \\ \sum_{j=1}^5 Y_{Bj}^2 &= 25^2 + 27^2 + 24^2 + 26^2 + 28^2 = 625 + 729 + 576 + 676 + 784 = 3390 \\ \sum_{j=1}^5 Y_{Cj}^2 &= 22^2 + 20^2 + 24^2 + 23^2 + 21^2 = 484 + 400 + 576 + 529 + 441 = 2430 \\ \Rightarrow \sum_{i=1}^3 \sum_{j=1}^5 Y_{ij}^2 &= 2215 + 3390 + 2430 = 8035\end{aligned}$$

Además, el término de corrección, común a SC_T y SC_{TRAT} :

$$\frac{Y_{\bullet\bullet}^2}{N} = \frac{345^2}{15} = \frac{119025}{15} = 7935$$

Luego, la suma de cuadrados total:

$$SC_T = \sum_{i=1}^k \sum_{j=1}^{n_i} Y_{ij}^2 - \frac{Y_{\bullet\bullet}^2}{N} = 8035 - 7935 = 100$$

La suma de cuadrados de tratamientos:

$$SC_{TRAT} = \sum_{i=1}^k \frac{Y_{i\bullet}^2}{n_i} - \frac{Y_{\bullet\bullet}^2}{N} = \frac{105^2}{5} + \frac{130^2}{5} + \frac{110^2}{5} - 7935 = 70$$

Finalmente, la suma de cuadrados del error:

$$SC_E = SC_T - SC_{TRAT} = 100 - 70 = 30$$

Posteriormente, los grados de libertad, con $k = 3$ tratamientos y $N = 15$ observaciones:

$$GL_{TRAT} = k - 1 = 3 - 1 = 2 \quad GL_E = N - k = 15 - 3 = 12 \quad GL_T = N - 1 = 15 - 1 = 14$$

Los cuadrados medios:

$$CM_{TRAT} = \frac{SC_{TRAT}}{k - 1} = \frac{70}{2} = 35 \quad CM_E = \frac{SC_E}{N - k} = \frac{30}{12} = 2,5$$

Y el estadístico de prueba:

$$F_0 = \frac{CM_{TRAT}}{CM_E} = \frac{35}{2,5} = 14$$

Con lo anterior, se obtiene la tabla ANOVA:

FV	SC	GL	CM	F ₀	Valor-p
Tratamientos	70	2	35,0	14	0,0007
Error	30	12	2,5		
Total	100	14			

(c) Definamos H_0 y H_1 :

$$\begin{array}{l} \blacksquare H_0 : \mu_A = \mu_B = \mu_C \\ \blacksquare H_1 : \mu_i \neq \mu_j \text{ para algún } i \neq j \end{array} \quad \Bigg|$$

Luego, determinamos el pivote obtenido:

$$\blacksquare F_{\text{obt}}^{(2,12)} = \frac{CM_{TRAT}}{CM_E} = \frac{35}{2,5} = 14$$

Según Región Crítica, puesto que $F_{\text{obt}}^{(2,12)} = 14 > F_{0,95}^{(2,12)} = 3,8853$, se rechaza H_0 , es decir, existe evidencia suficiente para afirmar que la resistencia media al impacto difiere en al menos un proveedor.

Posteriormente, determinamos el p-value:

$$\blacksquare p_{\text{value}} = \mathbb{P}(F^{(2,12)} > 14) = 1 - \mathbb{P}(F^{(2,12)} \leq 14) = 1 - 0,9993 = 0,0007$$

Finalmente, puesto que $p_{\text{value}} = 0,0007 < 0,05 = \alpha$, se rechaza H_0 , es decir, existe evidencia suficiente para afirmar que la resistencia media al impacto difiere en al menos un proveedor.

(d) La proporción de variabilidad explicada por el factor corresponde a:

$$R^2 = \frac{SC_{TRAT}}{SC_T} = \frac{70}{100} = 0,70$$

Es decir, el 70 % de la variabilidad total en la resistencia se debe a las diferencias entre proveedores, mientras que el 30 % restante corresponde al error aleatorio (variabilidad dentro de cada proveedor).

(e) No. El ANOVA solo permite concluir que **al menos una** media es distinta, pero no indica cuál(es) ni en qué sentido.

Si bien $\bar{Y}_{B\bullet} = 26$ es la media muestral más alta, para afirmar que el proveedor B es significativamente mejor que A y C (y determinar si A y C difieren entre sí) se debe aplicar una prueba de **comparaciones múltiples**, como la prueba de Tukey.

Además, antes de concluir se deben verificar los supuestos del modelo: normalidad, homogeneidad de varianzas e independencia de los residuos.

P5- [Ejercicio R] Una cadena de retail desea comparar la efectividad de cuatro campañas de marketing (A , B , C y D). Cada campaña se aplicó durante 6 semanas en sucursales asignadas aleatoriamente, registrándose las ventas semanales (en millones de pesos):

Datos

```
ventas <- data.frame(
  campana = factor(rep(c("A", "B", "C", "D"), each = 6)),
  ventas = c(12.1, 13.4, 11.8, 12.9, 13.0, 12.4,
             14.8, 15.6, 14.1, 15.9, 15.2, 14.6,
             12.6, 13.9, 12.2, 13.1, 12.8, 13.6,
             16.2, 15.1, 16.8, 15.7, 16.5, 15.9))
```

Considerando un nivel de significancia del 5 %:

- Realice un ANOVA de un factor ¿Existen diferencias en las ventas medias entre campañas?
- Aplique la prueba de Tukey ¿Qué campaña(s) recomendaría?

Solución:

- Definamos H_0 y H_1 :

$$\begin{array}{l} \blacksquare H_0 : \mu_A = \mu_B = \mu_C = \mu_D \\ \blacksquare H_1 : \mu_i \neq \mu_j \text{ para algún } i \neq j \end{array} \quad \Bigg|$$

Resolución con Comando

```
tapply(ventas$ventas, ventas$campana, mean)
modelo <- aov(ventas ~ campana, data = ventas)
summary(modelo)
qf(0.95, 3, 20) # Valor critico
```

Consola

```
> tapply(ventas$ventas, ventas$campana, mean)
      A      B      C      D
12.60000 15.03333 13.03333 16.03333
> summary(modelo)
            Df Sum Sq Mean Sq F value    Pr(>F)
campana      3  47.84   15.948   40.48 1.1e-08 ***
Residuals   20   7.88    0.394
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> qf(0.95, 3, 20) # Valor critico
[1] 3.098391
```

Según Región Crítica, puesto que $F_{\text{obt}}^{(3,20)} = 40,48 > F_{0,05}^{(3,20)} = 3,098$, se rechaza H_0 . De forma equivalente, $p\text{-value} = 1,1 \cdot 10^{-8} < 0,05$. Por lo tanto, existe evidencia suficiente para afirmar que las ventas medias difieren en al menos una campaña. Además, $R^2 = 47,84 / (47,84 + 7,88) = 0,8586$, es decir, la campaña explica cerca del 86 % de la variabilidad de las ventas.

(b) Aplicamos Tukey, que compara todos los pares de medias controlando el error tipo I global:

Resolución con Comando

```
TukeyHSD(modelo, conf.level = 0.95)
```

Consola

```
> TukeyHSD(modelo, conf.level = 0.95)
  Tukey multiple comparisons of means
    95% family-wise confidence level

Fit: aov(formula = ventas ~ campana, data = ventas)

$campana
      diff      lwr      upr    p adj
B-A  2.433333  1.4190052  3.4476661 0.0000087
C-A  0.433333 -0.5809948  1.4476661 0.6364670
D-A  3.433333  2.4190052  4.4476661 0.0000000
C-B -2.000000 -3.0143328 -0.9856672 0.0001156
D-B  1.000000 -0.0143328  2.0143328 0.0541930
D-C  3.000000  1.98566719  4.0143328 0.0000004
```

Un par de campañas difiere significativamente si su $p\text{-adj} < 0,05$ o, de forma equivalente, si su intervalo de confianza **no contiene al cero**:

Comparación	Diferencia	$p\text{-adj}$	Conclusión
$B - A$	2,43	$< 0,001$	Difieren
$C - A$	0,43	0,636	No difieren
$D - A$	3,43	$< 0,001$	Difieren
$C - B$	-2,00	$< 0,001$	Difieren
$D - B$	1,00	0,054	No difieren
$D - C$	3,00	$< 0,001$	Difieren

Se identifican dos grupos homogéneos: $\{A, C\}$, con ventas medias bajas (12,6 y 13,0), y $\{B, D\}$, con ventas medias altas (15,0 y 16,0). Si bien la campaña D presenta la mayor media muestral, su diferencia con B no es estadísticamente significativa ($p\text{-adj} = 0,054$, con un intervalo que incluye al cero por muy poco).

Finalmente, se recomiendan las campañas B o D , las cuales son significativamente mejores que A y C . La elección entre ambas puede basarse en criterios no estadísticos, como el costo de implementación de cada campaña. Dado que el $p\text{-adj}$ de la comparación $D - B$ está muy cerca del umbral, podría ser útil aumentar el número de semanas de observación para determinar con mayor precisión si D supera a B .