

Problemas de Análisis de Conglomerados

1. Concepto de clustering

Explique qué es el análisis de conglomerados y cuál es la diferencia entre **aprendizaje supervisado** y **no supervisado**.

2. Propiedades de los clusters

Explique los conceptos de:

- a) homogeneidad interna
- b) separación entre clusters

¿Por qué son importantes?

3. Definición formal

Sea $X = \{x_1, x_2, \dots, x_n\}$.

Explique qué significa que una partición $C = \{C_1, C_2, \dots, C_k\}$ cumpla:

- a) cobertura
- b) disjuntividad
- c) no vacío

$$A = (2, 8), B = (5, 3)$$

4. Distancia basada en correlación

Explique en qué situaciones es más apropiado utilizar **distancia basada en correlación** en lugar de distancia Euclídea.

5. Distancia Jaccard

Dos observaciones binarias tienen la siguiente tabla:

	j=1	j=0
i=1	3	2
i=0	1	4

Calcule la **distancia de Jaccard**.

6. Z-score

Una variable tiene:

media = 50

desviación estándar = 10

Calcule el **Z-score** de un valor $x = 65$.

7. Min-Max

Considere los valores: [5, 10, 15, 20]

Transforme el valor **15** usando **escalamiento Min-Max [0,1]**.

8. Interpretación

Explique **por qué es necesario estandarizar los datos** antes de aplicar clustering.

9. Considere las distancias entre cuatro observaciones:

	A	B	C	D
A	0	2	6	10
B	2	0	5	9
C	6	5	0	4
D	10	9	4	0

9.1. Single linkage

Determine **qué clusters se fusionan primero** usando **single linkage**.

9.2. Complete linkage

Determine qué clusters se fusionan primero usando **complete linkage**.

10. Interpretación del dendrograma

Explique qué representa la **altura de las fusiones en un dendrograma**.

11. Considere los siguientes puntos:

$$(1, 1), (2, 1), (4, 3), (5, 4)$$

y suponga que los centroides iniciales son:

$$\mu_1 = (1, 1), \mu_2 = (5, 4)$$

- Determine a qué cluster pertenece cada punto en la **primera iteración de K-means**.
- Calcule los **nuevos centroides** después de la primera asignación.
- Mencione **dos ventajas y dos desventajas** del algoritmo **K-means**.

12. Método del codo

Explique cómo funciona el **método del codo (Elbow Method)** y qué información proporciona para elegir el número de clusters.

13. Se tienen 6 empresas con las siguientes variables:

- X_1 : Inversión (millones)
- X_2 : Ventas (millones)

Empresa	X1	X2
E1	2	4
E2	3	5
E3	8	7
E4	9	6
E5	4	3

Empresa	X1	X2
E6	7	8

a) Calcule la **matriz de distancias Euclídeas**.

b) Aplique clustering jerárquico usando:

- Single Linkage
- Complete Linkage
- Ward

c) Dibuje el **dendrograma**.

d) Aplique **K-means con k = 2**.

e) Aplique dos iteraciones del método **DIANA** e identifique las divisiones.

14. Datos de 6 ciudades:

Ciudad	Temperatura	Humedad
C1	20	40
C2	22	45
C3	35	70
C4	33	68
C5	25	50
C6	36	72

a) Calcule la **distancia Manhattan** entre todas las ciudades.

b) Construya la matriz de distancias.

c) Aplique clustering jerárquico usando:

- Single linkage
- Complete linkage

d) Forme **3 clusters**.

e) Compare los resultados con **K-means (k=3)**.

15. Distancia Euclídea con 3 variables

Datos de estudiantes:

Estudiante	Matemática	Estadística	Programación
A	6	7	5
B	5	6	4
C	9	8	9
D	8	9	8
E	4	5	3
F	7	8	7

a) Calcule la **distancia Euclídea** entre los estudiantes.

b) Construya la matriz de distancias.

c) Aplique:

- Single linkage
- Complete linkage
- Centroide

d) Determine los clusters con **k=2**.

e) Aplique **K-means (k=2)**.

f) Compare con **DIANA**.

16. Datos de productos:

Producto	Precio	Calidad	Popularidad
P1	3	7	5
P2	4	6	6
P3	8	9	8
P4	9	8	7
P5	2	5	4
P6	7	8	9

a) Calcule la matriz de **distancias Manhattan**.

b) Aplique clustering jerárquico con:

- Single linkage
- Complete linkage
- Ward

c) Dibuje el dendrograma.

d) Aplique **K-means con k=2**.

e) Compare con **DIANA**.

17. Datos binarios (Jaccard)

Se registró presencia (1) o ausencia (0) de características en 6 especies.

Especie	F1	F2	F3	F4
S1	1	1	0	1
S2	1	0	0	1
S3	0	1	1	0
S4	0	1	1	1
S5	1	0	1	0
S6	0	0	1	1

a) Calcule la **distancia Jaccard** entre las especies.

b) Construya la matriz de distancias.

c) Aplique clustering jerárquico:

- Single linkage
- Complete linkage

d) Obtenga **3 clusters**.

e) Compare con **DIANA**.

18. Datos binarios (Simple Matching)

Datos de preferencias de clientes:

Cliente	Café	Té	Jugo
C1	1	0	1
C2	1	1	1

Cliente	Café	Té	Jugo
C3	0	1	0
C4	0	1	1
C5	1	0	0
C6	0	0	1

a) Calcule la **distancia Simple Matching**.

b) Construya la matriz de distancias.

c) Aplique clustering jerárquico.

d) Compare con **DIANA**.

19. Datos estandarizados

Se tienen los datos:

Empresa	Activos	Empleados
E1	10	50
E2	12	55
E3	45	80
E4	48	78
E5	20	60
E6	42	75

a) Estandarice las variables usando **Z-score**.

- b)** Calcule la **distancia Euclídea**.
- c)** Aplique clustering jerárquico.
- d)** Determine clusters usando **Ward**.
- e)** Compare con **K-means (k=2)**.
- f)** Compare con **DIANA**.

20. Comparación de distancias

Datos de 6 tiendas:

Tienda	Ventas	Clientes
T1	20	100
T2	22	105
T3	50	200
T4	55	210
T5	25	120
T6	52	205

- a)** Calcule:
 - distancia Euclídea
 - distancia Manhattan
- b)** Compare las matrices.
- c)** Aplique clustering jerárquico.
- d)** Determine clusters.
- e)** Compare con **K-means**.