

EXAMEN
MÉTODOS ESTADÍSTICOS PARA LA GESTIÓN
1 DE JULIO DE 2026

Pregunta 1:

El casino Dreams desea rediseñar su programa de lealtad Club Dreams, segmentando a sus clientes en grupos con comportamientos similares para ofrecer beneficios diferenciados. Se seleccionaron 5 clientes representativos y se registraron tres variables comportamentales, ya estandarizadas en una escala de 1 a 10:

- Valor (V): Win Real normalizado (cuánto gana el casino con el cliente).
- Frecuencia (F): Número de visitas anuales normalizado.
- Antigüedad (A): Años de membresía en el programa, normalizado.

Cliente	Valor (V)	Frecuencia (F)	Antigüedad (A)
C1	8	6	9
C2	7	5	9
C3	2	3	2
C4	1	2	3
C5	4	8	5

Se calculó la siguiente matriz de distancias Euclidianas entre los clientes:

	C1	C2	C3	C4	C5
C1	—	1,41	9,70	10,05	6,00
C2	1,41	—	8,83	9,00	5,83
C3	9,70	8,83	—	1,73	6,16
C4	10,05	9,00	1,73	—	7,00
C5	6,00	5,83	6,16	7,00	—

Fórmulas de referencia:

$$Z\text{-score: } z = (x - \mu) / \sigma$$

$$\text{Distancia Euclidian: } d(a, b) = \sqrt{\sum (a_i - b_i)^2}$$

$$\text{Centroide: } \bar{c} = (1/n) \sum x_i \text{ (promedio de las observaciones del grupo)}$$

a) **Estandarización (1,5 puntos):** En el proyecto original de segmentación de Dreams, las variables estaban en escalas muy distintas: Win Real en millones de pesos, Frecuencia en visitas anuales y Antigüedad en años.

1. ¿Por qué es necesario estandarizar las variables antes de calcular distancias para clustering? ¿Qué problema específico se produciría si no se estandariza?
2. El equipo de Dreams utilizó estandarización Z-score. Explique en qué consiste este método y cómo se interpreta un valor $z = -1,5$.

b) **Método del Centroides (3 puntos):** Utilizando la matriz de distancias Euclidianas proporcionada, aplique el método jerárquico aglomerativo del centroides durante 2 iteraciones. En cada iteración debe indicar:

1. Qué par de clústeres/observaciones se fusionan y a qué distancia.
2. El centroides del nuevo clúster formado.
3. La matriz de distancias actualizada (recalculando distancias desde el centroides del nuevo clúster).

c) **Interpretación de Negocios (1,5 puntos):** Tras una tercera iteración, se obtiene una solución con $k = 2$ clústeres: {C1, C2, C5} y {C3, C4}.

1. Describa el perfil de cada clúster en términos de las tres variables. ¿Qué tipo de cliente del casino representa cada grupo?
2. Proponga una estrategia de beneficios diferenciada para cada clúster dentro del programa Club Dreams.

Pregunta 2:

Una empresa manufacturera monitorea el desempeño de **120 máquinas**. Para cada máquina se registraron las siguientes variables:

- Temperatura promedio de operación (°C)
- Consumo eléctrico (kWh)
- Vibración (mm/s)
- Nivel de ruido (dB)
- Producción por hora (unidades)
- Tiempo promedio entre fallas (horas)

Un ingeniero desea resumir la información antes de construir un sistema de monitoreo. Para ello ejecuta el siguiente código en R.

```
datos <- read.csv("maquinas.csv")
pca <- prcomp(datos,
  center = TRUE,
  scale. = TRUE)
```

A partir de los resultados que le entrego R, el ingeniero construyó las siguientes tablas:

Tabla 1: Varianza Explicada

Componente	Desv.Est	Proporción Var.	Var. Acumulada
PC1	2.08	0.72	0.72
PC2	1.01	0.17	0.89
PC3	0.56	0.05	0.94
PC4	0.42	0.03	0.97
PC5	0.30	0.02	0.99
PC6	0.17	0.01	1.00

Tabla 2 Matriz de Cargas

Variable	PC1	PC2
Temperatura	0.47	-0.08
Consumo eléctrico	0.46	-0.18
Vibración	0.45	0.34
Ruido	0.44	0.52
Producción	-0.39	0.69
Tiempo entre fallas	-0.33	-0.33

- a) **1 punto** Explique qué efecto tienen las opciones center=TRUE y scale.=TRUE, del comando prcomp y por qué son recomendables en este problema.
- b) **1 punto** ¿Cuántas componentes conservaría? Justifique su respuesta.
- c) **1 punto** Dibuje el *screeplot*
- d) **1 punto** Interprete la primera componente principal (PC1): ¿Qué representa físicamente una máquina con un puntaje muy alto en PC1?
- e) **1 punto** ¿Qué análisis habría sido conveniente realizar *antes* de lanzarse a obtener los componentes principales.
- f) **1 punto** Considerando que el objetivo final es crear un sistema de monitoreo ¿Qué se gana y qué se pierde al usar componentes principales en este caso?

Pregunta 3:

Pregunta 3.1 Se lleva a cabo un experimento para que un ingeniero adquiriera conocimiento acerca de cómo influye la temperatura de sellado A, la temperatura de enfriamiento de una barra B, el porcentaje de aditivo de polietileno C y la presión D sobre la resistencia del sello (en gramos por pulgada) de un lote de envoltura para pan. Se utiliza un experimento factorial fraccionado

Corrida	A	B	C	D	Respuesta
1	-1	-1	-1	-1	7.6
2	1	-1	-1	1	6.9
3	-1	1	-1	1	7.9
4	1	1	-1	-1	6.1
5	-1	-1	1	1	9.2
6	1	-1	1	-1	6.8
7	-1	1	1	-1	11.4
8	1	1	1	1	7.3

- a) **1 punto** ¿Qué tipo de experimento fraccional se realizó? Describa una relación generadora para este experimento. ¿Qué significa que tenga resolución IV?
- b) **2 puntos**. Suponiendo que las interacciones tienen efecto nulo, estime los efectos principales de los factores A, B, C y D. Identifique cuál factor presenta el mayor efecto absoluto sobre la respuesta y muestre todos los cálculos realizados.

Pregunta 3.2: Con el objetivo de reducir los defectos de fabricación en hojuelas de soya producidas por extrusión, un equipo de ingenieros estudia el efecto de tres variables de proceso: **Temperatura de extrusión** (x_1), **Contenido de humedad de la mezcla** (x_2) y **Velocidad del tornillo de extrusión** (x_3)

Se utiliza un diseño de **Box–Behnken** con tres factores y tres niveles codificados (− 1, 0 y + 1), cuyos valores reales se muestran en la siguiente tabla:

Factor	-1	0	1
Temperatura (°C)	120	145	170
Humedad (%)	25	35	45
Velocidad del tornillo (rpm)	800	900	1000

La variable respuesta es: $Y = \text{Porcentaje de hojuelas rotas (\%)}$ medido al término de cada corrida experimental.

El diseño experimental en unidades codificadas y las respuestas observadas se muestran en el data frame de R.

Basado en los resultados de **R**, responda

- a) **1 punto** ¿El modelo cuadrático de segundo orden fue adecuado para describir la relación entre el porcentaje de hojuelas rotas y los factores experimentales? Determine cuáles términos del modelo son estadísticamente significativos. ¿Qué representa el resultado del R^2 obtenido en este modelo?
- b) **1 punto** Obtenga el punto estacionario de la superficie de respuesta. Solo tenga en cuenta los términos significativos. Clasifique el punto estacionario como un máximo, un mínimo o un punto de silla.
- c) **1 punto** Determine los niveles de temperatura, humedad y velocidad del tornillo que minimizan el porcentaje de hojuelas rotas.

```

# Datos
datos <- data.frame(
  x1 = c(-1,1,-1,1,-1,-1,1,1,0,0,0,0,0,0,0),
  x2 = c(-1,-1,1,1,0,0,0,0,-1,-1,1,1,0,0,0),
  x3 = c(0,0,0,0,-1,1,-1,1,-1,1,-1,1,0,0,0),
  y = c(22,27,31,35,25,32,30,37,24,31,30,38,23,25,23))

# Modelo cuadrático completo
modelo <- lm(
  y ~ x1 + x2 + x3 +
    x1:x2 + x1:x3 + x2:x3 +
    I(x1^2) + I(x2^2) + I(x3^2),
  data = datos
)

options(scipen = 999)

round(summary(modelo)$coefficients, 4)

summary(modelo)

```

```

> round(summary(modelo)$coefficients, 4)

```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	23.6667	0.5725	41.3378	0.0000
x1	2.3750	0.3506	6.7742	0.0011
x2	3.7500	0.3506	10.6961	0.0001
x3	3.6250	0.3506	10.3396	0.0001
I(x1^2)	2.6667	0.5161	5.1673	0.0036
I(x2^2)	2.4167	0.5161	4.6829	0.0054
I(x3^2)	4.6667	0.5161	9.0429	0.0003
x1:x2	-0.2500	0.4958	-0.5042	0.6355
x1:x3	0.0000	0.4958	0.0000	1.0000
x2:x3	0.2500	0.4958	0.5042	0.6355

Residual standard error: 0.9916 on 5 degrees of freedom
 Multiple R-squared: 0.9871, Adjusted R-squared: 0.9639
 F-statistic: 42.58 on 9 and 5 DF, p-value: 0.0003395