

Proyecto Computacional 1

Inferencia sobre una media y análisis factorial

Contexto y base de datos

La generación hidroeléctrica constituye una componente relevante del sistema eléctrico chileno, y su comportamiento depende de forma directa de la disponibilidad del recurso hídrico. Esa disponibilidad se caracteriza mediante los caudales afluentes registrados en los distintos nodos hidráulicos del sistema.

Junto con este enunciado se entrega el archivo AfluentesHistoricosChile.xlsx, que contiene los caudales afluentes medios mensuales de 151 nodos hidráulicos asociados a centrales hidroeléctricas chilenas, para el período enero de 2008 – diciembre de 2018 (132 meses). Los valores están expresados en metros cúbicos por segundo (m^3/s) y corresponden al promedio del mes.

El archivo viene en formato ancho: cada fila es un nodo (columna hydro_node_name) y cada columna posterior es un mes. El equipo deberá investigar y documentar en su informe el significado de los identificadores, en particular la convención de sufijos (_G, _E, _B) que clasifica el tipo de nodo, citando la fuente utilizada.

Preprocesamiento obligatorio

Antes de cualquier análisis, el equipo debe ejecutar y documentar los siguientes pasos. Las decisiones tomadas aquí forman parte de la evaluación:

- **Reestructuración:** convertir la base a formato largo, con una fila por combinación nodo-año-mes y las columnas nodo, año, mes y caudal.
- **Orden temporal:** las columnas del archivo original no están en orden cronológico (siguen el año hidrológico abril-marzo). Verificar y reordenar antes de graficar cualquier serie de tiempo.
- **Agregación anual:** el caudal anual de un nodo se define como el promedio de sus doce caudales medios mensuales. Justificar por qué no corresponde sumar los valores mensuales.
- **Series degeneradas:** identificar y reportar cualquier nodo cuya serie no presente variabilidad a lo largo del período, y excluirlo de los análisis multivariados explicando por qué su inclusión resulta problemática.
- **Semilla:** todo procedimiento aleatorio debe fijar la semilla con el número de grupo, mediante `set.seed(<número de grupo>)`. Los resultados del informe deben ser reproducibles de forma exacta.

Parte 1 — Inferencia sobre una media

Entre 2010 y 2018 la zona centro-sur de Chile atravesó un período prolongado de déficit de precipitaciones, documentado en la literatura como megasequía. Interesa determinar si ese fenómeno se refleja de manera estadísticamente significativa en los caudales afluentes del sistema.

Muestra y variable de interés

Tome una **muestra aleatoria simple de 30 nodos** del total de 151 (sin reemplazo, con la semilla indicada). Para cada nodo i de la muestra, calcule el **cambio porcentual** del caudal medio anual entre el trienio inicial y el trienio final del período:

$$d_i = 100 \times (\bar{C}_i(2016-2018) - \bar{C}_i(2008-2010)) / \bar{C}_i(2008-2010)$$

Valor de referencia: $\mu_0 = 0$, es decir, la afirmación de que en promedio los caudales no cambiaron entre ambos trienios. Nivel de significancia: $\alpha = 5\%$.

Con esa muestra, el equipo debe:

- Plantear formalmente H_0 y H_1 , justificando si la prueba es unilateral o bilateral a partir de la pregunta de investigación (no a partir del resultado observado).
- Verificar los supuestos necesarios con evidencia gráfica (histograma y gráfico cuantil-cuantil) y numérica, y discutir explícitamente el rol del tamaño de muestra.
- Aplicar la prueba adecuada, reportando el estadístico, los grados de libertad, el valor-p y el intervalo de confianza, e interpretar la decisión en términos hidrológicos.

Pregunta obligatoria de discusión

La variable de interés se definió como un cambio porcentual y no como una diferencia absoluta en m^3/s . Repita el cálculo del estadístico usando la diferencia absoluta, compare el comportamiento de ambas variables e indique cuál de las dos permite aplicar válidamente la prueba y por qué. Fundamente su respuesta con la evidencia gráfica y numérica correspondiente.

Parte 2 — Análisis de correlación y factorial

Conjunto de variables a analizar

Ordene los 151 nodos según su caudal medio del período completo y seleccione los **20 de mayor caudal medio**. Construya una matriz de datos en la que:

- las variables (columnas) son las 20 centrales seleccionadas;
- las observaciones (filas) son los 132 meses del período 2008–2018.

Esta orientación es obligatoria: el objetivo es estudiar la estructura de covariación **entre centrales**, tratando cada mes como una observación del sistema. Estandarice las variables antes del análisis y justifique por qué es necesario.

a) Matriz de correlación

- Calcule y presente la matriz de correlación entre las 20 centrales. Comente los pares de mayor y menor asociación.
- Evalúe si la matriz es adecuada para un análisis factorial mediante el test de esfericidad de Bartlett y la medida de adecuación KMO. Plantee las hipótesis del test de Bartlett e interprete ambos resultados.
- Discuta brevemente una limitación del test de Bartlett en este contexto: las observaciones son meses consecutivos de una misma serie y por lo tanto no son independientes entre sí.

b) Análisis de componentes principales

Sobre la matriz estandarizada, realice un análisis de componentes principales y presente:

- el porcentaje de varianza explicado por cada componente y la varianza acumulada;
- el gráfico de sedimentación (scree plot);
- los loadings de los primeros componentes y los scores de las observaciones;
- la representación de las centrales en el plano de los dos primeros componentes.

c) Análisis factorial

- Realice un análisis factorial extrayendo los factores mediante el método de componentes principales.
- Determine cuántos factores conviene retener aplicando todos los criterios estudiados en el curso: regla de Kaiser, porcentaje de varianza explicada, gráfico de sedimentación y análisis paralelo. Reporte qué indica cada criterio y discuta las discrepancias entre ellos.
- Independientemente del punto anterior, retenga dos factores y aplique rotación varimax. Reporte la matriz de cargas rotada y las comunales de cada central.
- Interprete y asigne un nombre a cada uno de los dos factores rotados, señalando qué centrales cargan en cada uno (utilice el umbral de carga significativa visto en clases).

Validación de la interpretación

Para respaldar la interpretación de los factores con evidencia independiente del análisis factorial, calcule para cada una de las 20 centrales el mes calendario en que alcanza su caudal medio máximo (promediando cada mes a lo largo de los once años). Contraste ese resultado con la agrupación obtenida en la rotación y discuta si ambas evidencias son consistentes.

Condiciones de entrega

Los resultados deben presentarse en un informe técnico que contenga al menos:

- **Introducción:** contexto del problema y objetivos del informe.
- **Metodología y datos:** origen de los datos y significado de las variables; preprocesamiento y selección de la muestra; estadísticos descriptivos y gráficos pertinentes; y métodos utilizados.
- **Resultados:** separados en dos subcapítulos, uno por cada parte.
- **Conclusiones.**
- **Referencias.**

Adicionalmente se debe entregar la base de datos utilizada y todo el código empleado en el análisis, en un único script R ordenado y comentado, con la semilla fijada, que reproduzca los resultados del informe al ejecutarse de principio a fin.

Trabajo en grupos de dos personas. Extensión sugerida del informe: 12 a 18 páginas, sin contar anexos.

Evaluación

Esta entrega se corrige con la Rúbrica de Evaluación del Proyecto Computacional — Entrega 1, sobre un total de 100 puntos, con 60% de exigencia (nota 4,0 = 60 puntos). El puntaje de cada criterio se obtiene multiplicando su puntaje máximo por el porcentaje del nivel de logro alcanzado.

Ponderación en la nota final del curso: 10% de la nota final (equivale al 25% del proyecto, que en total pondera 40%).

Criterio	Pts.	Qué se evalúa (nivel destacado)
Introducción y objetivos	10	Contextualiza el rol de la generación hidroeléctrica y del recurso hídrico, y plantea objetivos específicos alineados con las dos partes del trabajo.
Metodología y datos	15	Documenta el origen y el significado de las variables e identificadores; explica la reestructuración a formato largo, el criterio de agregación anual, el tratamiento de series degeneradas y la selección de la muestra (con semilla). Presenta descriptivos y gráficos pertinentes y justifica los métodos.
Aplicación técnica: inferencia (P1) y análisis factorial (P2)	30	P1: plantea H_0/H_1 sobre la media, verifica los supuestos con evidencia gráfica y numérica, y aplica la prueba adecuada al nivel de significancia declarado. P2: evalúa la significancia de la matriz de correlación (Bartlett y KMO), ejecuta el análisis factorial por componentes principales, aplica los criterios de retención estudiados y realiza la rotación varimax con dos factores.
Análisis e interpretación de resultados	20	Interpreta la decisión de la prueba en términos hidrológicos y nombra los dos factores rotados a partir de sus cargas, contrastando la interpretación con evidencia independiente (estacionalidad observada).
Conclusiones	10	Responden a los objetivos, integran ambas partes y reconocen alcances y limitaciones (dependencia temporal, asimetría, alcance del período).
Calidad del informe y referencias	10	Estructura completa, redacción clara, tablas y gráficos rotulados con unidades, y referencias en formato consistente.

Criterio	Pts.	Qué se evalúa (nivel destacado)
Reproducibilidad (base de datos y códigos)	5	Entrega la base y el código R ordenado, comentado y ejecutable, con semilla fijada, que reproduce exactamente los resultados del informe.
TOTAL	100	

El detalle de los cuatro niveles de logro (Destacado, Competente, Suficiente, Insuficiente) de cada criterio se encuentra en el documento Rúbrica de Evaluación del Proyecto Computacional.