

Proyecto Computacional 2

Análisis de conglomerados y clasificación supervisada

Contexto y base de datos

Una plataforma digital de delivery opera en las principales ciudades de Chile e intermedia pedidos entre sus clientes y los comercios asociados a ella, agrupados en cuatro categorías: restaurantes, supermercados, farmacias y tiendas de conveniencia. Sus ingresos provienen de la comisión que cobra por cada pedido, de modo que la recurrencia de los clientes es su variable crítica de gestión.

El área de Business Intelligence de la plataforma ha detectado dos problemas. Primero, una fracción relevante de los clientes reduce su nivel de gasto o deja de pedir de un trimestre a otro, y hoy no existe forma de anticipar quiénes lo harán. Segundo, las campañas de retención se ejecutan de manera indiferenciada —el mismo cupón para toda la base—, con un costo que crece más rápido que los ingresos que logran recuperar.

La gerencia comercial plantea entonces dos preguntas para su plan del próximo año. ¿Qué tipos de cliente conviven en la base, según su patrón de uso de la plataforma? Y, con la información disponible al cierre del primer trimestre, ¿es posible anticipar en qué nivel de gasto estará un cliente durante el trimestre siguiente, de modo de concentrar el presupuesto de retención en quienes están en riesgo?

Junto con este enunciado se entregan cinco archivos **grupo_i_clientes.csv** ($i \in \{1, 2, 3, 4, 5\}$). Cada uno contiene una muestra aleatoria simple de 1.000 clientes registrados en la plataforma (C-0001, ..., C-1000), observados durante el primer semestre del año. La regla que asigna un archivo a cada grupo, y la submuestra sobre la que debe trabajar, se indican en la sección siguiente.

Variables de la base

- **id_cliente**: identificador único del cliente.
- **dias_ultima_sesion**: días transcurridos entre la última sesión del cliente en la aplicación y el cierre del primer trimestre (T1). El valor está truncado en 180 días: a quienes llevan más de ese tiempo sin abrir la aplicación se les registra 180.
- **pedidos_12m**: número de pedidos que el cliente realizó en los doce meses previos al cierre del T1.
- **ticket_promedio**: gasto promedio por pedido del cliente durante el T1, en miles de pesos. Vale 0 si el cliente no realizó pedidos en ese trimestre.
- **pct_restaurantes**: proporción del gasto histórico del cliente en la plataforma destinada a comercios de la categoría restaurantes; el resto se reparte entre supermercados, farmacias y tiendas de conveniencia.
- **estado_t1**: nivel de gasto del cliente en el primer trimestre (Alto Gasto, Medio Gasto, Bajo Gasto o Inactivo).
- **estado_t2**: nivel de gasto del cliente en el segundo trimestre, con los mismos cuatro niveles.

Los niveles de **estado_t1** y **estado_t2** se definen a partir del gasto promedio por pedido del trimestre correspondiente:

- **Alto Gasto**: clientes cuyo gasto promedio por pedido es mayor a 50 mil pesos.
- **Medio Gasto**: clientes cuyo gasto promedio por pedido está entre 20 mil y 50 mil pesos, incluyendo ambos límites.
- **Bajo Gasto**: clientes cuyo gasto promedio por pedido es menor a 20 mil pesos.
- **Inactivo**: clientes que no realizaron pedidos en el trimestre analizado.

Advertencia sobre estado_t1

La variable **estado_t1** es una recodificación determinística de **ticket_promedio**: se obtiene aplicando los cortes anteriores a esa misma variable, de modo que no aporta información adicional sobre el cliente. Queda prohibido usarla como variable de clase. Si el equipo decide incluirla como predictora, debe justificar la decisión y comentar explícitamente su redundancia con **ticket_promedio**.

Reglas de trabajo y preprocesamiento obligatorio

Antes de cualquier análisis, el equipo debe ejecutar y documentar los siguientes pasos. Las decisiones tomadas aquí forman parte de la evaluación:

- **Base asignada y submuestra:** a cada grupo le corresponde el archivo grupo_i_clientes.csv con $i = ((\text{número de grupo} - 1) \bmod 5) + 1$. Sobre esa base, el equipo debe extraer una muestra aleatoria simple de 800 de los 1.000 clientes, sin reemplazo, mediante `set.seed(<número de grupo>)`. Todo el análisis del informe se realiza sobre esa submuestra: ningún resultado puede provenir de la base completa.
- **Semilla:** todo procedimiento aleatorio —partición de los datos, inicialización de k-medias, validación cruzada— debe fijar la semilla con el número de grupo, mediante `set.seed(<número de grupo>)`. Los resultados del informe deben ser reproducibles de forma exacta.
- **Descriptivos:** presentar estadísticos descriptivos y gráficos pertinentes de las cuatro variables continuas, y la distribución de frecuencias de estado_t1 y estado_t2.
- **Ceros estructurales:** los clientes con `ticket_promedio = 0` no corresponden a datos faltantes, sino a quienes no hicieron pedidos durante el T1. Explicitar qué tratamiento se les da y qué efecto tiene esa decisión sobre los análisis posteriores.
- **Truncamiento:** la variable `dias_ultima_sesion` está truncada en 180 días. Discutir brevemente qué implica ese techo para la interpretación de los resultados.
- **Escalamiento:** justificar si las variables se estandarizan o no antes de cada análisis, considerando que están medidas en unidades distintas.
- **Correlación:** calcular la matriz de correlación de las cuatro variables continuas y comentar cómo la asociación entre ellas afecta el cálculo de distancias en la Parte 1 y el supuesto de independencia de alguno de los clasificadores de la Parte 2.

Parte 1 — Análisis de conglomerados

El objetivo de esta parte es responder la primera pregunta de la gerencia comercial: qué tipos de cliente conviven en la base y cómo se diferencian entre sí.

Variables para la segmentación

La segmentación debe construirse únicamente con las cuatro variables continuas:

dias_ultima_sesion, pedidos_12m, ticket_promedio y pct_restaurantes. Las variables **estado_t1** y **estado_t2** no pueden participar en esta parte: se reservan para las Partes 2 y 3.

- Aplicar un método jerárquico, justificando la medida de distancia utilizada y comparando al menos dos criterios de enlace. Presentar el dendrograma y explicar cómo se lee el corte elegido.
- Aplicar k-medias y determinar el número de conglomerados aplicando los criterios estudiados en el curso. Reportar qué indica cada criterio y discutir las discrepancias entre ellos.
- Comparar la solución jerárquica con la de k-medias mediante una tabla de contingencia y comentar la estabilidad de la segmentación obtenida.
- Caracterizar cada conglomerado con sus centroides expresados en las unidades originales de las variables, no en las estandarizadas, y asignarle un nombre que refleje su comportamiento.

- Proponer una acción comercial concreta para cada segmento —presupuesto de retención, frecuencia de contacto, tipo de incentivo—, explicitando la evidencia del análisis en la que se basa cada propuesta.

Parte 2 — Clasificación supervisada

El objetivo de esta parte es responder la segunda pregunta: anticipar el nivel de gasto de un cliente en el trimestre siguiente con la información disponible al cierre del primero.

Variable de clase y predictores

La variable de clase es **estado_t2**, con sus cuatro niveles. Los predictores son las cuatro variables continuas, con la posibilidad de incluir **estado_t1** bajo la advertencia señalada más arriba. Note que el ejercicio es predictivo: todas las variables predictoras están disponibles al cierre del T1, es decir, antes de que se observe la clase.

- Reportar la distribución de la variable de clase y definir el clasificador trivial —aquel que asigna a todos los clientes la clase mayoritaria— como referencia obligatoria contra la cual comparar todo modelo ajustado.
- Separar los datos en entrenamiento y validación (por ejemplo, 70% y 30%, preservando la proporción de clases) o utilizar validación cruzada. Explicar por qué el desempeño no puede evaluarse sobre los mismos datos con los que se ajustó el modelo.
- Verificar los supuestos de los métodos: normalidad multivariante dentro de cada clase y homogeneidad de las matrices de covarianza. Decidir entre análisis discriminante lineal y cuadrático a partir de esa evidencia, y no del resultado obtenido.
- Ajustar al menos dos clasificadores de los estudiados en el curso, incluyendo Naive Bayes, y explicitar qué supone cada uno sobre los datos y en qué medida ese supuesto se cumple en esta base.
- Reportar la matriz de confusión sobre el conjunto de validación y las métricas por clase —sensibilidad y precisión—, además del desempeño global. Un porcentaje alto de aciertos en presencia de clases desbalanceadas no es evidencia suficiente de un buen modelo.
- Analizar los errores: identificar entre qué clases se concentra la confusión, explicar por qué ese patrón tiene sentido en términos del negocio y señalar qué variables discriminan mejor cada clase.

Pregunta obligatoria de discusión

El costo de los errores no es simétrico: clasificar como Alto Gasto a un cliente que terminará Inactivo tiene consecuencias distintas para la plataforma que el error contrario. Modifique las probabilidades a priori de al menos uno de los clasificadores ajustados, reporte cómo cambian la matriz de confusión y las métricas por clase, y discuta qué configuración le recomendaría a la gerencia comercial si el objetivo es priorizar el presupuesto de retención. Fundamente la recomendación con la evidencia numérica correspondiente.

Parte 3 — Integración de ambos análisis

- Construir la tabla de contingencia entre los conglomerados obtenidos en la Parte 1 y la variable **estado_t2**. ¿Los segmentos descubiertos sin supervisión anticipan el nivel de gasto del trimestre siguiente, o describen una estructura distinta?
- Evaluar si incorporar el conglomerado como variable predictora adicional mejora el desempeño del clasificador. Interpretar el resultado: qué significaría que mejorara y qué significa que no lo haga.
- Concluir cuál de las dos miradas —la segmentación descriptiva o la clasificación predictiva— responde mejor a cada una de las dos preguntas de la gerencia comercial, y por qué.

Condiciones de entrega

Los resultados deben presentarse en un informe técnico que contenga al menos:

- **Introducción:** contexto del problema y objetivos del informe.
- **Metodología y datos:** significado de las variables; preprocesamiento y decisiones documentadas; estadísticos descriptivos y gráficos pertinentes; y métodos utilizados en el análisis.
- **Resultados:** separados en subcapítulos, uno por cada parte.
- **Conclusiones.**
- **Referencias.**

Adicionalmente se debe entregar la base de datos utilizada y todo el código empleado en el análisis, en un único script R ordenado y comentado, con la semilla fijada, que reproduzca los resultados del informe al ejecutarse de principio a fin.

Trabajo en los mismos grupos de la Entrega 1. Extensión sugerida del informe: 12 a 18 páginas, sin contar anexos.

Evaluación

Esta entrega se corrige con la Rúbrica de Evaluación del Proyecto Computacional — Entrega 2, sobre un total de 100 puntos, con 60% de exigencia (nota 4,0 = 60 puntos). El puntaje de cada criterio se obtiene multiplicando su puntaje máximo por el porcentaje del nivel de logro alcanzado.

Ponderación en la nota final del curso: 15% de la nota final (equivale al 37,5% del proyecto, que en total pondera 40%).

Criterio	Pts.	Qué se evalúa (nivel destacado)
Introducción y objetivos	10	Contextualiza el problema de recurrencia y retención de la plataforma y plantea objetivos específicos alineados con las tres partes del trabajo.
Metodología y datos	15	Documenta el significado de las variables y el preprocesamiento (ceros estructurales, truncamiento, estandarización, correlación); presenta descriptivos y gráficos pertinentes; justifica los métodos y fija la semilla.
Aplicación técnica: análisis de conglomerados (P1)	12	Aplica un método jerárquico y k-medias, justifica la medida de distancia y el número de conglomerados con los criterios estudiados, compara ambas soluciones y caracteriza los segmentos en unidades originales.
Aplicación técnica: clasificación supervisada (P2)	20	Ajusta al menos dos clasificadores pertinentes, verifica los supuestos, separa entrenamiento y validación (o usa validación cruzada), reporta matriz de confusión y métricas por clase, compara contra el clasificador trivial y analiza el efecto de modificar las probabilidades a priori.
Análisis, interpretación e integración (P3)	18	Interpreta los segmentos y el desempeño del modelo en términos del negocio, explica dónde se concentran los errores de clasificación e integra ambos análisis mediante la tabla de contingencia entre conglomerados y estado_t2.
Conclusiones	10	Responden a los objetivos, integran las tres partes y reconocen alcances y limitaciones.
Calidad del informe y referencias	10	Estructura completa, redacción clara, tablas y gráficos rotulados con unidades, y referencias en formato consistente.
Reproducibilidad (base de datos y códigos)	5	Entrega la base y el código R ordenado, comentado y ejecutable, con semilla fijada, que reproduce exactamente los resultados del informe.
TOTAL	100	

El detalle de los cuatro niveles de logro (Destacado, Competente, Suficiente, Insuficiente) de cada criterio se encuentra en el documento Rúbrica de Evaluación del Proyecto Computacional.